

Phelipe Pereira de Souza

Deteccção de Intenção Implícita para Ativação de Assistentes de Voz em Ambientes Controlados

São Paulo

2026

Phelipe Pereira de Souza

Detecção de Intenção Implícita para Ativação de Assistentes de Voz em Ambientes Controlados

Proposta de Trabalho de Conclusão de Curso
apresentado ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do Bacharelado em Ciência da Com-
putação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Prof. Thyago Conchado Quintas

São Paulo
2026

Lista de ilustrações

Figura 1 – Projeção de crescimento do mercado global de assistentes virtuais de voz (2024–2030).	7
Figura 2 – Cenário ilustrativo de Detecção de Fala Direcionada ao Dispositivo (DDSD).	8
Figura 3 – Fluxo de seleção de estudos para a revisão bibliográfica.	15
Figura 4 – Arquitetura do pipeline proposto	41
Figura 5 – Cronograma de execução previsto para o TCC2	56

Lista de tabelas

Tabela 1	–	Mapeamento de tecnologias e seus papéis no trabalho	10
Tabela 2	–	Comparação técnica entre os trabalhos relacionados	38
Tabela 3	–	Diferencial deste TCC em relação aos trabalhos relacionados	38
Tabela 4	–	Variantes do Whisper avaliadas no módulo ASR	42
Tabela 5	–	Hiperparâmetros iniciais para o <i>fine-tuning</i> do BERTimbau	44
Tabela 6	–	Exemplo de diálogo sintético gerado por LLM com rótulos de classe . .	49
Tabela 7	–	Fontes, estratégias e volumes estimados do corpus de DDS em PT-BR	50
Tabela 8	–	Tecnologias e ferramentas previstas para o desenvolvimento	54
Tabela 9	–	Marcos e entregáveis por fase do TCC2	56

Lista de abreviaturas e siglas

ASR	<i>Automatic Speech Recognition</i> (Reconhecimento Automático de Fala)
DDSD	<i>Device-Directed Speech Detection</i> (Detecção de Fala Direcionada ao Dispositivo)
EER	<i>Equal Error Rate</i> (Taxa de Erro Igual)
HCI	<i>Human-Computer Interaction</i> (Interação Humano-Computador)
LLM	<i>Large Language Model</i> (Modelo de Linguagem de Grande Porte)
LR	<i>Logistic Regression</i> (Regressão Logística)
ML	<i>Machine Learning</i> (Aprendizado de Máquina)
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
NLU	<i>Natural Language Understanding</i> (Compreensão de Linguagem Natural)
SVM	<i>Support Vector Machines</i> (Máquinas de Vetores de Suporte)
TF-IDF	<i>Term Frequency-Inverse Document Frequency</i> (Frequência do Termo - Inverso da Frequência nos Documentos)
TTS	<i>Text-to-Speech</i> (Síntese de Fala)
VAD	<i>Voice Activity Detection</i> (Detecção de Atividade de Voz)
WER	<i>Word Error Rate</i> (Taxa de Erro de Palavras)

Sumário


1	INTRODUÇÃO	7
1.1	Cenário motivador	8
1.2	Contexto	9
1.3	Justificativa	11
1.4	Hipótese de pesquisa	12
1.5	Objetivos	12
1.5.1	Objetivo principal	12
1.5.2	Objetivos específicos	13
1.6	Limitações do trabalho	13
2	REVISÃO BIBLIOGRÁFICA	15
2.1	Metodologia da pesquisa bibliográfica	15
2.2	Referencial teórico	16
2.2.1	Assistentes virtuais e interação por voz	17
2.2.2	Deteção de Atividade de Voz (VAD)	17
2.2.3	Reconhecimento Automático de Fala (ASR)	18
2.2.4	Wake-words: mecanismo, vantagens e limitações	19
2.2.5	Deteção de Fala Direcionada ao Dispositivo (DDSD)	20
2.2.6	Processamento de Linguagem Natural e classificação de intenção	21
2.2.7	Modelos baseados em Transformers	22
2.3	Fundamentos	23
2.3.1	Arquitetura Transformer	23
2.3.2	BERT e o mecanismo de fine-tuning	25
2.3.3	BERTimbau: BERT para o português brasileiro	26
2.3.4	DeBERTa, DeBERTinha e Albertina PT-BR	27
2.3.5	Modelos baseline: TF-IDF, SVM e Regressão Logística	28
2.3.6	ASR com Whisper	29
2.3.7	Métricas de avaliação	30
2.4	Trabalhos relacionados	32
2.4.1	<i>Device-directed Utterance Detection</i>	32
2.4.2	<i>A Multimodal Approach to Device-Directed Speech Detection with Large Language Models</i>	34
2.4.3	<i>Leveraging Large Language Models for Exploiting ASR Uncertainty</i>	36
2.4.4	Síntese comparativa	37
3	DESENVOLVIMENTO	40

3.1	Visão geral da solução proposta	40
3.1.1	Arquitetura do pipeline	40
3.1.2	Definição de ambiente controlado	41
3.2	Módulo ASR: transcrição e geração do <i>n-best</i>	42
3.2.1	Escolha e configuração do Whisper	42
3.2.2	Estratégia de uso do <i>n-best</i>	43
3.2.3	Impacto esperado dos erros de transcrição (WER)	43
3.3	Módulo de classificação de intenção	44
3.3.1	Modelo principal: BERTimbau com <i>fine-tuning</i>	44
3.3.2	Modelos alternativos: DeBERTinha e Albertina	45
3.3.3	Baselines clássicos: TF-IDF + SVM e Regressão Logística	45
3.4	Construção do corpus	46
3.4.1	Esquema de rotulação	46
3.4.2	Fontes de dados e estratégias de construção	47
3.4.2.1	Classe NDD: datasets públicos de fala espontânea	47
3.4.2.2	Classes DD e AMB: geração sintética assistida por LLM	48
3.4.3	Protocolo de validação e controle de qualidade	50
3.4.4	Divisão treino / validação / teste	51
3.5	Planejamento experimental	51
3.5.1	Configuração dos experimentos e hiperparâmetros	51
3.5.2	Experimento <i>upper-bound</i> : transcrição manual <i>versus</i> automática	52
3.5.3	Análise de interpretabilidade	53
3.6	Critérios de validação e aceitação da hipótese	53
3.7	Tecnologias e ferramentas	54
3.8	Resultados esperados	54
3.9	Cronograma de trabalho	55
	REFERÊNCIAS	58

1 Introdução

Nas últimas décadas, os assistentes de voz tornaram-se componentes cada vez mais presentes no cotidiano, incorporados a *smartphones*, alto-falantes inteligentes, *wearables* e sistemas de automação residencial (JURAFSKY; MARTIN, 2024). Esses sistemas permitem que usuários interajam com dispositivos computacionais por meio de comandos de voz, facilitando a execução de tarefas como busca de informações, controle de dispositivos domésticos e gerenciamento de atividades. O mercado global de assistentes de voz foi avaliado em US\$ 7,35 bilhões em 2024 e projeta-se que alcance US\$ 33,74 bilhões até 2030, com taxa de crescimento anual composta de 26,5%, o que evidencia a escala e a relevância dessa tecnologia, conforme ilustrado no gráfico de projeção da Figura 1 (Next Move Strategy Consulting, 2025).

Figura 1 – Projeção de crescimento do mercado global de assistentes virtuais de voz (2024–2030).



Fonte: Next Move Strategy Consulting (2025).

Na maioria dos sistemas atuais, a interação com assistentes de voz é iniciada por meio de palavras de ativação explícitas, conhecidas como *wake-words* ou *hotwords*, tais como “Hey Siri”, “Alexa” ou “Ok Google”. Essas expressões atuam como um mecanismo de gatilho que sinaliza ao sistema o desejo do usuário de iniciar uma interação. Do ponto de vista técnico, essa abordagem é eficaz, pois permite reduzir o processamento contínuo de áudio e minimizar ativações indevidas (GARG et al., 2021). No entanto, a dependência de *wake-words* impõe limitações significativas à naturalidade da comunicação humano-computador, tornando a interação menos fluida e intuitiva quando comparada ao diálogo humano (NIE et al., 2021).

Em interações humanas cotidianas, comandos e solicitações são frequentemente expressos de forma implícita, inseridos naturalmente no fluxo da conversação, sem a necessidade de uma palavra específica para iniciar a comunicação (WELD et al., 2022). Em contraste, os sistemas baseados em *wake-words* são vulneráveis ao fenômeno de ativações falsas por palavras foneticamente semelhantes, conhecido como *Fake Wake* (CHEN et al., 2021). Esse


problema compromete a qualidade da experiência do usuário, evidenciando as limitações da abordagem atual para a viabilização de uma interação verdadeiramente natural e intuitiva.

Nesse cenário, surge a área de pesquisa denominada *Device-Directed Speech Detection* (traduzido como Detecção de Fala Direcionada ao Dispositivo, referenciado pela sigla DDSD), que visa determinar automaticamente se uma fala é direcionada a um assistente virtual, mesmo na ausência de uma palavra de ativação explícita, ou se faz parte de uma conversa entre humanos (MALLIDI et al., 2018; WAGNER et al., 2024). Essa abordagem possibilita interações mais naturais e fluidas, reduzindo a necessidade de gatilhos verbais explícitos (*wake-words*) e representando um avanço significativo rumo a uma comunicação humano-computador mais intuitiva e semelhante ao diálogo cotidiano.

Este trabalho investiga a viabilidade da DDSD em português brasileiro por meio de uma abordagem baseada exclusivamente no nível textual. O sistema proposto opera com transcrições de fala obtidas via Reconhecimento Automático de Fala (do inglês *Automatic Speech Recognition*, referido pela sigla ASR), e aplica técnicas de Processamento de Linguagem Natural (do inglês *Natural Language Processing*, referido pela sigla NLP) e Aprendizado de Máquina (do inglês *Machine Learning*, referido pela sigla ML) para classificar automaticamente se uma fala é direcionada ao dispositivo ou faz parte de uma conversa incidental entre humanos. O foco deste trabalho reside na etapa de classificação de intenção, tratando o ASR como um módulo de pré-processamento encarregado de gerar as transcrições textuais que servirão de entrada para o classificador.

1.1 Cenário motivador

Figura 2 – Cenário ilustrativo de Detecção de Fala Direcionada ao Dispositivo (DDSD).



Fonte: Elaborado pelo autor (2026).

Para ilustrar a complexidade e a relevância do problema, considere o cenário prático apresentado na Figura 2: em uma sala de estar, duas pessoas conversam informalmente na

presença de um assistente de voz ativo. Uma delas comenta, em tom casual: “nossa, está escuro aqui”. O sistema não deve acionar a iluminação, visto que o enunciado constitui apenas um comentário incidental e não uma instrução direcionada. Momentos depois, a mesma pessoa olha para o dispositivo e diz: “acende a luz da sala”. Nesse cenário, mesmo na ausência de uma *wake-word*, o assistente deve ser capaz de reconhecer a fala como claramente direcionada a ele.

Esse cenário ilustra as três classes de enunciados que o sistema precisa distinguir: (i) comandos implícitos direcionados ao dispositivo (DD, do inglês *Device-Directed*), como “acende a luz”; (ii) comentários incidentais e conversas paralelas, classificados como não direcionados ao dispositivo (NDD, do inglês *Non-Device-Directed*), como “nossa, está escuro aqui”; e (iii) enunciados ambíguos (AMB), cujo direcionamento depende estritamente do contexto extraverbal, como “apaga a luz, por favor”, que pode ser direcionado tanto a um interlocutor humano quanto ao assistente. O problema de DDSD consiste precisamente em classificar automaticamente esses enunciados em tempo real, sem depender de *wake-words* explícitas (MALLIDI et al., 2018; WAGNER et al., 2024).

1.2 Contexto

O desenvolvimento de assistentes de voz tem sido impulsionado por avanços significativos nas áreas de ASR e NLP. Modelos de última geração, como o Whisper (RADFORD et al., 2023), representam marcos importantes ao viabilizar a transcrição de áudio com elevada precisão e robustez em múltiplos idiomas. Em 2024, a OpenAI disponibilizou o Whisper Large V3 Turbo, uma versão otimizada que reduz o número de camadas do decodificador de 32 para 4, mantendo desempenho próximo ao modelo completo com ganho de velocidade de aproximadamente 6 vezes (JEFFRIES et al., 2024; BEVILACQUA et al., 2024). Essa versão é adotada neste trabalho como módulo principal de ASR, por oferecer o melhor equilíbrio entre precisão e eficiência para o português brasileiro. Na literatura, outras alternativas relevantes incluem o Whispy (BEVILACQUA et al., 2024), que adapta o Whisper para cenários de fluxo contínuo (*streaming*), e modelos compactos como o Moonshine (JEFFRIES et al., 2024), voltados para execução em dispositivos embarcados.

Especificamente para o português brasileiro, modelos baseados na arquitetura Wav2Vec 2.0 (GROSMAN; NOGUEIRA, 2021), ajustados com dados nacionais, também têm demonstrado resultados relevantes na literatura, representando alternativas para lidar com as variações fonéticas e prosódicas do idioma.

Simultaneamente, os desenvolvimentos em NLP foram revolucionados pela arquitetura Transformer (VASWANI et al., 2017), que serve de base para os modernos LLMs (Modelos de Linguagem de Grande Porte, do inglês *Large Language Models*). No âmbito nacional, o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) consolidou o uso de Transformers especializados em português brasileiro para tarefas de compreensão textual, sendo adotado

neste trabalho como classificador principal de intenção. Mais recentemente, modelos como Albertina (RODRIGUES et al., 2023) e DeBERTinha (ABONIZIO et al., 2023) introduziram abordagens altamente eficientes em termos de parâmetros e representação semântica, sendo considerados como alternativas a serem exploradas caso o cronograma permita. Ademais, LLMs generativos como o Sabiá (PIRES et al., 2023) ampliaram as competências de geração textual para o idioma, sendo empregado neste trabalho para a geração sintética de enunciados direcionados ao dispositivo na construção do corpus de experimentos.

Torna-se necessário delimitar o papel específico de cada família de modelos no escopo deste projeto: o Whisper Large V3 Turbo atua como módulo principal de ASR para a conversão de fala em texto, enquanto Moonshine e Wav2Vec 2.0 são mencionados como referências da literatura. Os modelos de linguagem pré-treinados, com destaque para o BERTimbau como classificador principal e DeBERTinha e Albertina como alternativas, constituem o núcleo da decisão de DDS textual. Por fim, o Sabiá é empregado como ferramenta de geração sintética de dados para a construção do corpus. A Tabela 1 sintetiza essa distribuição de responsabilidades.

Tabela 1 – Mapeamento de tecnologias e seus papéis no trabalho

Tecnologia	Papel no trabalho	Será implementada?
Whisper Large V3 Turbo	ASR - geração de transcrição	Sim (principal)
Moonshine	ASR - referência bibliográfica	Não
Wav2Vec 2.0 PT-BR	ASR - referência bibliográfica	Não
BERTimbau	Classificador textual (principal)	Sim
DeBERTinha	Classificador textual (alternativo)	Opcional
Albertina	Classificador textual (alternativo)	Opcional
TF-IDF + SVM/LR	Baseline clássico	Sim
Sabiá	Geração sintética de dados DD	Sim

Fonte: Elaborado pelo autor (2026).

Pesquisas recentes em DDS têm investigado abordagens focadas no nível do texto para mitigar as limitações de sistemas puramente acústicos. Trabalhos recentes (WAGNER et al., 2024; DIGHE et al., 2024) demonstraram que aplicar classificadores baseados em Transformers sobre as hipóteses de transcrição geradas por sistemas de ASR configura-se como uma estratégia robusta para inferir o direcionamento do enunciado. Expandindo essa premissa, Rudovic et al. (2024) evidenciaram como a semântica textual permite decodificar intenções implícitas em fluxos de diálogo contínuo, corroborando a viabilidade técnica da modelagem puramente linguística do sinal de áudio transcrito.

1.3 Justificativa

A crescente presença de assistentes de voz em diferentes dispositivos computacionais evidencia a relevância de pesquisas voltadas à melhoria da Interação Humano-Computador (conhecida por HCI, do inglês *Human-Computer Interaction*). Apesar dos avanços significativos em ASR e NLP, a maioria dos sistemas atuais ainda depende de palavras de ativação explícitas, que podem comprometer a naturalidade e a fluidez da comunicação (MALLIDI et al., 2018). Em ambientes com interações dinâmicas e frequentes, a necessidade de invocar repetidamente o dispositivo pode gerar fadiga no usuário e prejudicar a experiência de uso (NIE et al., 2021). Diante disso, o desenvolvimento de sistemas de DDS apresenta-se como uma abordagem relevante para reduzir a dependência de palavras de ativação explícitas e promover interações mais fluidas e intuitivas (WAGNER et al., 2024).

Sob a perspectiva acadêmica, o estudo de métodos alternativos de ativação baseados em intenção implícita situa-se na convergência do processamento de áudio, NLP e HCI. Embora a literatura aponte que a fusão multimodal (acústica e textual) resulte em menores taxas de erro de ativação (WAGNER et al., 2024), a implementação de sistemas multimodais demanda alto poder computacional, processos complexos de sincronização temporal de sinais e grandes volumes de dados rotulados em ambas as modalidades, o que impõe barreiras severas para a implantação em dispositivos de borda ou com recursos computacionais restritos (XU et al., 2024).

Adicionalmente, identifica-se uma lacuna geográfica e linguística na literatura: os principais estudos sobre DDS concentram-se quase exclusivamente no idioma inglês, com forte dependência de características acústicas e prosódicas nativas daquela língua (NOROUZIAN et al., 2019; KRISHNA et al., 2023). O português brasileiro, apesar de ser um dos idiomas mais falados do mundo, apresenta-se sub-representado nesse campo de pesquisa, carecendo de estudos focados na decodificação de padrões de direcionamento de fala adaptados à sua realidade gramatical e cultural.

Embora o ecossistema nacional tenha presenciado o surgimento de recursos linguísticos robustos, como o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e corpora públicos de fala (ex.: CORAA ASR (JUNIOR et al., 2023), NURC-SP (LIMA et al., 2025), TAGARELA (OLIVEIRA et al., 2026)), tais bases destinam-se prioritariamente a tarefas de transcrição fonética e reconhecimento acústico tradicional. Verifica-se, portanto, uma escassez de corpora especificamente anotados com fins de detecção de direcionamento de voz (DD vs NDD) em português brasileiro, constituindo um gargalo para a pesquisa científica e o desenvolvimento de soluções práticas para DDS nesse idioma.

Nesse cenário, este trabalho busca contribuir para o preenchimento dessa lacuna ao investigar a viabilidade técnica de uma abordagem de DDS puramente textual, alimentada por hipóteses de transcrição geradas por sistemas de ASR e operacionalizada por meio de modelos baseados em Transformer pré-treinados para o português brasileiro. A escolha exclusiva pela modalidade textual fundamenta-se em três pilares metodológicos:

(i) a superioridade dos modelos baseados em atenção para capturar nuances semânticas e intenções implícitas em tarefas de classificação de enunciados curtos (WELD et al., 2022); (ii) as evidências empíricas de que o sinal linguístico presente em transcrições automáticas carrega alto poder discriminativo para diferenciar comandos de conversações casuais (WAGNER et al., 2024; DIGHE et al., 2024). e (iii) o ganho de modularidade e isolamento arquitetural, o que facilita a comparação rigorosa com *baselines* lineares e viabiliza a mensuração precisa do impacto de ruídos e erros de transcrição de áudio (DIGHE et al., 2024).

1.4 Hipótese de pesquisa

A hipótese central deste trabalho é a seguinte:

*Sob condições de ambiente controlado, modelos de linguagem pré-treinados para o português brasileiro, aplicados sobre transcrições geradas por sistemas de ASR, alcançam desempenho estatisticamente superior a *baselines* lineares tradicionais, constituídos pela representação TF-IDF combinada com SVM ou LR, avaliados sobre o mesmo corpus sob as métricas de F1-score, acurácia e EER, comprovando a viabilidade técnica da abordagem puramente textual para a tarefa de DDS em português brasileiro.*

Essa conjectura encontra sustentação nos fundamentos apresentados na Seção 2.3: a viabilidade da classificação puramente textual sobre hipóteses de ASR (WAGNER et al., 2024), a superioridade de arquiteturas Transformer em tarefas de classificação de intenção (WELD et al., 2022) e o desempenho comprovado de modelos especializados no português brasileiro, como o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e o DeBERTinha (ABONIZIO et al., 2023).

A validação dessa hipótese será realizada por meio de experimentos controlados no TCC2, utilizando um corpus anotado especificamente para a tarefa de DDS em português brasileiro, com protocolo de validação cruzada e comparação rigorosa entre o modelo baseado em Transformer e os *baselines* lineares definidos nos Objetivos Específicos.

1.5 Objetivos

1.5.1 Objetivo principal

O objetivo principal desta pesquisa consiste em avaliar a viabilidade técnica e o desempenho de modelos de linguagem pré-treinados para o português brasileiro aplicados à DDS, operando sob transcrições puramente textuais geradas por sistemas de ASR, de modo a verificar se essa abordagem supera estatisticamente os *baselines* lineares compostos por TF-IDF associado a SVM ou LR, nas métricas de F1-score, acurácia e EER.

1.5.2 Objetivos específicos

Para que o objetivo principal seja alcançado, foram definidos os seguintes objetivos específicos:

1. Construir e validar um corpus balanceado de sentenças em português brasileiro, anotadas com base no direcionamento de fala (DD e NDD) sob critérios explícitos de anotação e rigorosos de exclusão, a partir de adaptações de corpora públicos (CORAA ASR (JUNIOR et al., 2023), NURC-SP (LIMA et al., 2025) e TAGARELA (OLIVEIRA et al., 2026)) e enunciados sintetizados controlados gerados por LLMs.
2. Implementar, ajustar (fine-tuning) e avaliar o modelo BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) na tarefa de classificação binária de DDSD, confrontando empiricamente seus resultados com um *baseline* composto pela representação vetorial TF-IDF aliada a SVM ou LR, utilizando hipóteses de transcrição geradas por ASR (1-best e/ou n-best).
3. Analisar o impacto gerado por erros e ruídos de transcrição automática no classificador semântico de intenções, mapeando o desempenho comparativo entre transcrições manuais e automáticas e estabelecendo a correlação estatística entre a *Word Error Rate* (traduzida como Taxa de Erro de Palavras, referenciada pela sigla WER) das saídas do ASR e o decaimento de desempenho do classificador textual (DIGHE et al., 2024).

1.6 Limitações do trabalho

Esta proposta apresenta restrições de escopo e limitações do desenho experimental adotado, explicitadas a seguir para contextualizar os resultados.

A primeira limitação refere-se à exclusividade da modalidade de entrada. O modelo proposto analisa estritamente informações do domínio textual das transcrições, omitindo características prosódicas, acústicas ou paralinguísticas (entonação, velocidade e pausas) comprovadamente relevantes para a DDSD (NOROUZIAN et al., 2019; KRISHNA et al., 2023). Embora seja uma escolha deliberada para estabelecer uma base textual robusta antes do desenvolvimento multimodal, assume-se o risco de o sistema apresentar menor sensibilidade em cenários com ruídos acústicos acentuados ou variações expressivas de tom.

A segunda limitação reside no impacto dos erros de transcrição gerados pelo ASR. Como a entrada do classificador depende diretamente da transcrição gerada pelo Whisper, erros fonéticos ou omissões podem corromper as estruturas gramaticais e semânticas analisadas pelo Transformer, especialmente em falas com sotaque, ruído de fundo ou vocabulário incomum (BEVILACQUA et al., 2024). O impacto desses erros será analisado como

parte dos experimentos, mas representa uma fonte de variabilidade não completamente controlável. A comparação entre transcrições manuais e automáticas, prevista no terceiro objetivo específico, buscará quantificar essa degradação.

A terceira limitação está associada à construção, representatividade e escala do corpus experimental. Diante da ausência de bases especificamente anotadas para DDS em português brasileiro, torna-se necessária a construção de um corpus próprio em ambiente controlado, combinando dados reais fragmentados e geração sintética assistida por LLMs. Tal estratégia implica restrições em termos de escala, espontaneidade conversacional, diversidade sociolinguística regional e variabilidade dialetal. Consequentemente, o corpus resultante não contemplará toda a complexidade e variabilidade da fala espontânea em contextos reais (JUNIOR et al., 2023), o que pode limitar a capacidade de generalização dos resultados.


Por fim, esta pesquisa não contempla aspectos relacionados à infraestrutura de implantação em ambientes produtivos, como latência de ponta a ponta, processamento contínuo em fluxo no dispositivo (*on-device streaming*), armazenamento de sinais de áudio, segurança de dados e privacidade. O foco repousa exclusivamente na análise experimental e estatística da viabilidade da classificação textual em ambiente laboratorial controlado, delegando a estudos futuros os desafios regulatórios e arquiteturais de privacidade, processamento local e mecanismos de consentimento do usuário (CHEN et al., 2021).

2 Revisão Bibliográfica

Este capítulo estabelece o embasamento teórico e tecnológico da pesquisa proposta. Inicialmente, descreve-se a metodologia de seleção dos trabalhos consultados. O referencial teórico, na sequência, percorre os paradigmas de interação por voz, desde os mecanismos tradicionais de ativação baseados em *wake-words* até as abordagens emergentes de Detecção de Fala Direcionada ao Dispositivo (do inglês *Device-Directed Speech Detection*, referida pela sigla DDSD). Os fundamentos técnicos são então aprofundados, com ênfase na arquitetura Transformer, nos modelos de linguagem pré-treinados para o português brasileiro e nas métricas de avaliação. Por fim, analisam-se os trabalhos mais diretamente relacionados ao tema, identificando lacunas que esta pesquisa busca preencher.

2.1 Metodologia da pesquisa bibliográfica

Figura 3 – Fluxo de seleção de estudos para a revisão bibliográfica.



Fonte: Elaborado pelo autor (2026).

A pesquisa bibliográfica foi conduzida de forma estruturada com o objetivo de identificar trabalhos científicos relevantes sobre detecção de intenção em linguagem natural, assistentes

virtuais baseados em voz, DDS e técnicas de aprendizado de máquina aplicadas ao reconhecimento e classificação de comandos de voz.

Foram consultadas bases de dados acadêmicas amplamente utilizadas na área de Computação, incluindo Google Scholar, Semantic Scholar, arXiv, IEEE Xplore e ACM Digital Library. Essas plataformas foram selecionadas por concentrarem artigos científicos, pré-publicações e trabalhos revisados por pares com abrangência nas áreas de processamento de fala, linguagem natural e aprendizado de máquina.

As buscas utilizaram combinações de palavras-chave em inglês, tais como: “*voice assistant*”, “*device-directed speech detection*”, “*intent detection*”, “*keyword spotting*”, “*implicit intent*”, “*wake-word*”, “*false trigger mitigation*”, “*natural language understanding*” e “*voice command classification*”. Essas expressões foram combinadas por meio de operadores booleanos (AND, OR) para ampliar ou restringir os resultados conforme necessário.

Como critérios de inclusão, foram considerados: (a) trabalhos publicados entre 2021 e 2026; (b) disponibilidade nos idiomas inglês ou português; (c) relação direta com o problema de pesquisa, priorizando-se artigos que apresentassem experimentos, métodos de classificação ou avaliações de sistemas de interação por voz. Como exceção, foram incluídos artigos seminais anteriores ao período definido, por representarem contribuições fundamentais para a área, como os trabalhos sobre a arquitetura Transformer (VASWANI et al., 2017) e o BERT (DEVLIN et al., 2019).

Como critérios de exclusão, foram desconsiderados: (a) trabalhos publicados antes de 2021, exceto os seminais; (b) artigos sem relação direta com detecção de intenção, DDS ou classificação de comandos de voz; (c) trabalhos duplicados entre as bases consultadas.

O processo de seleção ocorreu em duas etapas, conforme ilustrado na Figura 3. Na triagem inicial, foram identificados 118 artigos potencialmente relevantes com base na leitura de título e resumo. Na etapa de afunilamento, a análise em maior profundidade resultou na seleção de 27 trabalhos para compor a fundamentação teórica, os trabalhos relacionados e as referências deste estudo. Adicionalmente, foram incluídos 7 artigos seminais anteriores a 2021, entre os quais se destacam os trabalhos sobre a arquitetura Transformer (VASWANI et al., 2017), o BERT (DEVLIN et al., 2019), o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e os primeiros estudos de DDS (MALLIDI et al., 2018; NOROUZIAN et al., 2019). Dessa forma, o conjunto final de referências selecionadas para este trabalho foi composto por 34 artigos.

2.2 Referencial teórico

O referencial teórico apresenta os conceitos fundamentais que sustentam o desenvolvimento deste trabalho, estabelecendo um contraponto entre o modelo predominante de interação com assistentes virtuais baseado em comandos explícitos (*wake-words*) e a busca por interações mais naturais e fluidas por meio da Detecção de Fala Direcionada ao

Dispositivo (DDSD). A organização dos tópicos segue o fluxo típico de processamento de um assistente virtual baseado em voz: desde a captura e identificação da fala destinada ao sistema, passando pela transcrição do áudio, até a compreensão semântica da intenção do usuário.

2.2.1 Assistentes virtuais e interação por voz

A evolução da Interação Humano-Computador (IHC) tem se distanciando progressivamente de interfaces puramente gráficas e táteis, avançando em direção a interfaces conversacionais e ubíquas. Nesse contexto, os assistentes virtuais baseados em voz consolidaram-se como agentes computacionais capazes de interpretar linguagem natural, processar requisições e executar tarefas automatizadas, atuando como intermediários entre o usuário e ecossistemas de serviços digitais ([Next Move Strategy Consulting, 2025](#)).

De acordo com [Jurafsky e Martin \(2024\)](#), assistentes virtuais são sistemas que integram tecnologias de ASR, Compreensão de Linguagem Natural (conhecida por NLU, do inglês *Natural Language Understanding*) e Síntese de Fala (do inglês *Text-to-Speech*, referida pela sigla TTS) para viabilizar interações fluidas entre humanos e dispositivos. O funcionamento típico desses sistemas segue um *pipeline* composto por etapas sequenciais: (i) captura do sinal de áudio; (ii) Detecção de Atividade de Voz (VAD, do inglês *Voice Activity Detection*); (iii) ASR; (iv) NLU; e (v) geração da resposta ou execução da ação solicitada.

Na maioria dos sistemas comerciais, as etapas de processamento são precedidas por um módulo de detecção de *wake-word*, que atua como gatilho para iniciar o processamento mais custoso ([GARG et al., 2021](#)). Essa arquitetura permite que o assistente permaneça em modo de baixo consumo até ser explicitamente invocado.

A relevância dessa tecnologia é corroborada pelo crescimento do mercado global de assistentes de voz, avaliado em US\$ 7,35 bilhões em 2024 e projetado para alcançar US\$ 33,74 bilhões até 2030, com taxa de crescimento anual composta (CAGR) de 26,5% ([Next Move Strategy Consulting, 2025](#)). Tal expansão reforça a importância de pesquisas voltadas à melhoria da naturalidade e fluidez da interação humano-computador.

No entanto, a eficácia dessa interação depende criticamente da capacidade do sistema de identificar quando sua intervenção é solicitada. Em ambientes cotidianos, onde a fala humana é simultaneamente direcionada a outras pessoas e a dispositivos, surge o desafio de distinguir intenções implícitas, tema central deste trabalho.

2.2.2 Detecção de Atividade de Voz (VAD)

A Detecção de Atividade de Voz (VAD) é a primeira etapa de processamento de sinal após a captura do áudio pelo microfone. Sua função principal é identificar os segmentos do sinal que contêm fala humana, separando-os de trechos de silêncio, ruído de fundo e sons não-verbais ([LI et al., 2021](#)).

Essa etapa é fundamental para a eficiência do sistema como um todo. Ao descartar trechos sem fala, o VAD reduz significativamente o volume de dados que precisa ser processado pelos módulos subsequentes (ASR e NLU), diminuindo o consumo computacional, a latência e o gasto energético, aspectos especialmente críticos em dispositivos embarcados e de borda.

Em ambientes controlados, a tarefa de VAD é relativamente simples, baseada principalmente em limiares de energia ou características acústicas tradicionais. Entretanto, em cenários reais (cozinhas, salas com televisão ligada, conversas paralelas), a robustez do VAD torna-se um desafio considerável. Modelos baseados em aprendizado profundo têm apresentado resultados superiores nesses contextos.

Li et al. (LI et al., 2021) propuseram um modelo de VAD baseado em Redes Neurais Convolucionais com Codificador Auditivo Mascarado (Masked Auditory Encoder CNN — M-AECNN), inspirado em características da audição humana. Seus experimentos demonstraram ganhos significativos de precisão em ambientes ruidosos quando comparado a métodos tradicionais baseados em energia ou estatísticas de sinal.

A qualidade da detecção realizada pelo VAD impacta diretamente todas as etapas posteriores do pipeline. Um VAD excessivamente permissivo gera muitas ativações desnecessárias, enquanto um VAD muito restritivo pode descartar falas relevantes do usuário. Portanto, o equilíbrio entre sensibilidade e especificidade é um ponto crítico no projeto de assistentes virtuais baseados em voz.

2.2.3 Reconhecimento Automático de Fala (ASR)

O Reconhecimento Automático de Fala (*Automatic Speech Recognition* — ASR) consiste no processo de conversão de um sinal de áudio contendo fala humana em texto legível por máquina (JURAFSKY; MARTIN, 2024). No contexto de assistentes virtuais, o ASR atua como um componente crítico, funcionando como ponte entre o processamento do sinal acústico (após o VAD) e os módulos de compreensão semântica (NLU).

Historicamente, os sistemas de ASR baseavam-se em abordagens híbridas que combinavam Modelos de Markov Ocultos (*Hidden Markov Models* — HMM) com Modelos de Linguagem estatísticos (JURAFSKY; MARTIN, 2024). Essas abordagens dominaram a área por décadas, mas apresentavam limitações importantes na modelagem de dependências temporais longas e no aproveitamento de grandes volumes de dados. A partir da década de 2010, o avanço do aprendizado profundo trouxe significativa evolução, inicialmente com redes recorrentes (RNN/LSTM) e convolucionais, e posteriormente com a arquitetura Transformer (VASWANI et al., 2017), que permitiu saltos expressivos de performance.

Um dos principais marcos da área foi o modelo Whisper, proposto por Radford et al. (RADFORD et al., 2023). Treinado com aproximadamente 680 mil horas de dados multilíngues sob supervisão fraca, o Whisper destacou-se pela alta robustez a ruídos,

variações de sotaque e diferentes condições acústicas. Em 2024, a OpenAI lançou o Whisper Large V3 e sua versão otimizada ****Whisper Large V3 Turbo****, que reduz drasticamente o número de camadas do decodificador (de 32 para 4), mantendo desempenho próximo ao modelo completo com ganho substancial de velocidade (cerca de 6x mais rápido) (JEFFRIES et al., 2024; BEVILACQUA et al., 2024). Essas versões tornaram o Whisper ainda mais viável para aplicações em tempo real e dispositivos com recursos limitados.

Paralelamente, têm surgido modelos otimizados para cenários específicos de baixa latência e execução em borda, como Moonshine (JEFFRIES et al., 2024) e Whispy (BEVILACQUA et al., 2024), projetados para processamento contínuo (*streaming*). No contexto do português brasileiro, modelos baseados em arquiteturas auto-supervisionadas, como o Wav2Vec 2.0 (GROSMAN; NOGUEIRA, 2021), também apresentam resultados promissores.

A qualidade dos sistemas de ASR é comumente mensurada pela métrica *Word Error Rate* (traduzido como Taxa de Erro de Palavras, conhecido pela sigla WER), que calcula a taxa de palavras erradas, substituídas, deletadas ou inseridas em relação a uma transcrição de referência. Em aplicações de assistentes virtuais, a redução do WER é fundamental, pois erros de transcrição propagam-se diretamente para as etapas de classificação de intenção e extração de entidades.

Neste trabalho, o módulo de ASR será utilizado primordialmente como etapa de pré-processamento. As transcrições geradas (principalmente pelo Whisper) servirão de entrada para o classificador textual de intenção implícita, tornando a qualidade e a robustez do ASR um fator relevante para o desempenho final do sistema proposto.

2.2.4 Wake-words: mecanismo, vantagens e limitações

As *wake-words* (também denominadas hotwords ou palavras de ativação) constituem o mecanismo predominante de ativação em assistentes virtuais comerciais. Trata-se de expressões específicas pré-definidas — tais como “Hey Siri”, “Alexa”, “Ok Google” e “Hey Bixby” — que funcionam como gatilho para despertar o sistema do estado de espera e iniciar o processamento completo da solicitação do usuário (GARG et al., 2021).

Do ponto de vista técnico, a detecção de wake-words é realizada por um módulo especializado de *keyword spotting* que opera continuamente no dispositivo com consumo energético extremamente reduzido. Esse módulo permanece ativo mesmo quando os componentes mais custosos do pipeline (ASR e NLU) estão inativos, ativando-os somente após a detecção positiva da palavra de ativação (GARG et al., 2021; KUNDU et al., 2023).

Essa abordagem oferece importantes vantagens. Do ponto de vista energético, é altamente eficiente, sendo essencial para dispositivos alimentados por bateria, como smartphones, relógios inteligentes e alto-falantes portáteis (SHIN, 2023). Adicionalmente, contribui para a preservação da privacidade do usuário, uma vez que o processamento mais complexo — frequentemente realizado na nuvem — só é iniciado após a ativação explícita (NIE et

al., 2021). Por fim, minimiza o processamento desnecessário de áudio ambiente, reduzindo tanto o consumo de recursos quanto o risco de captação contínua de conversas.

No entanto, o mecanismo de wake-words apresenta limitações significativas. Do ponto de vista da Interação Humano-Computador, impõe um padrão rígido e artificial de comunicação, obrigando o usuário a utilizar uma fórmula específica para se dirigir ao assistente, o que contrasta com a naturalidade do diálogo humano (NIE et al., 2021). Essa rigidez gera fricção cognitiva e compromete a fluidez da experiência do usuário.

Uma vulnerabilidade técnica relevante é o fenômeno conhecido como *Fake Wake*, no qual palavras ou expressões foneticamente semelhantes à wake-word ativam inadvertidamente o sistema. Chen et al. (CHEN et al., 2021) realizaram um estudo sistemático sobre esse problema e desenvolveram um gerador automático de *fuzzy words*, conseguindo produzir 965 expressões capazes de acionar indevidamente oito dos principais assistentes de voz do mercado. Tal fragilidade compromete tanto a usabilidade quanto a privacidade do usuário, pois ativações falsas podem resultar no envio não intencional de áudio para servidores remotos.

Para mitigar os falsos gatilhos, foram propostas técnicas de *False Trigger Mitigation* (FTM). Garg et al. (2021) apresentaram uma arquitetura unificada baseada em Transformer com processamento em fluxo contínuo (*streaming*), capaz de suprimir até 95% dos falsos positivos utilizando apenas um segundo de áudio contextual após a ativação. Apesar dos avanços, essas soluções ainda adicionam complexidade ao sistema e não eliminam completamente a necessidade de uma ativação explícita inicial.

Diante dessas limitações técnicas, de usabilidade e de privacidade, a comunidade científica tem intensificado o desenvolvimento de alternativas mais naturais, como a Detecção de Fala Direcionada ao Dispositivo (DDSD).

2.2.5 Detecção de Fala Direcionada ao Dispositivo (DDSD)

A Detecção de Fala Direcionada ao Dispositivo (*Device-Directed Speech Detection* — DDSD) é definida como a tarefa de classificação binária que visa determinar automaticamente se uma *utterance* proferida pelo usuário é intencionalmente direcionada a um assistente virtual ou se faz parte de uma conversa incidental entre humanos ou ruído de fundo (MALLIDI et al., 2018; WAGNER et al., 2024).

Diferentemente do mecanismo tradicional de wake-words, que exige uma ativação explícita, a DDSD busca permitir interações mais naturais e fluidas, aproximando a comunicação humano-computador do padrão conversacional humano. Essa abordagem representa um dos principais caminhos para superar as limitações de rigidez e fricção cognitiva impostas pelas palavras de ativação (NIE et al., 2021).

Por convenção, neste trabalho a sigla DDSD será sempre apresentada, na primeira ocorrência de cada capítulo, com o termo em português seguido do termo em inglês em itálico.

As pesquisas na área de DDS têm evoluído principalmente em duas frentes: abordagens multimodais e abordagens unimodais (baseadas em áudio ou texto). As soluções multimodais combinam informações acústicas, textuais, prosódicas e, em alguns casos, visuais (detecção facial e rastreamento labial). Wagner et al. (WAGNER et al., 2024) demonstraram que a fusão de características acústicas, hipóteses do decodificador ASR e representações textuais processadas por Modelos de Linguagem de Grande Porte (do inglês *Large Language Models*, referidos como LLMs) pode reduzir a taxa de erro em até 61% em comparação com modelos unimodais. Da mesma forma, Krishna et al. (KRISHNA et al., 2023) exploraram a combinação de características verbais com informações prosódicas não verbais (entonação, ritmo e pausas), obtendo melhorias significativas na taxa de falsa aceitação.

Em outra linha, Nie et al. (NIE et al., 2021) propuseram um sistema multimodal que integra informações visuais (detecção facial e rastreamento de lábios) com características acústicas, sendo particularmente útil em robôs de diálogo e dispositivos equipados com câmeras.

Embora as abordagens multimodais apresentem melhor desempenho em cenários complexos, elas demandam maior poder computacional, sincronização precisa entre modalidades e grandes volumes de dados anotados multimodalmente, o que limita sua viabilidade em dispositivos com recursos restritos (WAGNER et al., 2024).

Nesse contexto, abordagens baseadas exclusivamente em texto — que utilizam transcrições geradas por sistemas de ASR como entrada — têm ganhado crescente atenção na literatura. Essas soluções oferecem maior simplicidade arquitetural, modularidade, interpretabilidade e facilidade de implementação, especialmente em idiomas com poucos recursos, como o português brasileiro. Além disso, estudos recentes têm demonstrado que as representações textuais extraídas de hipóteses ASR contêm um sinal discriminativo forte o suficiente para a detecção de intenção implícita, tornando a abordagem textual uma alternativa promissora e prática (DIGHE et al., 2024; RUDOVIC et al., 2024).

A DDS representa, portanto, uma evolução natural na interação humano-computador por voz. Este trabalho se posiciona dentro dessa linha de pesquisa ao investigar uma abordagem puramente textual para DDS no português brasileiro, buscando contribuir com uma solução mais acessível e adaptada à realidade linguística nacional.

2.2.6 Processamento de Linguagem Natural e classificação de intenção

O Processamento de Linguagem Natural (NLP) compreende o conjunto de técnicas computacionais destinadas à análise, compreensão e geração de linguagem humana em formato textual (JURAFSKY; MARTIN, 2024). No contexto de assistentes virtuais, a subárea de Compreensão de Linguagem Natural (NLU) é responsável por extrair o significado semântico, a intenção do usuário e as entidades mencionadas a partir das transcrições geradas pelo módulo de ASR (WELD et al., 2022).

Uma das tarefas centrais da NLU é a *classificação de intenção* (*intent classification*). Dado um enunciado do usuário, o objetivo é identificar qual é a intenção subjacente expressa nesse texto, ou seja, qual ação o usuário deseja que o sistema realize (WELD et al., 2022). Essa tarefa é frequentemente combinada com o preenchimento de *slots* (*slot filling*), responsável por extrair os parâmetros necessários para a execução da ação pretendida (ex.: “Defina um alarme para as 8 horas” → intenção: “criar alarme”; slot: horário = “8 horas”).

Historicamente, os sistemas de classificação de intenção baseavam-se em regras manuais e padrões lexicais. Com o tempo, métodos estatísticos tradicionais, como modelos de sequência e Máquinas de Vetores de Suporte (conhecidas por SVM, do inglês *Support Vector Machines*), tornaram-se predominantes (MANNING; RAGHAVAN; SCHÜTZE, 2008). No entanto, foi a partir da introdução da arquitetura Transformer (VASWANI et al., 2017) e, especialmente, do modelo BERT (DEVLIN et al., 2019) que a área experimentou um avanço expressivo. (WELD et al., 2022), em um abrangente levantamento da literatura, concluem que os modelos pré-treinados baseados em Transformers superam consistentemente abordagens anteriores em tarefas de detecção de intenção e preenchimento de slots, tanto em precisão quanto em generalização.

A principal vantagem dos modelos pré-treinados reside na capacidade de realizar *fine-tuning* com quantidades relativamente pequenas de dados rotulados específicos para a tarefa (DEVLIN et al., 2019). Essa característica torna tais modelos particularmente atrativos para idiomas com poucos recursos linguísticos, como o português brasileiro.

No escopo deste trabalho, a classificação de intenção assume papel central, uma vez que constitui o núcleo da abordagem textual proposta para a Detecção de Fala Direcionada ao Dispositivo (DDSD). Ao utilizar as transcrições geradas pelo ASR como entrada, o sistema busca identificar se o enunciado carrega uma intenção direcionada ao dispositivo, mesmo na ausência de wake-words explícitas, explorando o poder representacional dos modelos de linguagem pré-treinados para capturar pistas semânticas e contextuais presentes no texto.

2.2.7 Modelos baseados em Transformers

A arquitetura Transformer, proposta por Vaswani et al. (2017), representou um dos principais marcos na história do Processamento de Linguagem Natural. Diferentemente das redes neurais recorrentes (RNNs) e convolucionais dominantes até então, o Transformer introduziu o mecanismo de *atenção multi-cabeça* (*multi-head attention*) como principal componente para modelar dependências entre elementos de uma sequência. Essa arquitetura permite o processamento paralelo de toda a sequência de entrada, resultando em maior eficiência computacional durante o treinamento e melhor capacidade de capturar dependências de longo alcance (VASWANI et al., 2017).

A partir dessa arquitetura, Devlin et al. (2019) propuseram o modelo BERT (*Bidirectional Encoder Representations from Transformers*). O BERT realiza um pré-treinamento

bidirecional por meio de duas tarefas principais: *Masked Language Modeling* (MLM), que consiste em prever tokens aleatoriamente mascarados dentro de uma sentença, e *Next Sentence Prediction* (NSP), que treina o modelo a identificar se duas sentenças são consecutivas. Após essa fase de pré-treinamento em grandes corpora não anotados, o modelo pode ser adaptado (*fine-tuning*) para diversas tarefas específicas de NLP, adicionando uma camada de classificação sobre a representação do token especial [CLS] (DEVLIN et al., 2019).

A capacidade de transferência de conhecimento dos modelos pré-treinados permitiu avanços significativos em diversas tarefas, incluindo classificação de texto, reconhecimento de entidades nomeadas, análise de sentimento e, especialmente, classificação de intenção. Diversos estudos demonstram que modelos baseados em Transformers superam consistentemente abordagens tradicionais quando ajustados para domínios específicos (WELD et al., 2022).

No contexto do português brasileiro, Souza, Nogueira e Lotufo (2020) desenvolveram o BERTimbau, uma versão do BERT pré-treinada especificamente para o idioma. O modelo foi treinado em um corpus de aproximadamente 2,7 bilhões de tokens extraídos da Wikipédia em português e do corpus brWaC. Os autores demonstraram que o BERTimbau supera os modelos multilíngues em várias tarefas de NLP para o português, incluindo classificação textual, reconhecimento de entidades e similaridade semântica.

Posteriormente, outros modelos baseados em Transformers foram adaptados para o português, como a família Albertina (RODRIGUES et al., 2023) e a DeBERTinha (ABONIZIO et al., 2023), buscando maior eficiência computacional e desempenho em tarefas específicas do idioma. Esses avanços têm sido fundamentais para viabilizar aplicações de NLP em português com qualidade comparável à obtida em inglês.

No presente trabalho, os modelos baseados em Transformers, especialmente o BERTimbau, são utilizados como base para o classificador textual de intenção implícita na tarefa de DDS, explorando sua capacidade de capturar nuances semânticas e contextuais presentes nas transcrições geradas pelo ASR.

2.3 Fundamentos

Esta seção detalha as tecnologias, algoritmos e metodologias específicas que serão empregados no desenvolvimento da solução proposta. Diferentemente do referencial teórico, que apresenta conceitos gerais, os fundamentos aprofundam os aspectos técnicos diretamente utilizados na implementação.

2.3.1 Arquitetura Transformer

A arquitetura Transformer, introduzida por Vaswani et al. (2017), revolucionou o Processamento de Linguagem Natural ao eliminar a dependência de recorrência e convoluções,

substituindo-as pelo mecanismo de atenção como principal componente para modelagem de sequências. Diferentemente das Redes Neurais Recorrentes (RNNs) e Long Short-Term Memory (LSTM), que processam sequências de forma sequencial, o Transformer processa todos os elementos da sequência de entrada simultaneamente, permitindo alto grau de paralelização e melhor captura de dependências de longo alcance (VASWANI et al., 2017).

O componente central da arquitetura é o mecanismo de *Self-Attention*. Para cada token da sequência, o modelo calcula três vetores: *Query* (Q), *Key* (K) e *Value* (V). A atenção é calculada pela seguinte fórmula:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

onde d_k é a dimensão dos vetores de chave. Essa operação permite que cada token “preste atenção” em todos os outros tokens da sequência, ponderando sua importância relativa. O fator de escala $\sqrt{d_k}$ é utilizado para estabilizar os gradientes durante o treinamento.

Para aumentar a capacidade representacional do modelo, Vaswani et al. (2017) propuseram o *Multi-Head Attention*, que executa o mecanismo de atenção em paralelo h vezes (geralmente 8 ou 16 cabeças), cada uma com projeções lineares diferentes de Q, K e V. As saídas das cabeças são concatenadas e projetadas linearmente, permitindo que o modelo capture diferentes tipos de relações semânticas e sintáticas na mesma camada.

Outro componente essencial é o *Positional Encoding*. Como o Transformer não possui recorrência, é necessário injetar informação sobre a posição dos tokens na sequência. Os autores utilizaram funções seno e cosseno de diferentes frequências:

$$PE_{(pos, 2i)} = \sin \left(\frac{pos}{10000^{2i/d_{model}}} \right), \quad PE_{(pos, 2i+1)} = \cos \left(\frac{pos}{10000^{2i/d_{model}}} \right)$$

Esses valores são somados aos embeddings dos tokens de entrada, fornecendo ao modelo informação explícita sobre a ordem dos elementos.

A arquitetura completa é composta por blocos de *Encoder* e *Decoder*. Cada bloco do Encoder contém uma camada de Multi-Head Self-Attention seguida de uma rede feed-forward posicionada (duas camadas lineares com ativação ReLU). O Decoder possui uma camada adicional de Multi-Head Attention que recebe as saídas do Encoder (Cross-Attention). Conexões residuais (*residual connections*) e normalização de camada (*layer normalization*) são aplicadas em torno de cada subcamada para facilitar o treinamento de redes profundas.

Exemplo prático: na frase “O gato está no tapete”, o token “tapete” deve ter forte atenção com “gato” para entender a relação semântica. Enquanto uma RNN processaria a frase palavra por palavra (esquecendo informações iniciais em sequências longas), o Transformer consegue relacionar “tapete” diretamente com “gato” em uma única passada, independentemente da distância entre eles.

A arquitetura Transformer serviu de base para diversos modelos de grande sucesso, como BERT (apenas Encoder), GPT (apenas Decoder) e T5 (Encoder-Decoder). Sua

escalabilidade permitiu o treinamento de modelos com centenas de bilhões de parâmetros, consolidando-se como o fundamento dos modernos Large Language Models.

No contexto deste trabalho, a arquitetura Transformer é fundamental, pois tanto o BERTimbau quanto outros modelos utilizados no classificador de intenção implícita são construídos sobre ela.

2.3.2 BERT e o mecanismo de fine-tuning

O modelo BERT (*Bidirectional Encoder Representations from Transformers*), proposto por Devlin et al. (DEVLIN et al., 2019), foi um dos principais avanços no Processamento de Linguagem Natural ao introduzir o conceito de pré-treinamento bidirecional profundo. Diferentemente dos modelos anteriores que processavam o texto de forma unidirecional (da esquerda para a direita ou vice-versa), o BERT é capaz de considerar o contexto completo de uma palavra, analisando tanto os tokens à esquerda quanto à direita simultaneamente.

O BERT é treinado em duas tarefas de pré-treinamento não supervisionadas em grandes corpora de texto:

1. **Masked Language Modeling (MLM)**: Durante o treinamento, 15% dos tokens da entrada são aleatoriamente mascarados. O modelo deve prever qual era o token original com base apenas no contexto bidirecional. Por exemplo, na frase “O [MASK] está no tapete”, o modelo aprende a prever “gato” considerando tanto o contexto anterior quanto o posterior.
2. **Next Sentence Prediction (NSP)**: O modelo recebe pares de sentenças e deve aprender a identificar se a segunda sentença é a continuação lógica da primeira. Essa tarefa permite que o BERT desenvolva compreensão de relações discursivas e coerência textual.

Após o pré-treinamento em grandes volumes de dados não anotados, o BERT pode ser adaptado para tarefas específicas por meio do processo chamado *fine-tuning*. Nesse estágio, o modelo é inicializado com os pesos aprendidos durante o pré-treinamento e continua o treinamento em um conjunto de dados menor e rotulado para uma tarefa específica (classificação de texto, reconhecimento de entidades, resposta a perguntas, etc.). Apenas uma camada de classificação adicional é adicionada sobre a representação do token especial [CLS], que concentra informações de toda a sequência (DEVLIN et al., 2019).

Uma das grandes vantagens do BERT é que o *fine-tuning* requer relativamente poucos dados rotulados e poucas épocas de treinamento quando comparado ao treinamento do zero. Devlin et al. (DEVLIN et al., 2019) demonstraram que, com o fine-tuning, o BERT conseguiu superar o estado da arte em 11 tarefas de NLP diferentes, incluindo GLUE, SQuAD e SWAG.

No contexto de classificação de intenção, o processo de fine-tuning é relativamente simples: a última camada do modelo é substituída por uma camada linear com softmax (para classificação binária ou multiclasse), e o modelo é treinado minimizando a perda de entropia cruzada. Durante esse processo, os pesos das camadas anteriores também são atualizados, permitindo que o modelo ajuste suas representações internas para melhor capturar as nuances da tarefa específica.

No presente trabalho, o mecanismo de fine-tuning é fundamental, pois será aplicado sobre o BERTimbau para especializá-lo na tarefa de Detecção de Fala Direcionada ao Dispositivo (DDSD) em português brasileiro, utilizando transcrições geradas por ASR como entrada.

2.3.3 BERTimbau: BERT para o português brasileiro

O BERTimbau, proposto por [Souza, Nogueira e Lotufo \(2020\)](#), é a versão do modelo BERT pré-treinada especificamente para o português brasileiro. Seu desenvolvimento surgiu da constatação de que modelos multilíngues, apesar de apresentarem bom desempenho geral, possuem limitações importantes quando aplicados a idiomas com características morfosintáticas e vocabulário específicos, como o português do Brasil.

O modelo foi pré-treinado em um corpus de aproximadamente 2,7 bilhões de tokens, composto principalmente por textos da Wikipédia em português e pelo corpus brWaC (Brazilian Web as Corpus), que contém páginas da web coletadas e processadas com alto padrão de qualidade linguística. Foram disponibilizadas duas versões: BERTimbau Base (12 camadas, 110 milhões de parâmetros) e BERTimbau Large (24 camadas, 335 milhões de parâmetros) ([SOUZA; NOGUEIRA; LOTUFO, 2020](#)).

Durante o pré-treinamento, o BERTimbau seguiu a mesma metodologia do BERT original: as tarefas de *Masked Language Modeling* (MLM) e *Next Sentence Prediction* (NSP). No entanto, por ter sido treinado exclusivamente com dados em português brasileiro, o modelo desenvolveu representações linguísticas mais adequadas às particularidades do idioma, tais como o uso abundante de pronomes pessoais, conjugações verbais complexas, artigos definidos e contrações comuns (ex.: “do”, “na”, “pelo”).

[Souza, Nogueira e Lotufo \(2020\)](#) realizaram uma avaliação abrangente comparando o BERTimbau com o BERT multilíngue (mBERT) em diversas tarefas de NLP para o português. Os resultados demonstraram superioridade consistente do BERTimbau, especialmente em tarefas como Reconhecimento de Entidades Nomeadas (NER), Análise de Similaridade Semântica e Classificação Textual. Em alguns casos, a diferença de desempenho chegou a mais de 5 pontos percentuais em relação ao modelo multilíngue.

Exemplo prático: na frase “O presidente viajou para Brasília ontem”, o BERTimbau consegue melhor diferenciar o uso contextual de palavras como “viajou” (sentido literal de deslocamento) e capturar corretamente relações sintáticas específicas do português

brasileiro, como o uso do pronome “o” como objeto direto, algo que modelos multilíngues frequentemente apresentam maior dificuldade.

A disponibilidade do BERTimbau foi um marco importante para o desenvolvimento de aplicações de NLP em português, pois reduziu significativamente a barreira de entrada para pesquisadores e desenvolvedores que antes dependiam de modelos multilíngues com desempenho subótimo ou de modelos treinados do zero, o que exige grande volume de dados e alto custo computacional.

No âmbito deste trabalho, o BERTimbau é utilizado como modelo base para o classificador de intenção implícita. Por meio do processo de *fine-tuning*, o modelo é adaptado para a tarefa de Detecção de Fala Direcionada ao Dispositivo (DDSD), utilizando transcrições geradas por sistemas de ASR como entrada, buscando explorar suas representações linguísticas otimizadas para o português brasileiro.

2.3.4 DeBERTa, DeBERTinha e Albertina PT-BR

Embora o BERT tenha estabelecido um novo patamar para modelos de linguagem, arquiteturas subsequentes buscaram superar suas limitações, especialmente quanto à representação de dependências sintáticas e à eficiência computacional. Entre elas, destaca-se a família DeBERTa (*Decoding-enhanced BERT with Disentangled Attention*), proposta por He et al. (2021).

A principal inovação do DeBERTa é o mecanismo de *Disentangled Attention* (atenção desentrelada). Enquanto o BERT representa cada token por um único vetor que contém simultaneamente informação de conteúdo e de posição, o DeBERTa separa esses dois tipos de informação. Para cada par de tokens, o modelo calcula a atenção considerando tanto o conteúdo quanto a posição relativa de forma independente. Essa separação permite uma modelagem mais precisa de relações sintáticas e semânticas. Além disso, o DeBERTa utiliza um mecanismo de decodificação aprimorado (*enhanced mask decoder*) durante o pré-treinamento, o que contribui para representações mais ricas (He et al., 2021).

No contexto brasileiro, Abonizio et al. (2023) desenvolveram a **DeBERTinha**, uma versão compacta e adaptada do DeBERTaV3 (XSmall) para o português brasileiro. O modelo foi submetido a um processo de adaptação contínua (continual pre-training) utilizando grandes corpora em português, incluindo o brWaC e outros conjuntos de textos nacionais. Apesar de possuir apenas cerca de 70 milhões de parâmetros, a DeBERTinha demonstrou desempenho competitivo ou superior ao BERTimbau Large em várias tarefas de NLP para o português, com significativa vantagem em eficiência computacional.

Outra iniciativa relevante é a família **Albertina PT-BR**, desenvolvida por Rodrigues et al. (2023). Diferentemente da DeBERTinha, que se baseia no DeBERTa, a Albertina é construída sobre a arquitetura DeBERTaV3 e foi pré-treinada do zero em português, com diferentes tamanhos de modelo (Albertina 1.5B, 3B e 7B). Os autores enfatizaram a qualidade dos dados de pré-treinamento e técnicas avançadas de tokenização, resultando

em modelos que alcançam estado da arte em diversas tarefas de entendimento de linguagem em português.

Exemplo prático: na sentença “O banco ficou cheio depois da chuva”, o modelo precisa resolver a ambiguidade da palavra “banco” (instituição financeira × assento). Modelos como DeBERTinha e Albertina, por possuírem mecanismos de atenção mais sofisticados e terem sido treinados em corpora brasileiros ricos em contexto, tendem a resolver essa ambiguidade com maior precisão ao considerar melhor o contexto global da frase.

Tanto a DeBERTinha quanto a Albertina representam avanços importantes para o ecossistema de NLP em português brasileiro, oferecendo alternativas mais eficientes e especializadas em relação aos modelos multilíngues ou ao BERTimbau. Essas iniciativas reduzem a dependência de modelos estrangeiros e contribuem para a soberania tecnológica no processamento de linguagem natural da nossa língua.

No presente trabalho, tais modelos são considerados como alternativas ao BERTimbau para o classificador de intenção implícita, especialmente em cenários onde eficiência computacional e desempenho em português brasileiro são fatores críticos.

2.3.5 Modelos baseline: TF-IDF, SVM e Regressão Logística

Na área de classificação textual, é prática comum utilizar modelos mais simples e interpretáveis como baselines para comparar o desempenho de abordagens baseadas em deep learning. Neste trabalho, foram selecionados três componentes clássicos: o TF-IDF para representação vetorial de texto, combinado com Support Vector Machines (SVM) e Regressão Logística como classificadores.

A Frequência do Termo - Inverso da Frequência nos Documentos (do inglês *Term Frequency-Inverse Document Frequency*, referenciado por TF-IDF) é uma das técnicas mais tradicionais e eficazes de representação vetorial de documentos (MANNING; RAGHAVAN; SCHÜTZE, 2008). Ele atribui pesos às palavras considerando duas dimensões: a frequência do termo no documento (*Term Frequency* — TF) e a raridade do termo em toda a coleção de documentos (*Inverse Document Frequency* — IDF). A fórmula completa é dada por:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{\text{DF}(t) + 1} \right)$$

onde t é o termo, d é o documento, N é o número total de documentos e $\text{DF}(t)$ é o número de documentos que contêm o termo t . Essa ponderação reduz o peso de termos muito comuns (como artigos e preposições) e aumenta o peso de termos mais discriminativos. No contexto deste trabalho, o TF-IDF será aplicado sobre as transcrições geradas pelo ASR para criar vetores esparsos de alta dimensionalidade.

Como classificadores, foram escolhidos as Máquinas de Vetores de Suporte (SVM) e a Regressão Logística. O SVM, proposto por Cortes e Vapnik (CORTES; VAPNIK, 1995), busca encontrar o hiperplano que maximiza a margem de separação entre as classes.

Em problemas não linearmente separáveis, utiliza o truque do kernel (*kernel trick*) para mapear os dados para um espaço de maior dimensionalidade onde a separação linear se torna possível. No caso de classificação binária de intenção (dirigida $\times$ não dirigida), o SVM tenta maximizar a distância entre os vetores TF-IDF das duas classes.

A Regressão Logística, por sua vez, é um modelo estatístico que modela a probabilidade de uma classe binária por meio da função sigmoide:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

Apesar de ser um modelo linear, a Regressão Logística frequentemente apresenta bom desempenho em tarefas de classificação textual quando combinada com representações TF-IDF, especialmente em conjuntos de dados de tamanho moderado (MANNING; RAGHAVAN; SCHÜTZE, 2008).

Ambos os classificadores (SVM e Regressão Logística) são amplamente utilizados como baselines em pesquisas de NLP por serem eficientes computacionalmente, altamente interpretáveis e servirem como referência sólida para avaliar o ganho real obtido por modelos mais complexos, como os baseados em Transformers. Estudos demonstram que, embora modelos neurais profundos geralmente superem esses baselines em grandes conjuntos de dados, a diferença de desempenho pode ser menor em corpora de tamanho moderado ou quando o problema possui forte componente semântico (WELD et al., 2022).

No presente trabalho, os modelos TF-IDF combinados com SVM e Regressão Logística serão implementados como baselines para comparação com o classificador baseado no BERTimbau na tarefa de Detecção de Fala Direcionada ao Dispositivo (DDSD). Essa comparação permitirá avaliar o ganho real de performance obtido pela abordagem baseada em modelos pré-treinados em relação a métodos tradicionais de classificação textual.

2.3.6 ASR com Whisper

O Whisper é um modelo de Reconhecimento Automático de Fala de grande escala desenvolvido pela OpenAI e apresentado por Radford et al. (2023). Diferentemente da maioria dos sistemas ASR tradicionais, que são treinados com supervisão forte em conjuntos de dados relativamente pequenos e limpos, o Whisper foi treinado com uma abordagem de **supervisão fraca** em um corpus massivo de aproximadamente 680 mil horas de áudio multilíngue, coletado da web. Essa estratégia permitiu que o modelo aprendesse diretamente de dados brutos e ruidosos, resultando em alta robustez e generalização.

Arquiteturalmente, o Whisper segue o padrão Encoder-Decoder baseado em Transformer. O encoder processa o espectrograma log-Mel do áudio de entrada, gerando representações contextuais ricas. O decoder, por sua vez, é um Transformer autoregressivo que gera o texto transcrito token a token, podendo também realizar tarefas adicionais como tradução de fala, identificação de idioma e detecção de voz. Uma característica importante

é o uso de prompts especiais no decoder, que permitem ao modelo alternar entre diferentes tarefas (transcrição, tradução, legendas, etc.) sem necessidade de modificar a arquitetura (RADFORD et al., 2023).

Em 2024, a OpenAI lançou versões aprimoradas, com destaque para o **Whisper Large V3** e o **Whisper Large V3 Turbo**. A versão Turbo reduz significativamente o número de camadas do decoder (de 32 para apenas 4 camadas), mantendo a maior parte do desempenho do modelo completo, com ganho de velocidade de inferência de aproximadamente 6 vezes, tornando-o mais viável para aplicações em tempo real e dispositivos com recursos limitados (JEFFRIES et al., 2024; BEVILACQUA et al., 2024).

Entre as principais vantagens do Whisper destacam-se:

- Excelente desempenho em português brasileiro, mesmo em fala espontânea e com diferentes sotaques regionais;
- Alta robustez a ruídos ambientais, música de fundo e sobreposição de vozes;
- Capacidade nativa de identificar automaticamente o idioma falado;
- Suporte a transcrição com timestamps e detecção de múltiplos falantes (em versões mais recentes).

Como exemplo prático, ao processar a frase “Vou ligar o ar-condicionado porque está muito quente aqui”, o Whisper consegue transcrever corretamente mesmo com ruído de fundo ou sotaque regional, preservando contrações típicas do português brasileiro (“tá” em vez de “está”), o que facilita o trabalho posterior do classificador de intenção.

No escopo deste trabalho, o Whisper será utilizado exclusivamente como módulo de pré-processamento. As transcrições geradas por ele servirão de entrada para o classificador textual de intenção implícita. Essa escolha se justifica pela robustez do modelo em português e pela disponibilidade de versões otimizadas para diferentes cenários de latência e precisão. Experimentos no TCC2 incluirão a comparação entre diferentes tamanhos de modelo (Medium, Large V3 e Turbo) e a análise da relação entre a taxa de erro de palavras (Word Error Rate — WER) do ASR e o desempenho final do classificador de DDSD.

Embora o Whisper represente o estado da arte atual em ASR multilíngue, erros de transcrição ainda podem ocorrer, especialmente em ambientes muito ruidosos ou com vocabulário técnico. Por isso, a avaliação do impacto desses erros sobre a tarefa de detecção de intenção implícita constitui um dos objetivos específicos deste trabalho.

2.3.7 Métricas de avaliação

A avaliação de modelos de classificação, especialmente em tarefas de Detecção de Fala Direcionada ao Dispositivo (DDSD), requer métricas que permitam analisar não apenas a acurácia geral, mas também o equilíbrio entre erros de falso positivo e falso negativo.

Neste trabalho, serão utilizadas métricas tradicionais de classificação binária e métricas específicas da área de DDS.

A **Acurácia** (*Accuracy*) mede a proporção de classificações corretas em relação ao total de amostras. Embora seja intuitiva, pode ser enganosa em conjuntos de dados desbalanceados, situação comum em tarefas de DDS, onde as falas não direcionadas ao dispositivo geralmente são mais frequentes (MANNING; RAGHAVAN; SCHÜTZE, 2008).

A **Precisão** (*Precision*) indica a proporção de exemplos classificados como positivos que são realmente positivos. No contexto deste trabalho, representa a proporção de falas classificadas como direcionadas ao dispositivo que realmente o eram. É especialmente importante quando o custo de falsos positivos é alto (ativações indesejadas) (WELD et al., 2022).

A **Sensibilidade** (*Recall*) mede a proporção de exemplos positivos que foram corretamente identificados. Neste caso, indica quantas das falas realmente direcionadas ao dispositivo foram detectadas pelo modelo. Um recall baixo implica que muitas intenções do usuário estão sendo perdidas (WELD et al., 2022).

A métrica **F1-Score** representa a média harmônica entre Precisão e Sensibilidade, sendo particularmente útil quando se busca um equilíbrio entre as duas. Sua fórmula é dada por:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

No cenário de DDS, o F1-Score é uma das métricas principais, pois reflete bem o trade-off entre ativações corretas e ativações indevidas.

Uma métrica de grande relevância na literatura de detecção de fala direcionada é a **Taxa de Erro Igual** (do inglês *Equal Error Rate*, referida pela sigla EER). Ela corresponde ao ponto na curva ROC onde a taxa de falsos positivos (False Positive Rate) é igual à taxa de falsos negativos (False Negative Rate). Quanto menor o EER, melhor o desempenho do sistema. Wagner et al. (2024) e Krishna et al. (2023) utilizam o EER como métrica principal em seus trabalhos, por ser uma medida robusta e independente do threshold de decisão.

Além dessas, será calculada a **Área sob a Curva ROC (ROC-AUC)**, que avalia a capacidade do modelo de distinguir entre as classes em diferentes thresholds. Quanto mais próxima de 1, melhor o poder discriminativo do classificador.

Por fim, como o sistema proposto utiliza transcrições geradas por ASR, será analisado o impacto da qualidade da transcrição por meio da métrica **Word Error Rate (WER)**. O WER mede a taxa de erro entre a transcrição gerada e o texto de referência, considerando substituições, inserções e deleções de palavras. Estudos demonstram que existe correlação direta entre o WER do ASR e a degradação do desempenho do classificador textual (DIGHE et al., 2024).

A combinação dessas métricas permite uma avaliação multidimensional do sistema: acurácia geral, equilíbrio entre precisão e recall, robustez a variações de threshold (EER) e sensibilidade à qualidade da transcrição (WER). Todas as métricas serão calculadas utilizando validação cruzada e conjuntos de teste separados, garantindo maior confiabilidade dos resultados.

2.4 Trabalhos relacionados

A identificação e análise de trabalhos relacionados é uma etapa fundamental no processo de pesquisa científica, pois permite situar a proposta no contexto do conhecimento existente, evidenciar lacunas ainda não exploradas e justificar as escolhas metodológicas adotadas (WAZLAWICK, 2020). Nesta seção, são apresentados e discutidos os principais estudos relacionados à Detecção de Fala Direcionada ao Dispositivo (DDSD), selecionados a partir da metodologia descrita na Seção 2.1.

Os trabalhos foram selecionados segundo dois critérios centrais: (i) abordagem direta do problema de DDSD ou de tarefa funcionalmente equivalente — isto é, a classificação automática de enunciados de voz como dirigidos ou não a um sistema computacional — e (ii) uso de componente textual ou acústico relevante para a tarefa de classificação de intenção. Trabalhos que tratam apenas de ASR, VAD, *keyword spotting* clássico ou classificação de intenção em domínios distintos do de assistentes de voz foram excluídos, pois não compartilham o problema central investigado neste TCC (WAZLAWICK, 2020).

Com base nesses critérios, três trabalhos foram selecionados como relacionados principais. O primeiro, de Mallidi et al. (2018), estabelece as bases conceituais e experimentais da DDSD e representa o trabalho fundacional da área. O segundo, de Wagner et al. (2024), corresponde ao estado da arte em abordagens multimodais para DDSD, combinando características acústicas com representações textuais processadas por *Large Language Models* (LLMs). O terceiro, de Dighe et al. (2024), é o trabalho metodologicamente mais próximo da proposta deste TCC, por demonstrar que modelos de linguagem aplicados sobre saídas textuais de ASR são capazes de gerar sinal discriminativo suficiente para a tarefa de detecção de intenção. A análise crítica desses três estudos, conduzida nas subseções seguintes, permite identificar com precisão as lacunas que este trabalho busca preencher.

2.4.1 *Device-directed Utterance Detection*

O trabalho de Mallidi et al. (2018), intitulado *Device-directed Utterance Detection*, é considerado o estudo pioneiro e fundacional na área de Detecção de Fala Direcionada ao Dispositivo. Publicado nos anais do *Interspeech* em 2018, o estudo foi o primeiro a formalizar o problema de DDSD como uma tarefa independente de classificação binária, estabelecendo a terminologia, o protocolo experimental e as métricas de avaliação que

seriam adotados por estudos posteriores na área (MALLIDI et al., 2018; WAGNER et al., 2024).

O problema abordado pelos autores parte de uma constatação prática: em ambientes domésticos com assistentes virtuais sempre ligados, uma parcela significativa das falas captadas pelo microfone não é dirigida ao dispositivo, mas sim a outras pessoas presentes no ambiente ou constitui comentários incidentais do próprio usuário. Ativar o pipeline completo de processamento de voz — que inclui ASR, NLU e geração de resposta — para cada trecho de fala detectado pelo VAD resultaria em altíssimo consumo computacional, degradação da privacidade e experiência do usuário comprometida (MALLIDI et al., 2018). A proposta dos autores foi, portanto, inserir um módulo intermediário entre o VAD e o ASR, capaz de filtrar automaticamente as falas não dirigidas ao dispositivo antes que o processamento custoso fosse iniciado.

Do ponto de vista técnico, a abordagem proposta por Mallidi et al. (2018) é inteiramente baseada em características acústicas extraídas diretamente do sinal de áudio, sem depender de transcrições textuais. Os autores utilizaram um conjunto de *features* tradicionais de reconhecimento de fala, incluindo coeficientes cepstrais de frequência de Mel (MFCCs), *pitch*, energia e características prosódicas como duração de pausas e velocidade de fala. Essas *features* foram utilizadas como entrada para um modelo de classificação baseado em Redes Neurais *Feed-Forward*, treinado de forma supervisionada para distinguir enunciados dirigidos ao dispositivo de conversas incidentais entre humanos.

Os experimentos foram conduzidos em um corpus interno, coletado em cenários reais de uso doméstico em inglês, contendo tanto comandos explicitamente dirigidos ao assistente quanto conversas paralelas. Os autores reportaram uma *Equal Error Rate* (EER) de aproximadamente 12% em condições controladas, resultado considerado promissor para a época. Um achado relevante do estudo foi a constatação de que características prosódicas — em especial a entonação e a duração de pausas — exercem papel discriminativo importante para separar comandos intencionais de comentários incidentais, uma vez que esses elementos carregam informações sobre a intencionalidade que vão além do conteúdo lexical (MALLIDI et al., 2018).

Além da proposta técnica, Mallidi et al. (2018) ofereceram uma contribuição conceitual relevante ao argumentar que a dependência de *wake-words* impõe uma sobrecarga cognitiva artificial ao usuário, que precisa lembrar e pronunciar corretamente uma expressão específica a cada vez que deseja interagir com o assistente. Esse argumento fundamentou a necessidade de sistemas capazes de detectar intenção implícita sem gatilhos verbais explícitos, tornando-se referência recorrente na justificativa de trabalhos posteriores na área (NIE et al., 2021; WAGNER et al., 2024).

Apesar de seu inegável pioneirismo, o trabalho apresenta limitações significativas à luz do estado da arte atual. A abordagem puramente acústica não explora informações textuais ou semânticas das transcrições, o que restringe sua capacidade discriminativa em cenários

onde a distinção entre comando e comentário incidental depende predominantemente do conteúdo linguístico do enunciado. Considere, por exemplo, os enunciados “acende a luz” e “nossa, está escuro aqui”: do ponto de vista acústico, ambos podem apresentar padrões prosódicos semelhantes — curta duração, entonação descendente, ausência de pausas — enquanto do ponto de vista semântico são claramente distintos. Um modelo que não analisa o conteúdo textual tende a apresentar dificuldade justamente nesses casos ambíguos, que são os mais frequentes e relevantes em cenários de uso real (WAGNER et al., 2024; DIGHE et al., 2024). Adicionalmente, os experimentos foram realizados exclusivamente em inglês e com um corpus proprietário não disponibilizado publicamente, o que impede a reprodutibilidade dos resultados e a adaptação direta para outros idiomas, especialmente o português brasileiro.

Para o presente trabalho, a contribuição de Mallidi et al. (2018) é insubstituível do ponto de vista conceitual: a formalização do problema de DDSD como classificação binária, a definição das classes (dirigida ao dispositivo *versus* conversa incidental) e o uso do EER como métrica principal são elementos diretamente adotados neste TCC. No entanto, a abordagem técnica segue uma direção oposta: enquanto Mallidi et al. (2018) operam no domínio acústico, este trabalho opera exclusivamente no domínio textual, explorando a semântica dos enunciados por meio de modelos de linguagem pré-treinados para o português brasileiro.

2.4.2 A Multimodal Approach to Device-Directed Speech Detection with Large Language Models

O trabalho de Wagner et al. (2024), publicado no IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) em 2024, representa o estado da arte em Detecção de Fala Direcionada ao Dispositivo até o momento da elaboração deste TCC. O estudo propõe uma arquitetura multimodal que integra três fontes de informação complementares para maximizar o desempenho na tarefa de DDSD: características acústicas do sinal de áudio, hipóteses intermediárias geradas pelo decodificador do sistema de ASR e representações semânticas produzidas por *Large Language Models* (LLMs).

A motivação central de Wagner et al. (2024) parte de uma crítica às abordagens unimodais então predominantes na literatura: sistemas baseados exclusivamente em áudio capturam bem informações prosódicas e paralinguísticas, mas carecem de compreensão semântica; sistemas baseados exclusivamente em texto capturam a semântica, mas ignoram pistas acústicas como entonação e ritmo, que são altamente informativas para distinguir comandos de comentários. A fusão de múltiplas modalidades permitiria, portanto, explorar o sinal discriminativo presente em cada domínio de forma complementar (WAGNER et al., 2024).

Arquiteturalmente, o sistema proposto adota uma estratégia de fusão tardia (*late*

fusion): cada modalidade é processada por um *encoder* especializado de forma independente, e as representações resultantes são combinadas em um módulo de fusão para a classificação final. O componente acústico utiliza *features* extraídas diretamente do sinal de áudio, processadas por uma rede neural especializada. O componente textual principal utiliza representações geradas por um LLM a partir da transcrição 1-best produzida pelo ASR. Um terceiro componente, de particular interesse técnico, explora as hipóteses intermediárias geradas pelo processo de *beam search* do decodificador ASR — não apenas a transcrição mais provável, mas o conjunto de hipóteses alternativas com seus respectivos escores de confiança (WAGNER et al., 2024). Essa informação, denominada *n-best list*, carrega a incerteza do modelo ASR de forma explícita e mostrou-se altamente informativa para o classificador de intenção.

Os resultados reportados por Wagner et al. (2024) são expressivos: o modelo multimodal alcançou uma redução de até 61% na *Equal Error Rate* (EER) em comparação com as melhores abordagens unimodais, demonstrando o valor da integração de modalidades para a tarefa de DDS. Os experimentos foram conduzidos em um corpus interno de grande escala, contendo interações reais em ambientes domésticos em inglês. Os autores demonstraram ainda que o componente textual, isoladamente, já contribui de forma significativa para o desempenho do sistema — evidência direta de que informações semânticas extraídas de transcrições de ASR constituem um sinal discriminativo relevante para a tarefa (WAGNER et al., 2024).

Embora os resultados sejam notáveis, o trabalho apresenta limitações práticas importantes. A arquitetura multimodal proposta exige alto poder computacional, tanto no treinamento quanto na inferência, além de sincronização precisa entre os componentes de cada modalidade. O uso de LLMs de grande escala como componente central impõe restrições adicionais de latência e custo operacional, dificultando a implantação em dispositivos com recursos computacionais limitados (XU et al., 2024). Além disso, a abordagem foi desenvolvida e avaliada exclusivamente em inglês, com um corpus proprietário não disponibilizado publicamente, o que impede sua adaptação direta para o português brasileiro e limita a comparação objetiva com estudos futuros (WAGNER et al., 2024).

Para o presente trabalho, o estudo de Wagner et al. (2024) cumpre dois papéis fundamentais. Primeiro, fornece a evidência empírica mais robusta disponível na literatura de que representações textuais extraídas de hipóteses ASR contêm sinal discriminativo suficiente para a tarefa de DDS — evidência que fundamenta diretamente a hipótese de pesquisa deste TCC. Segundo, estabelece o referencial de EER com o qual abordagens futuras, incluindo a proposta neste trabalho, poderão ser comparadas em caráter aproximado, respeitando as diferenças de idioma, corpus e modalidade. A abordagem puramente textual proposta neste TCC pode ser entendida, nesse sentido, como a investigação isolada do componente que Wagner et al. (2024) identificaram como altamente discriminativo, aplicada ao português brasileiro com um modelo de linguagem especificamente adaptado

ao idioma.

2.4.3 *Leveraging Large Language Models for Exploiting ASR Uncertainty*

O trabalho de [Dighe et al. \(2024\)](#), também publicado no IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) em 2024, é o estudo metodologicamente mais próximo da proposta deste TCC. O artigo investiga o uso de *Large Language Models* para explorar a incerteza inerente às saídas dos sistemas de ASR em tarefas de *Spoken Language Understanding* (SLU), com ênfase na detecção de intenção — o que o torna diretamente relevante para o problema de DDSI investigado neste trabalho.

A premissa central de [Dighe et al. \(2024\)](#) é que pipelines tradicionais de SLU tratam a saída do ASR como determinística: utilizam apenas a transcrição mais provável (1-best) como entrada para os módulos semânticos subsequentes. Essa abordagem descarta informações potencialmente valiosas geradas durante o processo de decodificação, em particular as hipóteses alternativas produzidas pelo *beam search*, que carregam a incerteza do reconhecedor de forma explícita. Os autores argumentam que LLMs são especialmente adequados para explorar essa incerteza, uma vez que possuem a capacidade de raciocinar sobre múltiplas hipóteses textuais e selecionar a interpretação semanticamente mais plausível em função do contexto ([DIGHE et al., 2024](#)).

A metodologia proposta consiste em fornecer ao LLM não apenas a transcrição 1-best, mas um conjunto de hipóteses ASR (*n-best list*) ordenadas por probabilidade, ou alternativamente representações latentes do decodificador. O LLM processa essas hipóteses e produz uma representação semântica que leva em conta a incerteza do ASR ao classificar a intenção do enunciado. Os experimentos demonstram que essa abordagem gera ganhos consistentes em métricas de entendimento de intenção quando comparada a pipelines que utilizam apenas a transcrição 1-best, confirmando que a informação de incerteza do ASR é semanticamente relevante para a tarefa de classificação de intenção ([DIGHE et al., 2024](#)).

Uma contribuição técnica relevante do trabalho é demonstrar que modelos de linguagem pré-treinados são capazes de atuar como um segundo estágio de refinamento semântico após o ASR, compensando parcialmente erros de transcrição ao considerar a plausibilidade das hipóteses alternativas. Essa capacidade é particularmente importante em cenários com ruído ambiental ou sotaque regional, onde a transcrição 1-best pode conter erros que comprometem a classificação de intenção ([DIGHE et al., 2024](#)). Os autores sugerem ainda, como direção para trabalhos futuros, a análise sistemática da correlação entre a Taxa de Erro de Palavras (WER) do ASR e a degradação do desempenho do classificador de intenção — investigação que este TCC incorpora explicitamente como um de seus objetivos específicos.

Do ponto de vista técnico, o estudo valida a viabilidade de arquiteturas em cascata (ASR $\rightarrow$ LLM) para tarefas de compreensão de intenção em fala, nas quais a saída textual do reconhecedor é processada por modelos de linguagem sem necessidade de acesso

ao sinal acústico bruto. Embora os experimentos de [Dighe et al. \(2024\)](#) tenham sido conduzidos em inglês, a metodologia proposta é, em princípio, transferível para outros idiomas mediante o uso de modelos de linguagem pré-treinados no idioma-alvo — o que constitui precisamente a contribuição central deste TCC, ao aplicar uma arquitetura análoga utilizando o BERTimbau ([SOUZA; NOGUEIRA; LOTUFO, 2020](#)) como classificador para o português brasileiro.

Vale observar, contudo, que [Dighe et al. \(2024\)](#) utilizam LLMs de grande escala como componente central, o que implica custo computacional elevado e dependência de infraestrutura de nuvem para inferência em tempo real. Este trabalho se diferencia ao propor o uso do BERTimbau — um modelo de menor escala, especificamente pré-treinado para o português brasileiro e viável para execução local — como classificador de intenção, tornando a abordagem mais acessível e adequada a cenários com recursos computacionais restritos ([SOUZA; NOGUEIRA; LOTUFO, 2020](#); [XU et al., 2024](#)).

Para o presente TCC, o trabalho de [Dighe et al. \(2024\)](#) cumpre um papel duplo e insubstituível. Primeiro, valida empiricamente que abordagens baseadas exclusivamente em texto extraído de ASR são suficientes para gerar sinal discriminativo relevante na tarefa de detecção de intenção implícita, fortalecendo a escolha metodológica deste trabalho de operar exclusivamente no nível textual. Segundo, motiva e fundamenta o terceiro objetivo específico deste TCC: a análise da correlação entre o WER do ASR e a degradação do desempenho do classificador textual no contexto do português brasileiro, explorando uma lacuna deixada em aberto pelos próprios autores.

2.4.4 Síntese comparativa

A análise individual dos três trabalhos relacionados permite, em conjunto, delinear com precisão o estado da arte em DDS e identificar as lacunas que este TCC busca preencher. Para facilitar essa análise, as Tabelas 2 e 3 sintetizam, respectivamente, as características técnicas dos trabalhos relacionados entre si e o diferencial introduzido pela proposta deste trabalho.

A Tabela 2 revela que, apesar das diferenças de abordagem e complexidade entre os três estudos, há um padrão comum a todos eles: foram desenvolvidos exclusivamente para o inglês, com corpora proprietários de grande escala não disponibilizados publicamente, e nenhum deles adota *baselines* clássicos como referência de comparação. A ausência de *baselines* tradicionais é uma limitação metodológica relevante, pois impede a quantificação do ganho real obtido pelos modelos neurais propostos em relação a métodos mais simples e interpretáveis ([MANNING; RAGHAVAN; SCHÜTZE, 2008](#); [WELD et al., 2022](#)).

Do ponto de vista da evolução das abordagens, observa-se uma trajetória clara ao longo do período coberto pelos três estudos: de métodos puramente acústicos ([MALLIDI et al., 2018](#)), passando por arquiteturas multimodais de alta complexidade ([WAGNER et al.,](#)

Tabela 2 – Comparação técnica entre os trabalhos relacionados

Critério	Mallidi (2018)	Wagner (2024)	Dighe (2024)
Modalidade	Áudio	Áudio + Texto + ASR	Texto + ASR
Modelo principal	RNN <i>Feed-Forward</i>	LLM + fusão tardia	LLM (<i>n-best</i>)
Idioma	Inglês	Inglês	Inglês
Corpus	Interno	Interno	Interno
Métricas reportadas	EER	EER	F1, Acurácia
Baseline clássico	Não	Não	Não
Limitação central	Sem análise textual	Alto custo computacional	Apenas inglês

Fonte: Elaborado pelo autor (2026).

2024), até soluções em cascata que centralizam o processamento no componente textual do ASR (DIGHE et al., 2024). Essa trajetória indica que a semântica textual tem ganhado protagonismo crescente na tarefa de DDS, o que fundamenta a escolha metodológica deste trabalho de adotar uma abordagem exclusivamente textual, apoiada em modelos de linguagem pré-treinados para o português brasileiro.

Tabela 3 – Diferencial deste TCC em relação aos trabalhos relacionados

Trabalho	Idioma	Modalidade	Corpus público	Baseline	Análise WER
Mallidi (2018)	Inglês	Áudio	Não	Não	Não
Wagner (2024)	Inglês	Multimodal	Não	Não	Não
Dighe (2024)	Inglês	Texto + ASR	Não	Não	Parcial
Este TCC	PT-BR	Texto puro	Sim	Sim	Sim

Fonte: Elaborado pelo autor (2026).

A Tabela 3 posiciona este TCC como uma contribuição original em pelo menos quatro dimensões distintas, detalhadas a seguir.

O primeiro e mais imediato diferencial é o **idioma**. Nenhum dos trabalhos relacionados aborda o português brasileiro, que permanece sub-representado na literatura de DDS apesar de ser um dos idiomas mais falados do mundo (JUNIOR et al., 2023). O português brasileiro apresenta características morfosintáticas específicas — como o uso abundante de pronomes clíticos, contrações e variação dialetal regional — que podem influenciar diretamente o desempenho de classificadores de intenção treinados ou avaliados nesse idioma. A ausência de estudos de DDS em português não é meramente uma lacuna acadêmica, mas uma barreira prática para o desenvolvimento de assistentes de voz mais naturais e acessíveis para a população brasileira.

O segundo diferencial planejado é a **construção e disponibilização pública de um corpus textual em português brasileiro** especificamente para a tarefa de DDS. Os três trabalhos relacionados utilizam corpora internos e proprietários, o que impede a reprodutibilidade e dificulta comparações metodológicas entre estudos (WAZLAWICK, 2020). O corpus a ser produzido neste trabalho, com volume estimado em aproximadamente 105.000 amostras textuais, combinará transcrições extraídas de corpora públicos de fala espontânea (JUNIOR et al., 2023; LIMA et al., 2025; OLIVEIRA et al., 2026) com enunciados sintéticos gerados por LLMs (MØLLER; AIELLO; AUGENSTEIN, 2024), e será documentado com protocolo de validação explícito, critérios de divisão estratificada entre treino, validação e teste, e disponibilizado publicamente, contribuindo para a infraestrutura de recursos linguísticos para DDS em português brasileiro.

O terceiro diferencial é a inclusão de **baselines clássicos** — TF-IDF combinado com SVM e Regressão Logística (MANNING; RAGHAVAN; SCHÜTZE, 2008) — como referência de comparação explícita. Essa escolha, ausente nos três trabalhos relacionados, permite quantificar objetivamente o ganho de desempenho obtido pela abordagem baseada em BERTimbau em relação a métodos tradicionais amplamente conhecidos, tornando os resultados mais interpretáveis e a análise mais rigorosa do ponto de vista científico (WELD et al., 2022).

O quarto diferencial é a **análise sistemática do impacto dos erros de transcrição (WER) sobre o desempenho do classificador de intenção**. Embora Dighe et al. (2024) tratem parcialmente dessa questão ao explorar hipóteses alternativas do ASR, nenhum dos trabalhos relacionados propõe uma avaliação direta e quantitativa da correlação entre WER e degradação do classificador textual no contexto de português brasileiro. Essa análise é particularmente relevante dado que o português apresenta desafios específicos para sistemas de ASR, como a alta variabilidade fonética regional e a presença de reduções vocálicas características da fala informal (JUNIOR et al., 2023; BEVILACQUA et al., 2024).

Em conjunto, esses quatro diferenciais evidenciam que o presente trabalho não é uma replicação dos estudos anteriores em outro idioma, mas uma contribuição com dimensões próprias e complementares ao estado da arte em DDS. O objetivo não é superar os resultados de abordagens multimodais complexas como a de Wagner et al. (2024) — o que seria improvável dado o escopo e os recursos disponíveis — mas estabelecer um *baseline* textual sólido, reprodutível e documentado para o português brasileiro, que sirva de ponto de partida para investigações futuras na área (WAZLAWICK, 2020; DIGHE et al., 2024).

3 Desenvolvimento

Este capítulo apresenta a proposta de desenvolvimento deste trabalho, detalhando a arquitetura do sistema, as decisões metodológicas, o planejamento experimental e o cronograma de execução previstos para o TCC2. Em consonância com a natureza de uma proposta de pesquisa, conforme orientado por [Wazlawick \(2020\)](#), o foco está na especificação precisa do que será implementado e avaliado, justificando cada escolha com base na literatura revisada no Capítulo 2.

3.1 Visão geral da solução proposta

A solução proposta consiste em um sistema de Detecção de Fala Direcionada ao Dispositivo (do inglês *Device-Directed Speech Detection*, referida pela sigla DDSD) para o português brasileiro, operando exclusivamente sobre o nível textual. O sistema recebe como entrada um segmento de fala capturado em ambiente controlado, processa esse sinal por meio de um módulo de *Automatic Speech Recognition* (traduzido como Reconhecimento Automático de Fala, referenciado pela sigla ASR) e classifica automaticamente o enunciado resultante como dirigido ao dispositivo ou como conversa incidental, por meio de um classificador textual baseado em modelos de linguagem pré-treinados ([DIGHE et al., 2024](#); [WAGNER et al., 2024](#)).

A abordagem adotada é deliberadamente modular: o módulo ASR e o módulo de classificação são componentes independentes, com interfaces bem definidas entre si. Essa modularidade facilita a substituição de qualquer componente sem alterações no restante do sistema, permitindo a comparação entre diferentes modelos ASR e diferentes classificadores de forma controlada ([WAZLAWICK, 2020](#)).

3.1.1 Arquitetura do pipeline

O *pipeline* completo do sistema é composto por quatro etapas sequenciais, ilustradas na Figura 4:

1. **Captura de áudio:** o sinal de fala é capturado em ambiente controlado e segmentado em enunciados individuais por meio de um módulo de Detecção de Atividade de Voz (conhecida por VAD, do inglês *Voice Activity Detection*), que delimita os trechos de fala relevantes ([LI et al., 2021](#));
2. **Transcrição ASR:** o enunciado segmentado é processado pelo modelo Whisper ([RADFORD et al., 2023](#)), que gera as N hipóteses textuais mais prováveis (*n-best*

- list*) via *beam search*. Essas hipóteses são ordenadas por probabilidade e fornecidas como entrada ao módulo de classificação;
3. **Classificação de intenção:** o conjunto de hipóteses textuais é processado pelo classificador binário, que produz uma pontuação de probabilidade para cada classe (dirigida ao dispositivo *versus* conversa incidental);
 4. **Decisão:** com base na pontuação produzida pelo classificador, o sistema emite uma decisão binária, que pode acionar ou não o pipeline completo do assistente virtual.

Figura 4 – Arquitetura do pipeline proposto

Áudio	→	VAD	→	ASR (Whisper)	→	Classificador	→	Decisão
Sinal bruto		Segmento		<i>n-best</i> textual		BERTimbau		Dirigido?

Fonte: Elaborado pelo autor (2026).

É importante ressaltar que o sistema opera exclusivamente sobre texto: o classificador não tem acesso ao sinal de áudio bruto nem às representações acústicas internas do Whisper. As hipóteses geradas pelo *beam search* são tratadas como sequências de texto comuns, sem aproveitamento de probabilidades acústicas ou escores de confiança do decodificador. Essa escolha define a modalidade do sistema como **textual pura**, distinguindo-o das abordagens de [Wagner et al. \(2024\)](#) e [Dighe et al. \(2024\)](#), que acessam representações internas do ASR ou sinais acústicos complementares.

3.1.2 Definição de ambiente controlado

Para os fins deste trabalho, um **ambiente controlado** é definido como um cenário de coleta e avaliação com as seguintes características:

- **Ruído ambiental reduzido:** as gravações são realizadas em ambientes com baixo nível de ruído de fundo, sem sobreposição de múltiplos falantes simultâneos e sem música ou televisão ligada durante a captura;
- **Proximidade ao microfone:** os enunciados são produzidos a distância padronizada do dispositivo de captura, garantindo qualidade acústica consistente entre as amostras;
- **Variedade linguística controlada:** os enunciados cobrem as três classes definidas no cenário motivador (Seção 1.1): comandos diretos ao dispositivo, comentários incidentais e casos ambíguos, sem restrição de sotaque ou variação regional do português brasileiro;

- **Ausência de wake-word:** nenhum enunciado do corpus utiliza palavras de ativação explícitas, garantindo que o classificador opere exclusivamente sobre o conteúdo linguístico.

A escolha por ambiente controlado é uma limitação estratégica do escopo deste TCC, conforme discutido na Seção 1.6. Cenários com ruído elevado, múltiplos falantes ou condições acústicas adversas representam extensões naturais para trabalhos futuros (JUNIOR et al., 2023).

3.2 Módulo ASR: transcrição e geração do *n-best*

3.2.1 Escolha e configuração do Whisper

O módulo ASR será implementado com o modelo Whisper, desenvolvido pela OpenAI e descrito por Radford et al. (2023). A escolha do Whisper justifica-se por três razões principais: (i) desempenho competitivo em português brasileiro mesmo sem adaptação específica ao idioma, evidenciado por sua arquitetura treinada em 680 mil horas de dados multilíngues sob supervisão fraca (RADFORD et al., 2023); (ii) disponibilidade de múltiplos tamanhos de modelo, permitindo comparações entre precisão e custo computacional; e (iii) suporte nativo a *beam search* com geração de múltiplas hipóteses, essencial para a estratégia de *n-best* adotada neste trabalho.

Serão avaliadas três variantes do Whisper, selecionadas para cobrir diferentes pontos do *trade-off* entre precisão e eficiência computacional, conforme descrito na Tabela 4.

Tabela 4 – Variantes do Whisper avaliadas no módulo ASR

Modelo	Parâmetros	Camadas decoder	Uso previsto
Whisper Medium	307M	24	Referência intermediária
Whisper Large V3	1,5B	32	Maior precisão
Whisper Large V3 Turbo	~809M	4	Maior velocidade

Fonte: Elaborado pelo autor com base em Radford et al. (2023), Jeffries et al. (2024), Bevilacqua et al. (2024).

O modelo Whisper Large V3 Turbo merece destaque especial: ao reduzir o número de camadas do decodificador de 32 para apenas 4, mantém desempenho próximo ao modelo completo com ganho de velocidade de aproximadamente 6 vezes (JEFFRIES et al., 2024; BEVILACQUA et al., 2024), tornando-o particularmente adequado para cenários com restrições de latência. A comparação entre as três variantes permitirá analisar a relação entre a WER (Taxa de Erro de Palavras, do inglês *Word Error Rate*) de cada modelo e o desempenho final do classificador de intenção, conforme previsto no terceiro objetivo específico (Seção 1.5).

3.2.2 Estratégia de uso do *n-best*

Em vez de utilizar apenas a transcrição mais provável gerada pelo ASR (denominada 1-best), este trabalho adotará a estratégia de *n-best*, na qual as N hipóteses textuais mais prováveis geradas pelo *beam search* do Whisper são fornecidas como entrada ao classificador. Essa estratégia é motivada por evidências recentes na literatura: Dighe et al. (2024) demonstraram que hipóteses alternativas do ASR contêm informações complementares à transcrição 1-best e contribuem para melhorar o entendimento semântico da fala, especialmente em casos onde a transcrição mais provável apresenta erros.

É fundamental, contudo, esclarecer a natureza dessa estratégia no contexto deste trabalho. As N hipóteses geradas pelo Whisper são tratadas exclusivamente como sequências de texto: o classificador recebe apenas as transcrições em formato textual, sem acesso a probabilidades acústicas, escores de confiança do decodificador ou quaisquer representações internas do modelo ASR. O sistema opera, portanto, em modalidade **textual pura**, conforme detalhado na Seção 3.1.1.

A representação das hipóteses como entrada para o classificador será implementada por concatenação simples das N transcrições, separadas por um token especial de separação compatível com a arquitetura do BERTimbau (DEVLIN et al., 2019; SOUZA; NOGUEIRA; LOTUFO, 2020). O valor de N será definido empiricamente durante os experimentos do TCC2, com valores iniciais de $N \in \{1, 3, 5\}$, permitindo avaliar o impacto do número de hipóteses no desempenho do classificador.

3.2.3 Impacto esperado dos erros de transcrição (WER)

A qualidade das transcrições geradas pelo ASR é um fator crítico para o desempenho do classificador textual. Erros de transcrição, mensurados pela Taxa de Erro de Palavras (WER), podem corromper palavras semanticamente relevantes e degradar a capacidade discriminativa do modelo de linguagem (DIGHE et al., 2024). Por exemplo, o enunciado “acende a luz da sala” transcrito erroneamente como “acendes a luz da sela” pode confundir o classificador, especialmente em casos limítrofes.

Para quantificar esse impacto, este trabalho realizará o experimento *upper-bound* detalhado na Seção 3.5.2: o classificador será avaliado tanto sobre transcrições manuais (sem erros de ASR) quanto sobre transcrições automáticas (com erros reais do Whisper), permitindo medir a degradação de desempenho atribuível exclusivamente ao módulo ASR. Espera-se que a estratégia de *n-best* contribua para reduzir parcialmente essa degradação ao oferecer hipóteses alternativas que podem conter a palavra correta em casos de erro na transcrição 1-best (DIGHE et al., 2024).

3.3 Módulo de classificação de intenção

3.3.1 Modelo principal: BERTimbau com *fine-tuning*

O classificador principal será implementado com base no BERTimbau, modelo BERT pré-treinado especificamente para o português brasileiro por Souza, Nogueira e Lotufo (2020). A escolha do BERTimbau como modelo principal justifica-se por três fatores: (i) superioridade consistente sobre modelos multilíngues em tarefas de classificação textual em português, demonstrada por Souza, Nogueira e Lotufo (2020) em múltiplos benchmarks; (ii) capacidade de *fine-tuning* eficiente com quantidades moderadas de dados rotulados, característica crítica dado o tamanho limitado do corpus de DDS em português brasileiro; e (iii) ampla adoção na literatura de NLP (Processamento de Linguagem Natural, do inglês *Natural Language Processing*) em português, facilitando a reprodutibilidade e a comparação com estudos futuros (SOUZA; NOGUEIRA; LOTUFO, 2020; WELD et al., 2022).

O processo de *fine-tuning* seguirá a metodologia padrão descrita por Devlin et al. (2019): uma camada de classificação linear com ativação *softmax* será adicionada sobre a representação do token especial [CLS], e o modelo completo será treinado de forma supervisionada para minimizar a perda de entropia cruzada binária. Os hiperparâmetros iniciais adotados para o *fine-tuning* estão descritos na Tabela 5.

Tabela 5 – Hiperparâmetros iniciais para o *fine-tuning* do BERTimbau

Hiperparâmetro	Valor inicial	Justificativa
Taxa de aprendizado	2×10^{-5}	Padrão BERT (DEVLIN et al., 2019)
Tamanho do batch	16 ou 32	Limitação de memória GPU
Épocas de treinamento	3–5	Padrão <i>fine-tuning</i> (DEVLIN et al., 2019)
Comprimento máx. de sequência	128 tokens	Adequado a enunciados curtos
<i>Warmup steps</i>	10% do total	Estabilidade no início
<i>Dropout</i>	0,1	Regularização padrão BERT

Fonte: Elaborado pelo autor com base em Devlin et al. (2019), Souza, Nogueira e Lotufo (2020).

Serão avaliadas as duas variantes disponíveis do BERTimbau: a versão Base (12 camadas, 110 milhões de parâmetros) e a versão Large (24 camadas, 335 milhões de parâmetros) (SOUZA; NOGUEIRA; LOTUFO, 2020). A versão Base será utilizada como padrão principal, enquanto a versão Large será avaliada como alternativa de maior capacidade representacional, a depender dos recursos computacionais disponíveis no TCC2.

3.3.2 Modelos alternativos: DeBERTinha e Albertina

Além do BERTimbau, dois modelos alternativos serão avaliados como classificadores, caso os recursos computacionais e o cronograma permitam: a DeBERTinha (ABONIZIO et al., 2023) e a Albertina PT-BR (RODRIGUES et al., 2023).

A DeBERTinha é uma versão compacta do DeBERTaV3 adaptada para o português brasileiro por Abonizio et al. (2023), com aproximadamente 70 milhões de parâmetros. Apesar de seu tamanho reduzido, demonstrou desempenho competitivo ou superior ao BERTimbau Large em diversas tarefas de NLP para o português, com vantagem significativa em eficiência computacional. Sua avaliação neste trabalho é motivada pela possibilidade de que um modelo mais eficiente alcance desempenho comparável ao BERTimbau em DDSD, o que teria implicações práticas relevantes para cenários com recursos limitados.

A Albertina PT-BR (RODRIGUES et al., 2023), por sua vez, é construída sobre a arquitetura DeBERTaV3 e foi pré-treinada do zero em português, com ênfase na qualidade dos dados de pré-treinamento. Sua avaliação permitirá comparar abordagens de adaptação contínua (*continual pre-training*, como na DeBERTinha) com pré-treinamento do zero em português. Dado seu maior tamanho (variantes de 1,5B a 7B de parâmetros), sua avaliação estará condicionada à disponibilidade de infraestrutura computacional adequada.

3.3.3 Baselines clássicos: TF-IDF + SVM e Regressão Logística

Para permitir a quantificação objetiva do ganho de desempenho obtido pelos modelos baseados em Transformers, serão implementados dois *baselines* clássicos: TF-IDF (Frequência do Termo - Inverso da Frequência nos Documentos, do inglês *Term Frequency-Inverse Document Frequency*) combinada com SVM (Máquinas de Vetores de Suporte, do inglês *Support Vector Machines*) ou combinada com Regressão Logística (LR, do inglês *Logistic Regression*) (MANNING; RAGHAVAN; SCHÜTZE, 2008).

Esses *baselines* serão implementados com as seguintes configurações: (i) TF-IDF com n -gramas de 1 a 3 palavras, para capturar padrões lexicais e sintagmáticos relevantes para a tarefa; (ii) SVM com *kernel* linear e regularização C ajustada por validação cruzada; e (iii) Regressão Logística com regularização L2 e otimizador LBFGS. Ambos os classificadores receberão como entrada a transcrição 1-best gerada pelo Whisper, representada como vetor TF-IDF esparsos.

A inclusão de *baselines* clássicos é uma contribuição metodológica deste trabalho que os três estudos relacionados não contemplaram (MALLIDI et al., 2018; WAGNER et al., 2024; DIGHE et al., 2024). Ela permite determinar se a complexidade adicional dos modelos baseados em Transformers é justificada pelo ganho de desempenho em uma tarefa com corpus de tamanho moderado, tornando os resultados mais interpretáveis e a análise mais rigorosa (WELD et al., 2022; MANNING; RAGHAVAN; SCHÜTZE, 2008).

3.4 Construção do corpus

A construção de um corpus textual em português brasileiro para a tarefa de DDSD é um dos objetivos específicos centrais deste trabalho e, simultaneamente, uma de suas contribuições mais relevantes para a comunidade de pesquisa. A ausência de corpora públicos para DDSD em português, identificada na análise dos trabalhos relacionados (Seção 2.4.4), impõe a necessidade de construção de um recurso próprio, com protocolo de anotação explícito e critérios de qualidade documentados (WAZLAWICK, 2020).

Uma característica central deste corpus, que o distingue de corpora de DDSD típicos da literatura (MALLIDI et al., 2018; WAGNER et al., 2024), é que ele é **exclusivamente textual**, ou seja, não contém gravações de áudio nem anotações acústicas. Isso decorre diretamente da modalidade de entrada do classificador proposto, que será operado, durante o experimento, sobre transcrições textuais geradas por ASR. Essa decisão, além de ser coerente com a abordagem técnica adotada, tem uma consequência prática relevante, na qual remove as restrições de escala que corpora de fala impõem, uma vez que a coleta, geração e anotação de texto é significativamente mais rápida e barata do que a gravação e transcrição de áudio (MØLLER; AIELLO; AUGENSTEIN, 2024). Estima-se, por isso, um corpus de grande escala, com volume superior a 100.000 amostras textuais distribuídas entre as classes, o que representa uma ordem de grandeza acima dos corpora de DDSD existentes na literatura.

3.4.1 Esquema de rotulação

Cada enunciado do corpus receberá um rótulo pertencente a um dos três esquemas a seguir:

- **DD** (*Device-Directed*): o enunciado é inequivocamente um comando, pergunta ou solicitação dirigida ao assistente virtual. Exemplos: “liga o ventilador”, “qual a previsão do tempo para amanhã?”, “toca uma música relaxante”;
- **NDD** (*Non-Device-Directed*): o enunciado claramente não é dirigido ao dispositivo, sendo parte de uma conversa entre humanos, um comentário incidental ou um enunciado sem destinatário específico. Exemplos: “nossa, está quente hoje”, “você foi ao mercado ontem?”, “preciso terminar esse relatório”;
- **AMB** (*Ambiguous*): o enunciado poderia ser interpretado como DD ou NDD dependendo do contexto não disponível no texto. Exemplos: “apaga a luz, por favor”, “pode colocar mais baixo?”, “me lembra disso amanhã”.

Para os experimentos de classificação binária, os enunciados **AMB** serão tratados como **NDD**, seguindo a lógica conservadora de que, na ausência de contexto suficiente para confirmar a intenção ao dispositivo, o sistema não deve acionar o assistente. Essa convenção

está alinhada com a definição do problema de DDSD como tarefa de classificação binária (MALLIDI et al., 2018) e com o princípio de minimização de ativações indevidas. Os enunciados AMB serão mantidos como subconjunto identificado, permitindo análises específicas sobre o comportamento do classificador nesses casos ambíguos.

É importante reconhecer que a incorporação dos enunciados AMB à classe NDD introduz um viés conservador mensurável sobre as métricas de avaliação: como casos genuinamente ambíguos tendem a ser mais fáceis de classificar como NDD do que casos claramente DD, essa fusão pode inflacionar artificialmente as métricas de acurácia e F1 no subconjunto AMB. Para controlar esse efeito, os enunciados AMB serão identificados por uma flag no corpus, e os resultados serão reportados de forma segmentada: desempenho sobre o corpus completo (DD + NDD + AMB fundido) e desempenho sobre amostras inequívocas (apenas DD e NDD puros). Essa análise segmentada permitirá avaliar em que medida os casos AMB facilitam ou dificultam a tarefa do classificador, tornando as conclusões metodologicamente mais robustas.

3.4.2 Fontes de dados e estratégias de construção

O corpus será construído a partir de duas fontes complementares e distintas por classe: dados públicos existentes para a classe NDD e dados sintetizados com auxílio de *Large Language Models* (traduzidos como Modelos de Linguagem de Grande Porte, referidos pela sigla LLMs) para as classes DD e AMB. Essa separação reflete a disponibilidade assimétrica de recursos: corpora de fala espontânea em português brasileiro são relativamente abundantes para conversas incidentais, ao passo que não há corpora públicos de comandos para assistentes de voz em português (JUNIOR et al., 2023).

3.4.2.1 Classe NDD: datasets públicos de fala espontânea

A classe NDD será composta por transcrições extraídas de corpora públicos de fala espontânea em português brasileiro, selecionados por sua diversidade dialetal, de registro e de contexto. Três corpora serão utilizados como fontes primárias:

O **CORAA ASR** (JUNIOR et al., 2023) é um dos maiores corpora de fala espontânea validados manualmente para o português brasileiro, com transcrições de entrevistas, apresentações e conversas informais em diferentes variedades regionais. Suas transcrições são ricas em vocabulário cotidiano e padrões conversacionais naturais, tornando-o especialmente adequado para representar enunciados incidentais.

O **NURC-SP** (LIMA et al., 2025) contém gravações de fala espontânea com o sotaque paulistano em contextos formais e informais. Sua inclusão contribui para a representatividade do português falado em São Paulo, variedade amplamente presente nos contextos de uso de assistentes de voz.

O **TAGARELA** (OLIVEIRA et al., 2026) é um corpus de fala extraído de *podcasts* em português brasileiro, caracterizado por fala semi-espontânea em formato conversacional. Sua inclusão adiciona diversidade temática e de estilo ao subconjunto NDD.

As transcrições extraídas desses corpora não requerem nova anotação para a classe NDD, pois por definição seu conteúdo é fala espontânea em contextos nos quais assistentes de voz não estão presentes. Uma amostragem aleatória estratificada por corpus e por tipo de contexto será aplicada para garantir diversidade.

3.4.2.2 Classes DD e AMB: geração sintética assistida por LLM

A classe DD não possui representação natural em corpora de fala espontânea, pois enunciados dirigidos a assistentes virtuais raramente ocorrem em contextos de conversação cotidiana não mediada por dispositivo. Para suprir essa lacuna em escala, este trabalho adotará uma abordagem de **geração sintética assistida por modelos de linguagem de grande escala** (LLMs), estratégia que tem ganho crescente respaldo na literatura de NLP para a criação de dados de treinamento em domínios com poucos recursos (MØLLER; AIELLO; AUGENSTEIN, 2024).

A geração sintética será estruturada em três estratégias complementares, detalhadas a seguir.

Estratégia 1 — Expansão por paráfrase de templates (*Template-based paraphrasing*). Serão elaborados manualmente entre 200 e 300 templates de enunciados imperativos e interrogativos típicos de interações com assistentes de voz, cobrindo domínios funcionais relevantes: controle de dispositivos domésticos (iluminação, temperatura, eletrodomésticos), consulta de informações (clima, notícias, horários), entretenimento (música, vídeos, *podcasts*), produtividade (alarmes, lembretes, timers) e comunicação (mensagens, chamadas). Cada template será fornecido a um LLM com a instrução de gerar múltiplas paráfrases naturais em português brasileiro, variando o nível de formalidade, o grau de implicação e a estrutura sintática. Essa abordagem, denominada *template-based paraphrasing*, é eficaz para garantir cobertura semântica ampla a partir de um conjunto compacto de intenções-semente (MØLLER; AIELLO; AUGENSTEIN, 2024).

Estratégia 2 — Geração por *role-playing* contextual. O LLM será instruído a adotar o papel de um usuário em diferentes contextos domésticos e a gerar enunciados que esse usuário diria ao seu assistente virtual sem utilizar *wake-words*. Os contextos serão variados sistematicamente: cozinha, sala de estar, quarto, banheiro, carro, escritório. Adicionalmente, o tom e o estado emocional do usuário serão variados (casual, apressado, educado, irritado, sussurrando) para capturar a diversidade de registros que ocorre em uso real. Essa estratégia produz enunciados mais naturais e contextualmente situados do que a expansão por templates.

Estratégia 3 — Geração de diálogos sintéticos completos (*Synthetic dialogues*). O LLM será solicitado a gerar diálogos completos simulando uma pessoa em

ambiente doméstico alternando entre conversas com outras pessoas e enunciados ao assistente. Cada turno do diálogo gerado será rotulado com DD, NDD ou AMB pelo próprio LLM como parte do processo de geração, sendo esse rótulo posteriormente validado por amostragem humana. Essa estratégia é especialmente útil para a geração de enunciados AMB, uma vez que a ambiguidade surge naturalmente no contexto de diálogos mistos. Um exemplo de saída esperada para essa estratégia é apresentado no Quadro 6.

Tabela 6 – Exemplo de diálogo sintético gerado por LLM com rótulos de classe

Enunciado	Rótulo
“Nossa, está muito quente aqui hoje.”	NDD
“Liga o ventilador, por favor.”	AMB
“Coloca o ventilador no máximo.”	DD
“Você foi ao mercado ontem?”	NDD
“Qual a previsão do tempo para amanhã?”	DD
“Me lembra de ligar para o médico às três.”	DD
“Preciso terminar esse relatório hoje.”	NDD

Fonte: Elaborado pelo autor (2026).

Os LLMs utilizados na geração sintética incluirão modelos de alta capacidade disponíveis comercialmente ou via API, como GPT-4o, Claude e Gemini, bem como modelos com foco em português brasileiro, como o Sabiá (PIRES et al., 2023), priorizando a naturalidade e a correção gramatical dos enunciados gerados. A qualidade das amostras geradas será avaliada por amostragem humana, conforme descrito na Seção 3.4.3.

Um risco metodológico inerente à geração sintética assistida por LLMs é o denominado viés de artefato linguístico (LLM-style artifact bias): amostras geradas por LLMs tendem a apresentar linguagem mais formal, sintaticamente mais regular e semanticamente mais explícita do que a fala espontânea real em português brasileiro, caracterizada por disfluências, reduções fonéticas, elipses e construções coloquiais (MØLLER; AIELLO; AUGENSTEIN, 2024). Para mitigar esse viés, serão adotadas as seguintes estratégias durante a geração: (i) instrução explícita dos LLMs para emular registros coloquiais e informais, incluindo marcadores de disfluência típicos do português falado ("né", "tipo", "então", hesitações); (ii) variação sistemática de parâmetros de temperamento e de estilo nos prompts de geração, para ampliar a diversidade linguística das amostras; (iii) comparação da distribuição estatística de características lexicais (comprimento médio de sentença, riqueza de vocabulário, frequência de marcadores informais) entre as amostras sintéticas e as transcrições extraídas dos corpora públicos, como critério adicional de controle de qualidade. Caso o viés seja detectado na análise, técnicas de pós-filtragem e re-geração com prompts corrigidos serão aplicadas antes da incorporação ao corpus final.

A Tabela 7 resume as fontes, estratégias e volumes estimados de cada componente do corpus.

Tabela 7 – Fontes, estratégias e volumes estimados do corpus de DDS em PT-BR

Fonte / Estratégia	Classe	Método	Volume estimado
CORAA ASR (JUNIOR et al., 2023)	NDD	Extração de transcrições	~30.000
NURC-SP (LIMA et al., 2025)	NDD	Extração de transcrições	~20.000
TAGARELA (OLIVEIRA et al., 2026)	NDD	Extração de transcrições	~20.000
<i>Template-based paraphrasing</i>	DD	LLM (geração sintética)	~15.000
<i>Role-playing</i> contextual	DD	LLM (geração sintética)	~10.000
Diálogos sintéticos	DD / AMB	LLM (geração sintética)	~10.000
Total estimado	—	—	~105.000 amostras

Fonte: Elaborado pelo autor (2026).

Os volumes apresentados são estimativas iniciais sujeitas a ajuste durante a execução do TCC2, em função da disponibilidade dos corpora públicos e da capacidade de geração dos LLMs utilizados. O critério de balanceamento entre classes DD e NDD será monitorado durante a construção: caso a razão entre classes supere 3:1, serão adotadas técnicas de balanceamento durante o treinamento, como ponderação de classes (*class weighting*) ou *oversampling* da classe minoritária.

3.4.3 Protocolo de validação e controle de qualidade

Dado que a maioria das amostras NDD é extraída de corpora validados publicamente e que as amostras DD e AMB são geradas sinteticamente com rótulos atribuídos pelo próprio LLM, o protocolo de qualidade deste corpus difere do protocolo de anotação manual clássico. Ele é estruturado em duas etapas complementares:

Etapla 1 — Validação por amostragem humana. Uma amostra aleatória estratificada de 5% de cada subconjunto (NDD extraído, DD sintético e AMB sintético) será revisada manualmente por dois avaliadores independentes, falantes nativos do português brasileiro. A escolha de 5% por subconjunto corresponde, dado o volume estimado do corpus, a aproximadamente 3.500 amostras por avaliador — tamanho considerado suficiente para detectar, com margem de erro de 5% e intervalo de confiança de 95%, desvios de qualidade superiores a 5 pontos percentuais na taxa de acerto de rótulos (MANNING; RAGHAVAN; SCHÜTZE, 2008). Para cada amostra, os avaliadores confirmarão ou corrigirão o rótulo atribuído, sem acesso ao rótulo original. A concordância entre avaliadores será medida pelo coeficiente Kappa de Cohen; amostras com discordância serão resolvidas por um terceiro avaliador. Um valor de Kappa acima de 0,70 no subconjunto amostrado será

considerado indicativo de qualidade aceitável para o corpus completo; caso o Kappa obtido seja inferior a 0,60, o protocolo de geração sintética será revisado antes de prosseguir com o corpus completo.

Etapa 2 — Filtragem automática de qualidade. Amostras com comprimento inferior a 3 tokens ou superior a 50 tokens serão descartadas, por fugirem do padrão típico de enunciados de assistentes de voz. Duplicatas exatas e duplicatas aproximadas (similaridade cossenoidal TF-IDF superior a 0,95) também serão removidas para evitar contaminação entre treino e teste (MANNING; RAGHAVAN; SCHÜTZE, 2008).

3.4.4 Divisão treino / validação / teste

O corpus será dividido nas proporções 70% treino, 15% validação e 15% teste (MANNING; RAGHAVAN; SCHÜTZE, 2008), com divisão estratificada por classe e por fonte de dados. A estratificação por fonte é essencial para garantir que cada subconjunto contenha amostras de todas as origens (corpora públicos e geração sintética), evitando que o conjunto de teste seja composto exclusivamente por um único tipo de dado.

O conjunto de teste será mantido estritamente reservado durante todo o processo de desenvolvimento e ajuste de hiperparâmetros, sendo utilizado exclusivamente na avaliação final (WAZLAWICK, 2020). Adicionalmente, os enunciados AMB serão identificados por uma flag no corpus, permitindo análises de desempenho segmentadas por subconjunto: desempenho geral, desempenho em amostras inequívocas (DD e NDD puros) e desempenho em casos ambíguos.

Por fim, uma versão reduzida do conjunto de teste — composta por amostras com transcrições manuais produzidas durante a fase de validação humana — será utilizada no experimento *upper-bound* descrito na Seção 3.5.2, permitindo estimar o desempenho do classificador sobre texto sem ruído de transcrição ASR.

3.5 Planejamento experimental

O planejamento experimental define o conjunto de experimentos que serão conduzidos no TCC2 para testar a hipótese de pesquisa formulada na Seção 1.5. Os experimentos são organizados em três grupos, detalhados nas subseções a seguir.

3.5.1 Configuração dos experimentos e hiperparâmetros

Experimento 1 — Baselines clássicos. Os modelos TF-IDF + SVM e TF-IDF + Regressão Logística serão treinados e avaliados sobre o conjunto de treinamento, com hiperparâmetros ajustados por validação cruzada de 5 *folds* sobre o conjunto de treino. A entrada será a transcrição 1-best gerada pelo Whisper Large V3 Turbo.

Experimento 2 — BERTimbau com *fine-tuning*. O BERTimbau Base e o BERTimbau Large serão submetidos ao processo de *fine-tuning* descrito na Seção 3.3.1, com diferentes configurações de entrada: (a) transcrição 1-best apenas; e (b) *n-best* com $N \in \{3, 5\}$ hipóteses concatenadas. Os hiperparâmetros iniciais são os descritos na Tabela 5, com ajuste fino por validação no conjunto de validação.

Experimento 3 — Modelos alternativos (condicionais). Caso os recursos computacionais permitam, os modelos DeBERTinha (ABONIZIO et al., 2023) e Albertina (RODRIGUES et al., 2023) serão avaliados com as mesmas configurações do Experimento 2, permitindo comparação direta entre as diferentes famílias de modelos de linguagem para o português brasileiro.

Todos os experimentos serão avaliados sobre o conjunto de teste com as métricas descritas na Seção 2.3.7: F1-score, acurácia, precisão, *recall*, Taxa de Erro Igual (conhecida por EER, do inglês *Equal Error Rate*) e ROC-AUC. Os resultados serão reportados com média e desvio padrão sobre 5 execuções com diferentes sementes aleatórias, garantindo a robustez estatística das conclusões (WAZLAWICK, 2020).

3.5.2 Experimento *upper-bound*: transcrição manual *versus* automática

O terceiro objetivo específico deste trabalho prevê a análise sistemática do impacto dos erros de transcrição ASR no desempenho do classificador de intenção (DIGHE et al., 2024). Para isso, será conduzido um experimento específico denominado *upper-bound*:

1. O classificador BERTimbau (melhor configuração dos Experimentos 1 e 2) será avaliado sobre o conjunto de teste com transcrições **manuais** (sem erros de ASR), produzindo o desempenho *upper-bound* — o teto teórico da abordagem textual com entrada perfeita;
2. O mesmo classificador será avaliado sobre o conjunto de teste com transcrições **automáticas** geradas pelas três variantes do Whisper (Medium, Large V3 e Large V3 Turbo), produzindo os desempenhos reais do sistema completo;
3. A diferença entre o desempenho *upper-bound* e os desempenhos com transcrições automáticas será analisada em função do WER de cada variante do Whisper, verificando se existe correlação entre a taxa de erro de transcrição e a degradação do classificador.

Esse experimento é particularmente relevante para o contexto do português brasileiro, idioma que apresenta desafios específicos para sistemas de ASR, como alta variabilidade fonética regional, reduções vocálicas e contrações características da fala informal (JUNIOR et al., 2023; BEVILACQUA et al., 2024).

3.5.3 Análise de interpretabilidade

Para além das métricas quantitativas, será conduzida uma análise qualitativa de interpretabilidade dos resultados do classificador BERTimbau. Essa análise tem dois objetivos: (i) identificar os padrões linguísticos mais discriminativos para a tarefa de DDS em português brasileiro; e (ii) verificar se os erros do classificador concentram-se nos casos ambíguos esperados, validando a coerência dos resultados com a teoria.

A análise de interpretabilidade será realizada por meio da técnica SHAP (*SHapley Additive exPlanations*) aplicada aos modelos *baseline* (TF-IDF + SVM/LR), que por sua natureza linear permitem identificar diretamente as *features* (termos do vocabulário) com maior peso discriminativo. Para o BERTimbau, será utilizada a técnica de visualização de pesos de atenção (*attention visualization*), que permite identificar quais tokens o modelo considera mais relevantes para a decisão de classificação (WELD et al., 2022).

3.6 Critérios de validação e aceitação da hipótese

A hipótese de pesquisa formulada na Seção 1.5 será considerada **confirmada** se, e somente se, os seguintes critérios forem simultaneamente satisfeitos sobre o conjunto de teste:

1. **Superioridade sobre os baselines clássicos:** o BERTimbau com *fine-tuning* deve alcançar F1-score estatisticamente superior (teste t de Student com $p < 0,05$) ao melhor *baseline* clássico (TF-IDF + SVM ou Regressão Logística).
2. **Viabilidade técnica da abordagem textual:** o sistema proposto deve alcançar EER inferior a 30% sobre o conjunto de teste, limiar definido como indicativo de capacidade discriminativa não trivial da abordagem textual para DDS em português brasileiro. Esse limiar foi estabelecido com base na premissa de que um classificador sem capacidade discriminativa real convergiria para EER próximo a 50% (equivalente à chance), e que qualquer valor substancialmente abaixo desse patamar constitui evidência de viabilidade técnica.
3. **Ganho mensurável do *n-best* sobre o 1-best:** a configuração com *n-best* ($N > 1$) deve apresentar F1-score igual ou superior à configuração com apenas a transcrição 1-best, validando a estratégia de uso de múltiplas hipóteses do ASR.

Caso a hipótese não seja confirmada, os resultados serão igualmente reportados e analisados, pois resultados negativos também contribuem para o avanço do conhecimento na área, especialmente no contexto de um *baseline* inicial para DDS em português brasileiro (WAZLAWICK, 2020).

3.7 Tecnologias e ferramentas

A implementação do sistema proposto utilizará o ecossistema Python de aprendizado de máquina e processamento de linguagem natural, consolidado como padrão na área (WELD et al., 2022). A Tabela 8 lista as principais bibliotecas e ferramentas previstas.

Tabela 8 – Tecnologias e ferramentas previstas para o desenvolvimento

Ferramenta	Versão prevista	Finalidade
Python	3.11+	Linguagem principal
PyTorch	2.x	Framework de deep learning
HuggingFace Transformers	4.x	Fine-tuning BERTimbau
HuggingFace Datasets	2.x	Gerenciamento do corpus
OpenAI Whisper	Large V3	Módulo ASR
scikit-learn	1.x	Baselines TF-IDF + SVM/LR
NumPy / Pandas	—	Manipulação de dados
Matplotlib / Seaborn	—	Visualização de resultados
SHAP	—	Análise de interpretabilidade
Git / GitHub	—	Controle de versão

Fonte: Elaborado pelo autor (2026).

Os experimentos serão executados em ambiente com suporte a GPU, dado o custo computacional do *fine-tuning* de modelos baseados em Transformers. Caso os recursos computacionais locais sejam insuficientes, será utilizada a plataforma Google Colab Pro ou equivalente com acesso a GPUs de pelo menos 16GB de VRAM, requisito mínimo para o *fine-tuning* do BERTimbau Large (SOUZA; NOGUEIRA; LOTUFO, 2020).

3.8 Resultados esperados

Com base na literatura revisada no Capítulo 2 e nas escolhas metodológicas descritas neste capítulo, são esperados os seguintes resultados ao final do TCC2:

(i) **Corpus textual de DDS em português brasileiro.** Espera-se a produção de um corpus com aproximadamente 105.000 amostras textuais anotadas, distribuídas entre as classes DD, NDD e AMB, construído a partir de corpora públicos de fala espontânea e de geração sintética assistida por LLMs (MÖLLER; AIELLO; AUGENSTEIN, 2024). Esse corpus será a primeira contribuição pública de grande escala para DDS em português brasileiro, de acordo com o levantamento realizado na metodologia de pesquisa bibliográfica (Seção 2.1).

(ii) **Superioridade do BERTimbau sobre os baselines clássicos.** Com base em Weld et al. (2022), que demonstram que modelos Transformer superam consistentemente abordagens tradicionais em tarefas de classificação de intenção, espera-se que o BERTimbau com *fine-tuning* alcance F1-score superior ao TF-IDF + SVM e à Regressão Logística. A magnitude dessa superioridade dependerá do tamanho final do corpus: em corpora menores, a diferença tende a ser menos expressiva (WELD et al., 2022).

(iii) **Ganho parcial da estratégia *n-best*.** Com base nos achados de Dighe et al. (2024), espera-se que a estratégia de *n-best* contribua para reduzir parcialmente o impacto dos erros de transcrição, especialmente em enunciados com WER elevado. No entanto, o ganho pode ser marginal em casos onde a transcrição 1-best já é de alta qualidade.


(iv) **Degradação mensurável do desempenho com erros de ASR.** O experimento *upper-bound* deverá evidenciar uma degradação estatisticamente significativa entre o desempenho com transcrições manuais e com transcrições automáticas, com magnitude proporcional ao WER de cada variante do Whisper. Essa análise fornecerá evidências empíricas sobre o papel do módulo ASR como gargalo do sistema proposto.

(v) **Baseline textual inicial para DDSD em PT-BR.** O conjunto de resultados produzidos — corpus, modelos treinados, código e métricas — constituirá o primeiro *baseline* documentado e reproduzível para a tarefa de DDSD em português brasileiro, servindo como ponto de referência para estudos futuros na área (WAZLAWICK, 2020; DIGHE et al., 2024).

3.9 Cronograma de trabalho

O cronograma de execução do TCC2 está organizado em seis fases sequenciais, distribuídas ao longo de um semestre letivo de aproximadamente 16 semanas, conforme ilustrado no diagrama de Gantt da Figura 5.

Figura 5 – Cronograma de execução previsto para o TCC2



Fonte: Elaborado pelo autor (2026).

A Tabela 9 descreve os marcos e entregáveis esperados ao final de cada fase.

Tabela 9 – Marcos e entregáveis por fase do TCC2

Fase	Semanas	Entregável principal
F1 – Corpus	1–5	Corpus anotado e validado
F2 – Implementação	4–9	Pipeline ASR + baselines + modelo BERTimbau
F3 – Experimentos	8–13	Resultados completos dos experimentos
F4 – Análise	12–14	Análise quantitativa e qualitativa
F5 – Escrita	13–15	Texto completo do TCC2 redigido
F6 – Entrega	15–16	TCC2 revisado, submetido e apresentado

Fonte: Elaborado pelo autor (2026).

As Fases F1 e F2 possuem sobreposição intencional a partir da Semana 4, permitindo que o desenvolvimento do módulo ASR inicie paralelamente ao processo final de anotação do corpus. Da mesma forma, as Fases F4 e F5 apresentam sobreposição a partir da Semana 13, viabilizando o início da redação enquanto as análises finais ainda estão em andamento.

Essa sobreposição foi planejada para otimizar o tempo disponível dentro das 16 semanas do semestre.

Referências

- ABONIZIO, H. et al. DeBERTinha: A multistep approach to adapt DeBERTaV3 XSmall for Brazilian Portuguese natural language processing tasks. *arXiv preprint arXiv:2309.16844*, 2023. 10, 12, 23, 27, 45, 52
- BEVILACQUA, A. et al. Whispy: Adapting STT whisper models to real-time environments. *arXiv preprint arXiv:2405.03484*, 2024. 9, 13, 19, 30, 39, 42, 52
- CHEN, Y. et al. FakeWake: Understanding and mitigating fake wake-up words of voice assistants. In: *Proceedings of the 2021 ACM SIGSAC Conference on Computer and Communications Security*. [S.l.]: ACM, 2021. p. 1861–1883. 7, 14, 20
- CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, v. 20, n. 3, p. 273–297, 1995. 28
- DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Association for Computational Linguistics, p. 4171–4186, 2019. 16, 22, 23, 25, 43, 44
- DIGHE, P. et al. Leveraging large language models for exploiting asr uncertainty. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2024. 10, 12, 13, 21, 31, 32, 34, 36, 37, 38, 39, 40, 41, 43, 45, 52, 55
- GARG, V. et al. Streaming transformer for hardware efficient voice trigger detection and false trigger mitigation. *Proceedings of Interspeech 2021*, 2021. 7, 17, 19, 20
- GROSMAN, J.; NOGUEIRA, R. Wav2vec 2.0 for Brazilian Portuguese. In: *Anais do Encontro Nacional de Inteligência Artificial e Computacional (ENIAC)*. [S.l.]: SBC, 2021. 9, 19
- HE, P. et al. DeBERTa: Decoding-enhanced BERT with disentangled attention. In: *Proceedings of the 9th International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2021. 27
- JEFFRIES, N. et al. Moonshine: Speech recognition for live transcription and voice commands. *arXiv preprint arXiv:2410.15608*, 2024. 9, 19, 30, 42
- JUNIOR, A. C. et al. Coraa asr: A large corpus of spontaneous and prepared speech manually validated for speech recognition in brazilian portuguese. *Language Resources and Evaluation*, Springer, v. 57, p. 1139–1171, 2023. 11, 13, 14, 38, 39, 42, 47, 50, 52
- JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.]: Pearson, 2024. Rascunho online disponível em <https://web.stanford.edu/~jurafsky/slp3/>. 7, 17, 18, 21
- KRISHNA, G. et al. Modality dropout for multimodal device directed speech detection using verbal and non-verbal features. *arXiv preprint arXiv:2310.15261*, 2023. 11, 13, 21, 31

- KUNDU, A. et al. Heimdal: Highly efficient method for detection and localization of wake-words. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2023. 19
- LI, N. et al. Robust voice activity detection using a masked auditory encoder based convolutional neural network. In: *IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*. [S.l.: s.n.], 2021. 17, 18, 40
- LIMA, R. et al. A large dataset of spontaneous speech with the accent spoken in são paulo for automatic speech recognition evaluation. In: *Intelligent Systems*. [S.l.]: Springer, 2025. (Lecture Notes in Computer Science). 11, 13, 39, 47, 50
- MALLIDI, S. H. et al. Device-directed utterance detection. In: *Proceedings of Interspeech 2018*. [S.l.: s.n.], 2018. p. 3629–3633. 8, 9, 11, 16, 20, 32, 33, 34, 37, 45, 46, 47
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press, 2008. 22, 28, 29, 31, 37, 39, 45, 50, 51
- MØLLER, A. G.; AIELLO, L. M.; AUGENSTEIN, I. Is a prompt and a few samples all you need? using GPT-4 for data augmentation in low-resource classification tasks. In: *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. [S.l.]: ELRA and ICCL, 2024. p. 12764–12779. 39, 46, 48, 49, 54
- Next Move Strategy Consulting. *Voice Assistant Market Size and Share / Statistics 2025-2030*. 2025. Acesso em: 09 abr. 2026. Disponível em: <<https://www.nextmsc.com/report/voice-assistant-market>>. 7, 17
- NIE, L. et al. Multimodal activation: Awakening dialog robots without wake words. In: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. [S.l.]: ACM, 2021. p. 491–500. 7, 11, 20, 21, 33
- NOROUZIAN, A. et al. Exploring attention mechanism for acoustic-based classification of speech utterances into system-directed and non-system-directed. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2019. p. 7310–7314. 11, 13, 16
- OLIVEIRA, F. S. de et al. Tagarela: A portuguese speech dataset from podcasts. *arXiv preprint arXiv:2603.15326*, 2026. 11, 13, 39, 48, 50
- PIRES, R. et al. Sabiá: Portuguese large language models. In: *Brazilian Conference on Intelligent Systems (BRACIS)*. [S.l.]: Springer, 2023. p. 226–240. 10, 49
- RADFORD, A. et al. Robust speech recognition via large-scale weak supervision. *Proceedings of the 40th International Conference on Machine Learning*, PMLR, p. 28492–28518, 2023. 9, 18, 29, 30, 40, 42
- RODRIGUES, J. et al. Advancing neural encoding of Portuguese with transformer Albertina PT-*. *arXiv preprint arXiv:2305.06721*, 2023. 10, 23, 27, 45, 52
- RUDOVIC, O. et al. Device-directed speech detection for follow-up conversations using large language models. In: *NeurIPS 2024 Workshop on Adaptive Foundation Models*. [S.l.: s.n.], 2024. 10, 21

- SHIN, D. *Low Latency and Energy-efficient Hotword Detection Based on Mouth Movement*. [S.l.], 2023. Disponível em: <https://www.tdcommons.org/dpubs_series/6034/>. 19
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: *Proceedings of the Brazilian Conference on Intelligent Systems (BRACIS)*. [S.l.]: Springer, 2020. p. 403–417. 9, 11, 12, 13, 16, 23, 26, 37, 43, 44, 54
- VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems*, v. 30, p. 5998–6008, 2017. 9, 16, 18, 22, 23, 24
- WAGNER, D. et al. A multimodal approach to device-directed speech detection with large language models. In: *IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*. [S.l.: s.n.], 2024. 8, 9, 10, 11, 12, 20, 21, 31, 32, 33, 34, 35, 38, 39, 40, 41, 45, 46
- WAZLAWICK, R. S. *Metodologia de Pesquisa para Ciência da Computação*. 3. ed. Rio de Janeiro: Elsevier, 2020. 32, 39, 40, 46, 51, 52, 53, 55
- WELD, H. et al. A survey of joint intent detection and slot filling models in natural language understanding. *ACM Computing Surveys*, v. 55, n. 8, p. 156, 2022. Levantamento amplo sobre métodos de detecção de intenção. Demonstra que modelos baseados em Transformers pré-treinados como o BERT atingem estado da arte em classificação de intenção textual, superando abordagens tradicionais de ML. 7, 12, 21, 22, 23, 29, 31, 37, 39, 44, 45, 53, 54, 55
- XU, M. et al. Conformer-based speech recognition on extreme edge-computing devices. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Industry Track)*. [S.l.]: Association for Computational Linguistics, 2024. p. 131–139. 11, 35, 37