

Phelipe Pereira de Souza

Deteccção de Intenção Implícita para Ativação de Assistentes de Voz em Ambientes Controlados

São Paulo

2026

Phelipe Pereira de Souza

Detecção de Intenção Implícita para Ativação de Assistentes de Voz em Ambientes Controlados

Proposta de Trabalho de Conclusão de Curso
apresentado ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do Bacharelado em Ciência da Com-
putação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Prof. Thyago Conchado Quintas

São Paulo
2026

Lista de ilustrações

Figura 1 – Projeção de crescimento do mercado global de assistentes virtuais de voz (2024–2030).	7
Figura 2 – Cenário ilustrativo de Detecção de Fala Direcionada ao Dispositivo (DDSD).	8
Figura 3 – Fluxo de seleção de estudos para a revisão bibliográfica.	15
Figura 4 – Arquitetura do pipeline proposto para DDSD textual	35
Figura 5 – Cronograma de execução previsto para o TCC2	48

Lista de tabelas

Tabela 1	–	Mapeamento de tecnologias e seus papéis no trabalho	10
Tabela 2	–	Comparação técnica entre os trabalhos relacionados	32
Tabela 3	–	Diferencial deste TCC em relação aos trabalhos relacionados	32
Tabela 4	–	Variantes do Whisper avaliadas no módulo ASR	36
Tabela 5	–	Hiperparâmetros iniciais para o <i>fine-tuning</i> do BERTimbau	38
Tabela 6	–	Exemplo de diálogo sintético gerado por LLM com rótulos de classe . .	42
Tabela 7	–	Fontes, estratégias e volumes estimados do corpus de DDS em PT-BR	43
Tabela 8	–	Tecnologias e ferramentas previstas para o desenvolvimento	47
Tabela 9	–	Marcos e entregáveis por fase do TCC2	49

Lista de abreviaturas e siglas

ASR	<i>Automatic Speech Recognition</i> (Reconhecimento Automático de Fala)
DDSD	<i>Device-Directed Speech Detection</i> (Detecção de Fala Direcionada ao Dispositivo)
EER	<i>Equal Error Rate</i> (Taxa de Erro Igual)
HCI	<i>Human-Computer Interaction</i> (Interação Humano-Computador)
HMM	<i>Hidden Markov Model</i> (Modelo Oculto de Markov)
LLM	<i>Large Language Model</i> (Modelo de Linguagem de Grande Porte)
LR	<i>Logistic Regression</i> (Regressão Logística)
ML	<i>Machine Learning</i> (Aprendizado de Máquina)
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
NLU	<i>Natural Language Understanding</i> (Compreensão de Linguagem Natural)
SVM	<i>Support Vector Machines</i> (Máquinas de Vetores de Suporte)
TF-IDF	<i>Term Frequency-Inverse Document Frequency</i> (Frequência do Termo - Inverso da Frequência nos Documentos)
TTS	<i>Text-to-Speech</i> (Síntese de Fala)
VAD	<i>Voice Activity Detection</i> (Detecção de Atividade de Voz)
WER	<i>Word Error Rate</i> (Taxa de Erro de Palavras)

Sumário


1	INTRODUÇÃO	7
1.1	Cenário motivador	8
1.2	Contexto	9
1.3	Justificativa	11
1.4	Hipótese de pesquisa	12
1.5	Objetivos	12
1.5.1	Objetivo principal	12
1.5.2	Objetivos específicos	13
1.6	Limitações do trabalho	13
2	REVISÃO BIBLIOGRÁFICA	15
2.1	Metodologia da pesquisa bibliográfica	15
2.2	Referencial teórico	16
2.2.1	Assistentes virtuais e interação por voz	17
2.2.2	Deteção de Atividade de Voz (VAD)	17
2.2.3	Reconhecimento Automático de Fala (ASR)	18
2.2.4	Wake-words: mecanismo, vantagens e limitações	18
2.2.5	Deteção de Fala Direcionada ao Dispositivo (DDSD)	19
2.2.6	Processamento de Linguagem Natural e classificação de intenção	20
2.2.7	Modelos baseados em Transformers	21
2.3	Fundamentos	21
2.3.1	Arquitetura Transformer	21
2.3.2	BERT e o mecanismo de fine-tuning	23
2.3.3	BERTimbau: BERT para o português brasileiro	23
2.3.4	DeBERTa, DeBERTinha e Albertina PT-BR	24
2.3.5	Modelos baseline: TF-IDF, SVM e Regressão Logística	25
2.3.6	ASR com Whisper	26
2.3.7	Métricas de avaliação	26
2.4	Trabalhos relacionados	27
2.4.1	Mallidi et al. (2018)	28
2.4.2	Wagner et al. (2024)	29
2.4.3	Dighe et al. (2024)	30
2.4.4	Síntese comparativa	31
3	DESENVOLVIMENTO	34
3.1	Visão geral da solução proposta	34

3.1.1	Arquitetura do pipeline	34
3.1.2	Definição de ambiente controlado	35
3.2	Módulo ASR: transcrição e geração do <i>n-best</i>	36
3.2.1	Escolha e configuração do Whisper	36
3.2.2	Estratégia de uso do <i>n-best</i>	36
3.2.3	Impacto esperado dos erros de transcrição (WER)	37
3.3	Módulo de classificação de intenção	37
3.3.1	Modelo principal: BERTimbau com <i>fine-tuning</i>	37
3.3.2	Modelos alternativos: DeBERTinha e Albertina	38
3.3.3	Baselines clássicos: TF-IDF + SVM e Regressão Logística	39
3.4	Construção do corpus	39
3.4.1	Esquema de rotulação	40
3.4.2	Fontes de dados e estratégias de construção	40
3.4.2.1	Classe NDD: datasets públicos de fala espontânea	40
3.4.2.2	Classes DD e AMB: geração sintética assistida por LLM	41
3.4.3	Protocolo de validação e controle de qualidade	42
3.4.4	Divisão treino / validação / teste	43
3.5	Planejamento experimental	44
3.5.1	Configuração dos experimentos e hiperparâmetros	44
3.5.2	Experimento <i>upper-bound</i> : transcrição manual <i>versus</i> automática	45
3.5.3	Análise de interpretabilidade	45
3.6	Critérios de validação e aceitação da hipótese	46
3.7	Tecnologias e ferramentas	46
3.8	Resultados esperados	47
3.9	Cronograma de trabalho	48
	 REFERÊNCIAS	 50

1 Introdução

Nas últimas décadas, os assistentes de voz tornaram-se componentes cada vez mais presentes no cotidiano, incorporados a *smartphones*, alto-falantes inteligentes, *wearables* e sistemas de automação residencial (JURAFSKY; MARTIN, 2024). Esses sistemas permitem que usuários interajam com dispositivos computacionais por meio de comandos de voz, facilitando a execução de tarefas como busca de informações, controle de dispositivos domésticos e gerenciamento de atividades. O mercado global de assistentes de voz foi avaliado em US\$ 7,35 bilhões em 2024 e projeta-se que alcance US\$ 33,74 bilhões até 2030, com taxa de crescimento anual composta de 26,5%, o que evidencia a escala e a relevância dessa tecnologia, conforme ilustrado no gráfico de projeção da Figura 1 (Next Move Strategy Consulting, 2025).

Figura 1 – Projeção de crescimento do mercado global de assistentes virtuais de voz (2024–2030).



Fonte: Next Move Strategy Consulting (2025).

Na maioria dos sistemas atuais, a interação com assistentes de voz é iniciada por meio de palavras de ativação explícitas, conhecidas como *wake-words* ou *hotwords*, tais como “Hey Siri”, “Alexa” ou “Ok Google”. Essas expressões atuam como um mecanismo de gatilho que sinaliza ao sistema o desejo do usuário de iniciar uma interação. Do ponto de vista técnico, essa abordagem é eficaz, pois permite reduzir o processamento contínuo de áudio e minimizar ativações indevidas (GARG et al., 2021). No entanto, a dependência de *wake-words* impõe limitações significativas à naturalidade da comunicação humano-computador, tornando a interação menos fluida e intuitiva quando comparada ao diálogo humano (NIE et al., 2021).

Em interações humanas cotidianas, comandos e solicitações são frequentemente expressos de forma implícita, inseridos naturalmente no fluxo da conversação, sem a necessidade de uma palavra específica para iniciar a comunicação (WELD et al., 2022). Em contraste, os sistemas baseados em *wake-words* são vulneráveis ao fenômeno de ativações falsas por palavras foneticamente semelhantes, conhecido como *Fake Wake* (CHEN et al., 2021). Esse


problema compromete a qualidade da experiência do usuário, evidenciando as limitações da abordagem atual para a viabilização de uma interação verdadeiramente natural e intuitiva.

Nesse cenário, surge a área de pesquisa denominada *Device-Directed Speech Detection* (traduzido como Detecção de Fala Direcionada ao Dispositivo, referenciado pela sigla DDSD), que visa determinar automaticamente se uma fala é direcionada a um assistente virtual, mesmo na ausência de uma palavra de ativação explícita, ou se faz parte de uma conversa entre humanos (MALLIDI et al., 2018; WAGNER et al., 2024). Essa abordagem possibilita interações mais naturais e fluidas, reduzindo a necessidade de gatilhos verbais explícitos (*wake-words*) e representando um avanço significativo rumo a uma comunicação humano-computador mais intuitiva e semelhante ao diálogo cotidiano.

Este trabalho investiga a viabilidade da DDSD em português brasileiro por meio de uma abordagem baseada exclusivamente no nível textual. O sistema proposto opera com transcrições de fala obtidas via Reconhecimento Automático de Fala (do inglês *Automatic Speech Recognition*, referido pela sigla ASR), e aplica técnicas de Processamento de Linguagem Natural (do inglês *Natural Language Processing*, referido pela sigla NLP) e Aprendizado de Máquina (do inglês *Machine Learning*, referido pela sigla ML) para classificar automaticamente se uma fala é direcionada ao dispositivo ou faz parte de uma conversa incidental entre humanos. O foco deste trabalho reside na etapa de classificação de intenção, tratando o ASR como um módulo de pré-processamento encarregado de gerar as transcrições textuais que servirão de entrada para o classificador.

1.1 Cenário motivador

Figura 2 – Cenário ilustrativo de Detecção de Fala Direcionada ao Dispositivo (DDSD).



Fonte: Elaborado pelo autor (2026).

Para ilustrar a complexidade e a relevância do problema, considere o cenário prático apresentado na Figura 2: em uma sala de estar, duas pessoas conversam informalmente na

presença de um assistente de voz ativo. Uma delas comenta, em tom casual: “nossa, está escuro aqui”. O sistema não deve acionar a iluminação, visto que o enunciado constitui apenas um comentário incidental e não uma instrução direcionada. Momentos depois, a mesma pessoa olha para o dispositivo e diz: “acende a luz da sala”. Nesse cenário, mesmo na ausência de uma *wake-word*, o assistente deve ser capaz de reconhecer a fala como claramente direcionada a ele.

Esse cenário ilustra as três classes de enunciados que o sistema precisa distinguir: (i) comandos implícitos direcionados ao dispositivo (DD, do inglês *Device-Directed*), como “acende a luz”; (ii) comentários incidentais e conversas paralelas, classificados como não direcionados ao dispositivo (NDD, do inglês *Non-Device-Directed*), como “nossa, está escuro aqui”; e (iii) enunciados ambíguos (AMB), cujo direcionamento depende estritamente do contexto extraverbal, como “apaga a luz, por favor”, que pode ser direcionado tanto a um interlocutor humano quanto ao assistente. O problema de DDS consiste precisamente em classificar automaticamente esses enunciados em tempo real, sem depender de *wake-words* explícitas (MALLIDI et al., 2018; WAGNER et al., 2024).

1.2 Contexto

O desenvolvimento de assistentes de voz tem sido impulsionado por avanços significativos nas áreas de ASR e NLP. Modelos de última geração, como o Whisper (RADFORD et al., 2023), representam marcos importantes ao viabilizar a transcrição de áudio com elevada precisão e robustez em múltiplos idiomas. Em 2024, a OpenAI disponibilizou o Whisper Large V3 Turbo, uma versão otimizada que reduz o número de camadas do decodificador de 32 para 4, mantendo desempenho próximo ao modelo completo com ganho de velocidade de aproximadamente 6 vezes (JEFFRIES et al., 2024; BEVILACQUA et al., 2024). Essa versão é adotada neste trabalho como módulo principal de ASR, por oferecer o melhor equilíbrio entre precisão e eficiência para o português brasileiro. Na literatura, outras alternativas relevantes incluem o Whispy (BEVILACQUA et al., 2024), que adapta o Whisper para cenários de fluxo contínuo (*streaming*), e modelos compactos como o Moonshine (JEFFRIES et al., 2024), voltados para execução em dispositivos embarcados.

Especificamente para o português brasileiro, modelos baseados na arquitetura Wav2Vec 2.0 (GROSMAN; NOGUEIRA, 2021), ajustados com dados nacionais, também têm demonstrado resultados relevantes na literatura, representando alternativas para lidar com as variações fonéticas e prosódicas do idioma.

Simultaneamente, os desenvolvimentos em NLP foram revolucionados pela arquitetura Transformer (VASWANI et al., 2017), que serve de base para os modernos LLMs (Modelos de Linguagem de Grande Porte, do inglês *Large Language Models*). No âmbito nacional, o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) consolidou o uso de Transformers especializados em português brasileiro para tarefas de compreensão textual, sendo adotado

neste trabalho como classificador principal de intenção. Mais recentemente, modelos como Albertina (RODRIGUES et al., 2023) e DeBERTinha (ABONIZIO et al., 2023) introduziram abordagens altamente eficientes em termos de parâmetros e representação semântica, sendo considerados como alternativas a serem exploradas caso o cronograma permita. Ademais, LLMs generativos como o Sabiá (PIRES et al., 2023) ampliaram as competências de geração textual para o idioma, sendo empregado neste trabalho para a geração sintética de enunciados direcionados ao dispositivo na construção do corpus de experimentos.

Torna-se necessário delimitar o papel específico de cada família de modelos no escopo deste projeto: o Whisper Large V3 Turbo atua como módulo principal de ASR para a conversão de fala em texto, enquanto Moonshine e Wav2Vec 2.0 são mencionados como referências da literatura. Os modelos de linguagem pré-treinados, com destaque para o BERTimbau como classificador principal e DeBERTinha e Albertina como alternativas, constituem o núcleo da decisão de DDS textual. Por fim, o Sabiá é empregado como ferramenta de geração sintética de dados para a construção do corpus. A Tabela 1 sintetiza essa distribuição de responsabilidades.

Tabela 1 – Mapeamento de tecnologias e seus papéis no trabalho

Tecnologia	Papel no trabalho	Será implementada?
Whisper Large V3 Turbo	ASR - geração de transcrição	Sim (principal)
Moonshine	ASR - referência bibliográfica	Não
Wav2Vec 2.0 PT-BR	ASR - referência bibliográfica	Não
BERTimbau	Classificador textual (principal)	Sim
DeBERTinha	Classificador textual (alternativo)	Opcional
Albertina	Classificador textual (alternativo)	Opcional
TF-IDF + SVM/LR	Baseline clássico	Sim
Sabiá	Geração sintética de dados DD	Sim

Fonte: Elaborado pelo autor (2026).

Pesquisas recentes em DDS têm investigado abordagens focadas no nível do texto para mitigar as limitações de sistemas puramente acústicos. Trabalhos recentes (WAGNER et al., 2024; DIGHE et al., 2024) demonstraram que aplicar classificadores baseados em Transformers sobre as hipóteses de transcrição geradas por sistemas de ASR configura-se como uma estratégia robusta para inferir o direcionamento do enunciado. Expandindo essa premissa, Rudovic et al. (2024) evidenciaram como a semântica textual permite decodificar intenções implícitas em fluxos de diálogo contínuo, corroborando a viabilidade técnica da modelagem puramente linguística do sinal de áudio transcrito.

1.3 Justificativa

A crescente presença de assistentes de voz em diferentes dispositivos computacionais evidencia a relevância de pesquisas voltadas à melhoria da Interação Humano-Computador (conhecida por HCI, do inglês *Human-Computer Interaction*). Apesar dos avanços significativos em ASR e NLP, a maioria dos sistemas atuais ainda depende de palavras de ativação explícitas, que podem comprometer a naturalidade e a fluidez da comunicação (MALLIDI et al., 2018). Em ambientes com interações dinâmicas e frequentes, a necessidade de invocar repetidamente o dispositivo pode gerar fadiga no usuário e prejudicar a experiência de uso (NIE et al., 2021). Diante disso, o desenvolvimento de sistemas de DDS apresenta-se como uma abordagem relevante para reduzir a dependência de palavras de ativação explícitas e promover interações mais fluidas e intuitivas (WAGNER et al., 2024).

Sob a perspectiva acadêmica, o estudo de métodos alternativos de ativação baseados em intenção implícita situa-se na convergência do processamento de áudio, NLP e HCI. Embora a literatura aponte que a fusão multimodal (acústica e textual) resulte em menores taxas de erro de ativação (WAGNER et al., 2024), a implementação de sistemas multimodais demanda alto poder computacional, processos complexos de sincronização temporal de sinais e grandes volumes de dados rotulados em ambas as modalidades, o que impõe barreiras severas para a implantação em dispositivos de borda ou com recursos computacionais restritos (XU et al., 2024).

Adicionalmente, identifica-se uma lacuna geográfica e linguística na literatura: os principais estudos sobre DDS concentram-se quase exclusivamente no idioma inglês, com forte dependência de características acústicas e prosódicas nativas daquela língua (NOROUZIAN et al., 2019; KRISHNA et al., 2023). O português brasileiro, apesar de ser um dos idiomas mais falados do mundo, apresenta-se sub-representado nesse campo de pesquisa, carecendo de estudos focados na decodificação de padrões de direcionamento de fala adaptados à sua realidade gramatical e cultural.

Embora o ecossistema nacional tenha presenciado o surgimento de recursos linguísticos robustos, como o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e corpora públicos de fala (ex.: CORAA ASR (JUNIOR et al., 2023), NURC-SP (LIMA et al., 2025), TAGARELA (OLIVEIRA et al., 2026)), tais bases destinam-se prioritariamente a tarefas de transcrição fonética e reconhecimento acústico tradicional. Verifica-se, portanto, uma escassez de corpora especificamente anotados com fins de detecção de direcionamento de voz (DD vs NDD) em português brasileiro, constituindo um gargalo para a pesquisa científica e o desenvolvimento de soluções práticas para DDS nesse idioma.

Nesse cenário, este trabalho busca contribuir para o preenchimento dessa lacuna ao investigar a viabilidade técnica de uma abordagem de DDS puramente textual, alimentada por hipóteses de transcrição geradas por sistemas de ASR e operacionalizada por meio de modelos baseados em Transformer pré-treinados para o português brasileiro. A escolha exclusiva pela modalidade textual fundamenta-se em três pilares metodológicos:

(i) a superioridade dos modelos baseados em atenção para capturar nuances semânticas e intenções implícitas em tarefas de classificação de enunciados curtos (WELD et al., 2022); (ii) as evidências empíricas de que o sinal linguístico presente em transcrições automáticas carrega alto poder discriminativo para diferenciar comandos de conversações casuais (WAGNER et al., 2024; DIGHE et al., 2024). e (iii) o ganho de modularidade e isolamento arquitetural, o que facilita a comparação rigorosa com *baselines* lineares e viabiliza a mensuração precisa do impacto de ruídos e erros de transcrição de áudio (DIGHE et al., 2024).

1.4 Hipótese de pesquisa

A hipótese central deste trabalho é a seguinte:

*Sob condições de ambiente controlado, modelos de linguagem pré-treinados para o português brasileiro, aplicados sobre transcrições geradas por sistemas de ASR, alcançam desempenho estatisticamente superior a *baselines* lineares tradicionais, constituídos pela representação TF-IDF combinada com SVM ou LR, avaliados sobre o mesmo corpus sob as métricas de F1-score, acurácia e EER, comprovando a viabilidade técnica da abordagem puramente textual para a tarefa de DDS em português brasileiro.*

Essa conjectura encontra sustentação nos fundamentos apresentados na Seção 2.3: a viabilidade da classificação puramente textual sobre hipóteses de ASR (WAGNER et al., 2024), a superioridade de arquiteturas Transformer em tarefas de classificação de intenção (WELD et al., 2022) e o desempenho comprovado de modelos especializados no português brasileiro, como o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e o DeBERTinha (ABONIZIO et al., 2023).

A validação dessa hipótese será realizada por meio de experimentos controlados no TCC2, utilizando um corpus anotado especificamente para a tarefa de DDS em português brasileiro, com protocolo de validação cruzada e comparação rigorosa entre o modelo baseado em Transformer e os *baselines* lineares definidos nos Objetivos Específicos.

1.5 Objetivos

1.5.1 Objetivo principal

O objetivo principal desta pesquisa consiste em avaliar a viabilidade técnica e o desempenho de modelos de linguagem pré-treinados para o português brasileiro aplicados à DDS, operando sob transcrições puramente textuais geradas por sistemas de ASR, de modo a verificar se essa abordagem supera estatisticamente os *baselines* lineares compostos por TF-IDF associado a SVM ou LR, nas métricas de F1-score, acurácia e EER.

1.5.2 Objetivos específicos

Para que o objetivo principal seja alcançado, foram definidos os seguintes objetivos específicos:

1. Construir e validar um corpus balanceado de sentenças em português brasileiro, anotadas com base no direcionamento de fala (DD e NDD) sob critérios explícitos de anotação e rigorosos de exclusão, a partir de adaptações de corpora públicos (CORAA ASR (JUNIOR et al., 2023), NURC-SP (LIMA et al., 2025) e TAGARELA (OLIVEIRA et al., 2026)) e enunciados sintetizados controlados gerados por LLMs.
2. Implementar, ajustar (fine-tuning) e avaliar o modelo BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) na tarefa de classificação binária de DDSD, confrontando empiricamente seus resultados com um *baseline* composto pela representação vetorial TF-IDF aliada a SVM ou LR, utilizando hipóteses de transcrição geradas por ASR (1-best e/ou n-best).
3. Analisar o impacto gerado por erros e ruídos de transcrição automática no classificador semântico de intenções, mapeando o desempenho comparativo entre transcrições manuais e automáticas e estabelecendo a correlação estatística entre a *Word Error Rate* (traduzida como Taxa de Erro de Palavras, referenciada pela sigla WER) das saídas do ASR e o decaimento de desempenho do classificador textual (DIGHE et al., 2024).

1.6 Limitações do trabalho

Esta proposta apresenta restrições de escopo e limitações do desenho experimental adotado, explicitadas a seguir para contextualizar os resultados.

A primeira limitação refere-se à exclusividade da modalidade de entrada. O modelo proposto analisa estritamente informações do domínio textual das transcrições, omitindo características prosódicas, acústicas ou paralingüísticas (entonação, velocidade e pausas) comprovadamente relevantes para a DDSD (NOROUZIAN et al., 2019; KRISHNA et al., 2023). Embora seja uma escolha deliberada para estabelecer uma base textual robusta antes do desenvolvimento multimodal, assume-se o risco de o sistema apresentar menor sensibilidade em cenários com ruídos acústicos acentuados ou variações expressivas de tom.

A segunda limitação reside no impacto dos erros de transcrição gerados pelo ASR. Como a entrada do classificador depende diretamente da transcrição gerada pelo Whisper, erros fonéticos ou omissões podem corromper as estruturas gramaticais e semânticas analisadas pelo Transformer, especialmente em falas com sotaque, ruído de fundo ou vocabulário incomum (BEVILACQUA et al., 2024). O impacto desses erros será analisado como

parte dos experimentos, mas representa uma fonte de variabilidade não completamente controlável. A comparação entre transcrições manuais e automáticas, prevista no terceiro objetivo específico, buscará quantificar essa degradação.

A terceira limitação está associada à construção, representatividade e escala do corpus experimental. Diante da ausência de bases especificamente anotadas para DDS em português brasileiro, torna-se necessária a construção de um corpus próprio em ambiente controlado, combinando dados reais fragmentados e geração sintética assistida por LLMs. Tal estratégia implica restrições em termos de escala, espontaneidade conversacional, diversidade sociolinguística regional e variabilidade dialetal. Consequentemente, o corpus resultante não contemplará toda a complexidade e variabilidade da fala espontânea em contextos reais (JUNIOR et al., 2023), o que pode limitar a capacidade de generalização dos resultados.


Por fim, esta pesquisa não contempla aspectos relacionados à infraestrutura de implantação em ambientes produtivos, como latência de ponta a ponta, processamento contínuo em fluxo no dispositivo (*on-device streaming*), armazenamento de sinais de áudio, segurança de dados e privacidade. O foco repousa exclusivamente na análise experimental e estatística da viabilidade da classificação textual em ambiente laboratorial controlado, delegando a estudos futuros os desafios regulatórios e arquiteturais de privacidade, processamento local e mecanismos de consentimento do usuário (CHEN et al., 2021).

2 Revisão Bibliográfica

Este capítulo estabelece o embasamento teórico e tecnológico da pesquisa proposta. Inicialmente, descreve-se a metodologia de seleção dos trabalhos consultados. O referencial teórico, na sequência, percorre os paradigmas de interação por voz, desde os mecanismos tradicionais de ativação baseados em *wake-words* até as abordagens emergentes de Detecção de Fala Direcionada ao Dispositivo (do inglês *Device-Directed Speech Detection*, referida pela sigla DDSD). Os fundamentos técnicos são então aprofundados, com ênfase na arquitetura Transformer, nos modelos de linguagem pré-treinados para o português brasileiro e nas métricas de avaliação. Por fim, analisam-se os trabalhos mais diretamente relacionados ao tema, identificando lacunas que esta pesquisa busca preencher.

2.1 Metodologia da pesquisa bibliográfica

Figura 3 – Fluxo de seleção de estudos para a revisão bibliográfica.



Fonte: Elaborado pelo autor (2026).

A pesquisa bibliográfica foi conduzida de forma estruturada com o objetivo de identificar trabalhos científicos relevantes sobre detecção de intenção em linguagem natural, assistentes

virtuais baseados em voz, DDS D e técnicas de aprendizado de máquina aplicadas ao reconhecimento e classificação de comandos de voz.

Foram consultadas bases de dados acadêmicas amplamente utilizadas na área de Computação, incluindo Google Scholar, Semantic Scholar, arXiv, IEEE Xplore e ACM Digital Library. Essas plataformas foram selecionadas por concentrarem artigos científicos, pré-publicações e trabalhos revisados por pares com abrangência nas áreas de processamento de fala, linguagem natural e aprendizado de máquina.

As buscas utilizaram combinações de palavras-chave em inglês, tais como: “*voice assistant*”, “*device-directed speech detection*”, “*intent detection*”, “*keyword spotting*”, “*implicit intent*”, “*wake-word*”, “*false trigger mitigation*”, “*natural language understanding*” e “*voice command classification*”. Essas expressões foram combinadas por meio de operadores booleanos (AND, OR) para ampliar ou restringir os resultados conforme necessário.

Como critérios de inclusão, foram considerados: (a) trabalhos publicados entre 2021 e 2026; (b) disponibilidade nos idiomas inglês ou português; (c) relação direta com o problema de pesquisa, priorizando-se artigos que apresentassem experimentos, métodos de classificação ou avaliações de sistemas de interação por voz. Como exceção, foram incluídos artigos seminais anteriores ao período definido, por representarem contribuições fundamentais para a área, como os trabalhos sobre a arquitetura Transformer (VASWANI et al., 2017) e o BERT (DEVLIN et al., 2019).

Como critérios de exclusão, foram desconsiderados: (a) trabalhos publicados antes de 2021, exceto os seminais; (b) artigos sem relação direta com detecção de intenção, DDS D ou classificação de comandos de voz; (c) trabalhos duplicados entre as bases consultadas.

O processo de seleção ocorreu em duas etapas, conforme ilustrado na Figura 3. Na triagem inicial, foram identificados 118 artigos potencialmente relevantes com base na leitura de título e resumo. Na etapa de afunilamento, a análise em maior profundidade resultou na seleção de 27 trabalhos para compor a fundamentação teórica, os trabalhos relacionados e as referências deste estudo. Adicionalmente, foram incluídos 7 artigos seminais anteriores a 2021, entre os quais se destacam os trabalhos sobre a arquitetura Transformer (VASWANI et al., 2017), o BERT (DEVLIN et al., 2019), o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e os primeiros estudos de DDS D (MALLIDI et al., 2018; NOROUZIAN et al., 2019). Dessa forma, o conjunto final de referências selecionadas para este trabalho foi composto por 34 artigos.

2.2 Referencial teórico

O referencial teórico apresenta os conceitos que sustentam este trabalho, estabelecendo um contraponto entre o modelo predominante de interação com assistentes virtuais baseado em comandos explícitos (*wake-words*) e a busca por interações mais naturais por meio da DDS D. A organização dos tópicos segue o fluxo típico de processamento de um assistente

virtual baseado em voz, desde a captura e identificação da fala destinada ao sistema, passando pela transcrição do áudio, até a compreensão semântica da intenção do usuário.

2.2.1 Assistentes virtuais e interação por voz

A evolução da Interação Humano-Computador (conhecida por HCI, do inglês *Human-Computer Interaction*) tem avançado das interfaces puramente gráficas e táteis em direção a interfaces conversacionais e ubíquas. Nesse contexto, os assistentes virtuais baseados em voz consolidaram-se como agentes computacionais capazes de interpretar linguagem natural, processar requisições e executar tarefas automatizadas, mediando a relação entre o usuário e ecossistemas de serviços digitais.

De acordo com [Jurafsky e Martin \(2024\)](#), assistentes virtuais são sistemas que integram tecnologias de ASR (Reconhecimento Automático de Fala, do inglês *Automatic Speech Recognition*), Compreensão de Linguagem Natural (NLU, do inglês *Natural Language Understanding*) e Síntese de Fala (TTS, do inglês *Text-to-Speech*) para viabilizar interações fluidas entre humanos e dispositivos. O funcionamento típico segue um *pipeline* sequencial: (i) captura do sinal de áudio; (ii) Detecção de Atividade de Voz (VAD, do inglês *Voice Activity Detection*); (iii) ASR; (iv) NLU; e (v) geração da resposta ou execução da ação solicitada.

Na maioria dos sistemas comerciais, essas etapas são precedidas por um módulo de detecção de *wake-word*, que atua como gatilho para iniciar o processamento mais custoso ([GARG et al., 2021](#)). Essa arquitetura permite que o assistente permaneça em modo de baixo consumo até ser explicitamente invocado. A relevância dessas tecnologias é corroborada pelo crescimento acelerado do mercado global de assistentes de voz, conforme apresentado no Capítulo 1 ([Next Move Strategy Consulting, 2025](#)).

A eficácia da interação, no entanto, depende da capacidade do sistema de identificar quando sua intervenção é solicitada. Em ambientes cotidianos, onde a fala humana é simultaneamente direcionada a outras pessoas e a dispositivos, surge o desafio de distinguir intenções implícitas, tema central deste trabalho.

2.2.2 Detecção de Atividade de Voz (VAD)

A Detecção de Atividade de Voz (VAD) é a primeira etapa de processamento após a captura do áudio, sendo responsável por identificar os segmentos do sinal que contêm fala humana e separá-los de trechos de silêncio, ruído de fundo e sons não verbais ([LI et al., 2021](#)). Ao descartar trechos sem fala, o VAD reduz o volume de dados processado pelos módulos subsequentes (ASR e NLU), diminuindo o consumo computacional e a latência, aspectos críticos em dispositivos embarcados e de borda.

Em ambientes controlados, a tarefa é relativamente simples, baseada em limiares de energia ou características acústicas tradicionais. Em cenários reais, a robustez torna-

se um desafio, e modelos baseados em aprendizado profundo têm alcançado resultados superiores (LI et al., 2021). A qualidade da detecção impacta diretamente as etapas posteriores do *pipeline*. Um VAD muito permissivo gera ativações desnecessárias, enquanto um VAD restritivo demais pode descartar falas relevantes. Dessa forma, o equilíbrio entre sensibilidade e especificidade constitui um aspecto importante para o desempenho de assistentes de voz. Embora o VAD esteja fora do escopo de implementação deste trabalho, seu papel como pré-requisito funcional do *pipeline* justifica sua menção no referencial.

2.2.3 Reconhecimento Automático de Fala (ASR)

O Reconhecimento Automático de Fala (ASR) consiste na conversão de um sinal de áudio contendo fala humana em texto legível por máquina (JURAFSKY; MARTIN, 2024). No contexto de assistentes virtuais, o ASR atua como ponte entre o processamento do sinal acústico e os módulos de compreensão semântica.

Historicamente, os sistemas de ASR baseavam-se em abordagens híbridas que combinavam Modelos de Markov Ocultos (HMM, do inglês *Hidden Markov Models*) com modelos de linguagem estatísticos (JURAFSKY; MARTIN, 2024). Essas abordagens dominaram a área por décadas, mas apresentavam limitações na modelagem de dependências temporais longas e no aproveitamento de grandes volumes de dados. A partir da década de 2010, o aprendizado profundo trouxe avanços significativos, inicialmente com redes recorrentes (RNN, LSTM) e convolucionais, e posteriormente com a arquitetura Transformer (VASWANI et al., 2017), que permitiu saltos expressivos de desempenho. Modelos contemporâneos, como o Whisper (RADFORD et al., 2023), atingiram robustez elevada em múltiplos idiomas ao serem treinados com supervisão fraca em corpora massivos. Os detalhes técnicos do Whisper e de outros modelos de ASR empregados neste trabalho são apresentados na Seção 2.3.

A qualidade dos sistemas de ASR é comumente mensurada pela métrica *Word Error Rate* (traduzida como Taxa de Erro de Palavras, referenciada pela sigla WER), que calcula a proporção de palavras erradas, substituídas, deletadas ou inseridas em relação a uma transcrição de referência. Em aplicações de assistentes virtuais, erros de transcrição propagam-se diretamente para as etapas de classificação de intenção, o que torna o WER um indicador relevante para o desempenho final do sistema.

2.2.4 Wake-words: mecanismo, vantagens e limitações

As *wake-words* (também denominadas *hotwords* ou palavras de ativação) constituem o mecanismo predominante de ativação em assistentes virtuais comerciais. Trata-se de expressões pré-definidas, tais como “Hey Siri”, “Alexa”, “Ok Google” e “Hey Bixby”, que funcionam como gatilho para despertar o sistema do estado de espera e iniciar o processamento da solicitação do usuário (GARG et al., 2021).

Do ponto de vista técnico, a detecção de *wake-words* é realizada por um módulo de *keyword spotting* que opera continuamente no dispositivo com consumo energético reduzido. Esse módulo permanece ativo mesmo quando os componentes mais custosos do *pipeline* (ASR e NLU) estão inativos, ativando-os somente após a detecção positiva da palavra de ativação (GARG et al., 2021; KUNDU et al., 2023).

Essa abordagem oferece vantagens relevantes. Do ponto de vista energético, é eficiente e adequada para dispositivos alimentados por bateria (SHIN, 2023). Contribui também para a preservação da privacidade, uma vez que o processamento em nuvem só é iniciado após a ativação explícita (NIE et al., 2021). Além disso, minimiza o processamento desnecessário de áudio ambiente.

No entanto, o mecanismo de *wake-words* apresenta limitações. Do ponto de vista da HCI, impõe um padrão rígido e artificial de comunicação que contrasta com a naturalidade do diálogo humano (NIE et al., 2021). Uma vulnerabilidade técnica relevante é o fenômeno *FakeWake*, em que expressões foneticamente semelhantes à *wake-word* ativam inadvertidamente o sistema. Chen et al. (2021) desenvolveram um gerador automático de *fuzzy words* capaz de produzir 965 expressões que acionavam indevidamente oito dos principais assistentes do mercado, comprometendo usabilidade e privacidade.

Para mitigar os falsos gatilhos, foram propostas técnicas de mitigação de falsos acionamentos (FTM, do inglês *False Trigger Mitigation*). Garg et al. (2021) apresentaram uma arquitetura baseada em Transformer com processamento em fluxo contínuo, capaz de suprimir até 95% dos falsos positivos utilizando apenas um segundo de áudio contextual após a ativação. Apesar dos avanços, essas soluções adicionam complexidade ao sistema e não eliminam a necessidade de uma ativação explícita inicial, motivando o desenvolvimento de alternativas como a DDS.

2.2.5 Detecção de Fala Direcionada ao Dispositivo (DDSD)

A Detecção de Fala Direcionada ao Dispositivo (DDSD) é definida como a tarefa de classificação binária que visa determinar automaticamente se um enunciado é intencionalmente direcionado a um assistente virtual ou se faz parte de uma conversa incidental entre humanos (MALLIDI et al., 2018; WAGNER et al., 2024).

Diferentemente do mecanismo de *wake-words*, a DDS busca permitir interações mais naturais, aproximando a comunicação humano-computador do padrão conversacional humano e superando as limitações de rigidez e fricção cognitiva discutidas na subseção anterior (NIE et al., 2021).

As pesquisas na área têm evoluído em duas frentes: abordagens multimodais e abordagens unimodais (baseadas em áudio ou texto). As soluções multimodais combinam informações acústicas, textuais, prosódicas e, em alguns casos, visuais. Wagner et al. (2024) demonstraram que a fusão de características acústicas, hipóteses do decodificador ASR e representações textuais processadas por LLMs (Modelos de Linguagem de Grande Porte,

do inglês *Large Language Models*) pode reduzir a taxa de erro em até 61% frente a modelos unimodais. Krishna et al. (2023) exploraram a combinação de características verbais com informações prosódicas não verbais (entonação, ritmo e pausas), obtendo melhorias na taxa de falsa aceitação. Em outra vertente, Nie et al. (2021) propuseram um sistema multimodal integrando informações visuais (detecção facial e rastreamento labial) com características acústicas. Do ponto de vista exclusivamente acústico, Norouzia et al. (2019) investigaram o uso de mecanismos de atenção para classificar enunciados como dirigidos ou não ao sistema, evidenciando o potencial de *features* espectrais combinadas com redes neurais de atenção.

Embora as abordagens multimodais obtenham melhor desempenho em cenários complexos, demandam maior poder computacional, sincronização precisa entre modalidades e grandes volumes de dados anotados multimodalmente, o que limita sua viabilidade em dispositivos com recursos restritos (WAGNER et al., 2024).

Nesse contexto, abordagens baseadas exclusivamente em texto, que utilizam transcrições geradas por ASR como entrada, têm sido exploradas como alternativa viável na literatura recente, embora permaneçam menos estudadas do que as soluções acústicas e multimodais. Essas soluções oferecem maior simplicidade arquitetural, modularidade e interpretabilidade, especialmente em idiomas com poucos recursos anotados, como o português brasileiro. Estudos recentes demonstram que as representações textuais extraídas de hipóteses ASR contêm sinal discriminativo relevante para a detecção de intenção implícita (DIGHE et al., 2024; WAGNER et al., 2024).

2.2.6 Processamento de Linguagem Natural e classificação de intenção

O Processamento de Linguagem Natural (do inglês *Natural Language Processing*, referido pela sigla NLP) compreende o conjunto de técnicas computacionais destinadas à análise, compreensão e geração de linguagem humana em formato textual (JURAFSKY; MARTIN, 2024). No contexto de assistentes virtuais, a subárea de Compreensão de Linguagem Natural (NLU) é responsável por extrair o significado semântico e a intenção do usuário a partir das transcrições geradas pelo ASR (WELD et al., 2022).

Dado um enunciado do usuário, o objetivo é identificar a intenção subjacente, ou seja, qual ação o sistema deve realizar (WELD et al., 2022). Essa tarefa é frequentemente combinada com o preenchimento de *slots* (*slot filling*), responsável por extrair os parâmetros necessários para a execução da ação (ex.: “Defina um alarme para as 8 horas” → intenção: “criar alarme”; slot: horário = “8 horas”).

Historicamente, os sistemas de classificação de intenção baseavam-se em regras manuais e padrões lexicais. Métodos estatísticos, como Máquinas de Vetores de Suporte (SVM), tornaram-se predominantes na sequência (MANNING; RAGHAVAN; SCHÜTZE, 2008). Foi, contudo, a partir da introdução da arquitetura Transformer (VASWANI et al., 2017) e, especialmente, do modelo BERT (DEVLIN et al., 2019) que a área experimentou

avanço expressivo. Em levantamento abrangente, [Weld et al. \(2022\)](#) concluem que modelos pré-treinados baseados em Transformers superam consistentemente abordagens anteriores em tarefas de detecção de intenção, tanto em precisão quanto em generalização.

A principal vantagem dos modelos pré-treinados reside na capacidade de realizar *fine-tuning* com quantidades relativamente pequenas de dados rotulados ([DEVLIN et al., 2019](#)), característica particularmente atrativa para idiomas com poucos recursos linguísticos. A classificação de intenção constitui o núcleo da abordagem textual proposta para a DDS, a partir das transcrições geradas pelo ASR, o sistema busca identificar se o enunciado carrega uma intenção direcionada ao dispositivo, mesmo na ausência de *wake-words* explícitas.

2.2.7 Modelos baseados em Transformers

A arquitetura Transformer, proposta por [Vaswani et al. \(2017\)](#), representou um dos principais marcos do NLP ao substituir recorrência e convoluções pelo mecanismo de *atenção multi-cabeça* como principal componente para modelar dependências em sequências textuais. A partir dessa arquitetura, [Devlin et al. \(2019\)](#) propuseram o BERT (*Bidirectional Encoder Representations from Transformers*), que introduziu o pré-treinamento bidirecional profundo e demonstrou ganhos expressivos em diversas tarefas de compreensão textual. O detalhamento técnico dessas arquiteturas, incluindo as formulações matemáticas do mecanismo de atenção e o processo de *fine-tuning*, é apresentado na Seção 2.3.

No contexto do português brasileiro, [Souza, Nogueira e Lotufo \(2020\)](#) desenvolveram o BERTimbau, versão do BERT pré-treinada especificamente para o idioma, com resultados superiores aos modelos multilíngues em tarefas como classificação textual e reconhecimento de entidades. Modelos mais recentes, como a DeBERTinha ([ABONIZIO et al., 2023](#)) e a Albertina ([RODRIGUES et al., 2023](#)), introduziram variantes com diferentes compromissos entre eficiência computacional e desempenho. Esses modelos são detalhados na Seção 2.3 e constituem as opções de classificadores investigadas neste trabalho.

2.3 Fundamentos

Esta seção detalha as tecnologias, algoritmos e metodologias específicas que serão empregadas no desenvolvimento da solução proposta. Diferentemente do referencial teórico, que contextualiza os conceitos gerais da área, os fundamentos aprofundam os aspectos técnicos diretamente utilizados na implementação.

2.3.1 Arquitetura Transformer

A arquitetura Transformer, introduzida por [Vaswani et al. \(2017\)](#), eliminou a dependência de recorrência e convoluções, substituindo-as pelo mecanismo de atenção como principal componente para modelagem de sequências. Diferentemente das RNNs (Redes

Neurais Recorrentes, do inglês *Recurrent Neural Networks*), que processam sequências de forma sequencial, o Transformer processa todos os elementos da entrada simultaneamente, permitindo alto grau de paralelização. Embora variantes como LSTM (Memória de Longo e Curto Prazo, do inglês *Long Short-Term Memory*) e GRU (Unidade Recorrente com Portão, do inglês *Gated Recurrent Unit*) atenuem parcialmente o problema de dissipação de gradientes das RNNs tradicionais, essas arquiteturas ainda enfrentam limitações em dependências muito longas, que o Transformer supera por construção (VASWANI et al., 2017).

O componente central é o mecanismo de *Self-Attention*. Para cada token da sequência, o modelo calcula três vetores: *Query* (Q), *Key* (K) e *Value* (V). A atenção é obtida por:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

onde d_k é a dimensão dos vetores de chave. Essa operação permite que cada token pondere a importância de todos os demais tokens da sequência. O fator de escala $\sqrt{d_k}$ estabiliza os gradientes durante o treinamento.

Para aumentar a capacidade representacional, Vaswani et al. (2017) propuseram o *Multi-Head Attention*, que executa o mecanismo de atenção em paralelo h vezes (tipicamente 8 ou 16 cabeças), cada uma com projeções lineares independentes de Q, K e V. As saídas são concatenadas e projetadas linearmente, permitindo que o modelo capture diferentes tipos de relações semânticas e sintáticas em uma mesma camada.

Como o Transformer não possui recorrência, é necessário injetar informação posicional por meio do *Positional Encoding*. Os autores utilizaram funções seno e cosseno de diferentes frequências:

$$PE_{(pos, 2i)} = \sin \left(\frac{pos}{10000^{2i/d_{model}}} \right), \quad PE_{(pos, 2i+1)} = \cos \left(\frac{pos}{10000^{2i/d_{model}}} \right)$$

Esses valores são somados aos *embeddings* dos tokens de entrada, fornecendo informação explícita sobre a ordem dos elementos.

A arquitetura completa é composta por blocos de *Encoder* e *Decoder*. Cada bloco do Encoder contém uma camada de Multi-Head Self-Attention seguida de uma rede *feed-forward* posicionada (duas camadas lineares com ativação ReLU). O Decoder possui uma camada adicional de *Cross-Attention* que recebe as saídas do Encoder. Conexões residuais e normalização de camada (*layer normalization*) são aplicadas em torno de cada subcamada, facilitando o treinamento de redes profundas.

Para ilustrar: na frase “O gato está no tapete”, o token “tapete” deve apresentar forte atenção com “gato” para capturar a relação semântica. Enquanto RNNs tradicionais processam a frase de forma sequencial, com dificuldade crescente para reter contextos distantes, mesmo com mecanismos de *gating*, o Transformer relaciona “tapete” diretamente com “gato” em uma única passada, independentemente da distância entre eles.

A arquitetura serviu de base para modelos como BERT (apenas Encoder), GPT (apenas Decoder) e T5 (Encoder-Decoder), consolidando-se como o alicerce dos modernos Modelos de Linguagem de Grande Porte (LLMs).

2.3.2 BERT e o mecanismo de fine-tuning

O modelo BERT (*Bidirectional Encoder Representations from Transformers*), proposto por [Devlin et al. \(2019\)](#), introduziu o conceito de pré-treinamento bidirecional profundo. Diferentemente dos modelos anteriores, que processavam o texto de forma unidirecional, o BERT considera o contexto completo de cada palavra, analisando simultaneamente os tokens à esquerda e à direita.

O pré-treinamento ocorre por meio de duas tarefas em grandes corpora não anotados:

1. **Masked Language Modeling (MLM)**: 15% dos tokens da entrada são aleatoriamente mascarados, e o modelo deve prever o token original com base no contexto bidirecional. Na frase “O [MASK] está no tapete”, o modelo aprende a prever “gato” considerando tanto o contexto anterior quanto o posterior.
2. **Next Sentence Prediction (NSP)**: o modelo recebe pares de sentenças e deve identificar se a segunda é a continuação lógica da primeira, desenvolvendo compreensão de relações discursivas e coerência textual.

Após o pré-treinamento, o BERT pode ser adaptado para tarefas específicas por meio de *fine-tuning*. Nesse estágio, o modelo é inicializado com os pesos pré-treinados e continua o treinamento em um conjunto de dados menor e rotulado. Uma camada de classificação é adicionada sobre a representação do token especial [CLS], que concentra informações de toda a sequência ([DEVLIN et al., 2019](#)). Os pesos das camadas anteriores também são atualizados, permitindo que as representações internas se ajustem à tarefa em questão.

Uma das vantagens do *fine-tuning* é a necessidade de relativamente poucos dados rotulados e poucas épocas de treinamento. [Devlin et al. \(2019\)](#) demonstraram que, com essa abordagem, o BERT superou o estado da arte em 11 tarefas de NLP, incluindo os *benchmarks* GLUE, SQuAD e SWAG.

Na classificação de intenção, o processo é direto: a última camada é substituída por uma camada linear com *softmax*, e o modelo é treinado minimizando a perda de entropia cruzada. Essa abordagem será aplicada sobre o BERTimbau para especializá-lo na tarefa de DDS em português brasileiro.

2.3.3 BERTimbau: BERT para o português brasileiro

O BERTimbau, proposto por [Souza, Nogueira e Lotufo \(2020\)](#), é a versão do BERT pré-treinada especificamente para o português brasileiro. Seu desenvolvimento partiu da

constatação de que modelos multilíngues, apesar do bom desempenho geral, apresentam limitações quando aplicados a idiomas com características morfosintáticas e vocabulário específicos.

O modelo foi pré-treinado em um corpus de aproximadamente 2,7 bilhões de tokens, composto por textos da Wikipédia em português e pelo corpus brWaC (*Brazilian Web as Corpus*). Foram disponibilizadas duas versões: BERTimbau Base (12 camadas, 110 milhões de parâmetros) e BERTimbau Large (24 camadas, 335 milhões de parâmetros) (SOUZA; NOGUEIRA; LOTUFO, 2020).

O pré-treinamento seguiu a mesma metodologia do BERT original (MLM e NSP), porém, por ter sido treinado exclusivamente com dados em português brasileiro, o modelo desenvolveu representações mais adequadas às particularidades do idioma, tais como conjugações verbais complexas, artigos definidos e contrações comuns (“do”, “na”, “pelo”).

Souza, Nogueira e Lotufo (2020) realizaram avaliação abrangente comparando o BERTimbau com o BERT multilíngue (mBERT) em diversas tarefas de NLP para o português. Os resultados demonstraram superioridade consistente do BERTimbau, com diferenças superiores a 5 pontos percentuais em alguns *benchmarks*, incluindo Reconhecimento de Entidades Nomeadas, Similaridade Semântica e Classificação Textual. A disponibilidade do BERTimbau reduziu a barreira de entrada para pesquisadores e desenvolvedores que anteriormente dependiam de modelos multilíngues com desempenho subótimo ou de treinamentos do zero.

2.3.4 DeBERTa, DeBERTinha e Albertina PT-BR

Embora o BERT tenha estabelecido um novo patamar para modelos de linguagem, arquiteturas subsequentes buscaram superar suas limitações, especialmente quanto à representação de dependências sintáticas e à eficiência computacional. Destaca-se a família DeBERTa (*Decoding-enhanced BERT with Disentangled Attention*), proposta por He et al. (2021).

A principal inovação do DeBERTa é o mecanismo de atenção desentrelada (*Disentangled Attention*). Enquanto o BERT representa cada token por um único vetor que combina informação de conteúdo e posição, o DeBERTa separa essas dimensões. Para cada par de tokens, a atenção é calculada considerando conteúdo e posição relativa de forma independente, o que permite modelagem mais precisa de relações sintáticas. Além disso, o DeBERTa utiliza um decodificador aprimorado (*enhanced mask decoder*) durante o pré-treinamento (HE et al., 2021).

No contexto brasileiro, Abonizio et al. (2023) desenvolveram a **DeBERTinha**, uma versão compacta adaptada a partir do DeBERTaV3 XSmall para o português brasileiro. O modelo passou por adaptação contínua (*continual pre-training*) em grandes corpora nacionais, incluindo o brWaC. Apesar de possuir cerca de 70 milhões de parâmetros, a

DeBERTinha demonstrou desempenho competitivo com o BERTimbau em várias tarefas de NLP, com vantagem em eficiência computacional.

Outra iniciativa relevante é a família **Albertina PT-BR**, desenvolvida por [Rodrigues et al. \(2023\)](#). Construída sobre a arquitetura DeBERTaV2, a Albertina foi pré-treinada com dados em português em diferentes escalas de modelo. Os autores enfatizaram a qualidade dos dados de pré-treinamento e técnicas avançadas de tokenização, alcançando resultados competitivos em tarefas de entendimento de linguagem em português.

2.3.5 Modelos baseline: TF-IDF, SVM e Regressão Logística

Na classificação textual, é prática comum utilizar modelos mais simples e interpretáveis como *baselines* para comparação com abordagens de *deep learning*. Foram selecionados três componentes clássicos: TF-IDF para representação vetorial, combinado com SVM e Regressão Logística como classificadores.

A Frequência do Termo-Inverso da Frequência nos Documentos (TF-IDF, do inglês *Term Frequency-Inverse Document Frequency*) é uma das técnicas mais tradicionais de representação vetorial de texto ([MANNING; RAGHAVAN; SCHÜTZE, 2008](#)). Atribui pesos às palavras considerando a frequência do termo no documento (TF) e a raridade do termo na coleção (IDF):

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{\text{DF}(t) + 1} \right)$$

onde t é o termo, d é o documento, N é o número total de documentos e $\text{DF}(t)$ é o número de documentos que contêm t . Essa ponderação reduz o peso de termos comuns e aumenta o peso de termos discriminativos.

As Máquinas de Vetores de Suporte (SVM), propostas por [Cortes e Vapnik \(1995\)](#), buscam o hiperplano que maximiza a margem de separação entre as classes. Em problemas não linearmente separáveis, o truque do kernel (*kernel trick*) mapeia os dados para um espaço de maior dimensionalidade onde a separação linear se torna possível. Na classificação binária de DDSD ($\text{DD} \times \text{NDD}$), o SVM busca maximizar a distância entre os vetores TF-IDF das duas classes.

A Regressão Logística modela a probabilidade de uma classe binária por meio da função sigmoide:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

Apesar de ser um modelo linear, a Regressão Logística frequentemente obtém bom desempenho em classificação textual quando combinada com TF-IDF, especialmente em conjuntos de dados de tamanho moderado ([MANNING; RAGHAVAN; SCHÜTZE, 2008](#)).

Ambos os classificadores são amplamente utilizados como *baselines* em pesquisas de NLP por serem eficientes, interpretáveis e constituírem referência sólida para aferir o ganho

real obtido por modelos mais complexos. Embora modelos neurais profundos geralmente os superem em grandes conjuntos de dados, a diferença pode ser reduzida em corpora de tamanho moderado (WELD et al., 2022). A comparação entre os *baselines* TF-IDF+SVM e TF-IDF+LR com o classificador BERTimbau permitirá quantificar objetivamente o ganho da abordagem baseada em Transformer na tarefa de DDS.

2.3.6 ASR com Whisper

O Whisper é um modelo de ASR de grande escala desenvolvido pela OpenAI (RADFORD et al., 2023). Diferentemente da maioria dos sistemas tradicionais, treinados com supervisão forte em conjuntos relativamente pequenos e limpos, o Whisper foi treinado com supervisão fraca em um corpus de aproximadamente 680 mil horas de áudio multilíngue coletado da web. Essa estratégia conferiu ao modelo alta robustez e capacidade de generalização.

Arquiteturalmente, o Whisper segue o padrão Encoder-Decoder baseado em Transformer. O *encoder* processa o espectrograma log-Mel do áudio de entrada, gerando representações contextuais. O *decoder*, autoregressivo, gera o texto transcrito token a token, podendo também realizar tarefas como tradução de fala e identificação de idioma por meio de *prompts* especiais (RADFORD et al., 2023).

Em 2024, a OpenAI lançou versões aprimoradas, com destaque para o Whisper Large V3 Turbo. Essa versão reduz o número de camadas do *decoder* de 32 para 4, mantendo desempenho próximo ao modelo completo com ganho de velocidade de inferência de cerca de 6 vezes, tornando-o mais viável para aplicações em tempo real (JEFFRIES et al., 2024; BEVILACQUA et al., 2024).

Entre as vantagens do Whisper para este trabalho destacam-se o bom desempenho em português brasileiro, a robustez a ruídos ambientais e a capacidade nativa de identificação de idioma. As transcrições geradas servirão de entrada para o classificador textual de DDS. Experimentos no TCC2 incluirão a comparação entre diferentes tamanhos de modelo (Medium, Large V3 e Turbo) e a análise da relação entre o WER do ASR e o desempenho do classificador.

Embora o Whisper represente o estado da arte em ASR multilíngue, erros de transcrição podem ocorrer, especialmente em ambientes ruidosos ou com vocabulário incomum. A avaliação do impacto desses erros sobre a detecção de intenção implícita constitui um dos objetivos específicos deste trabalho.

2.3.7 Métricas de avaliação

A avaliação de modelos de classificação em tarefas de DDS requer métricas que analisem não apenas a acurácia geral, mas também o equilíbrio entre erros de falso positivo

e falso negativo. Serão utilizadas métricas tradicionais de classificação binária e métricas específicas da área.

A **Acurácia** (*Accuracy*) mede a proporção de classificações corretas em relação ao total de amostras. Embora intuitiva, pode ser enganosa em conjuntos desbalanceados, situação comum em DDSD, onde falas não direcionadas ao dispositivo geralmente são mais frequentes (MANNING; RAGHAVAN; SCHÜTZE, 2008).

A **Precisão** (*Precision*) indica a proporção de exemplos classificados como positivos que são realmente positivos. Representa, neste contexto, a proporção de falas classificadas como direcionadas ao dispositivo que efetivamente o eram. É especialmente relevante quando o custo de falsos positivos (ativações indesejadas) é alto (WELD et al., 2022).

A **Sensibilidade** (*Recall*) mede a proporção de exemplos positivos corretamente identificados. Um *recall* baixo indica que muitas intenções do usuário estão sendo perdidas (WELD et al., 2022).

O **F1-Score** representa a média harmônica entre Precisão e Sensibilidade:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

No cenário de DDSD, o F1-Score é uma das métricas principais, pois reflete o compromisso entre ativações corretas e ativações indevidas.

A **Taxa de Erro Igual** (EER, do inglês *Equal Error Rate*) corresponde ao ponto na curva ROC onde a taxa de falsos positivos iguala a taxa de falsos negativos. Quanto menor o EER, melhor o desempenho do sistema. Wagner et al. (2024) e Krishna et al. (2023) utilizam o EER como métrica principal em seus trabalhos, por ser robusta e independente do *threshold* de decisão.

Será calculada também a **Área sob a Curva ROC (ROC-AUC)**, que avalia a capacidade discriminativa do modelo em diferentes *thresholds*. Por fim, como o sistema proposto utiliza transcrições de ASR, o impacto da qualidade da transcrição será analisado por meio da **Word Error Rate (WER)**. Estudos demonstram correlação direta entre o WER do ASR e a degradação do desempenho do classificador textual (DIGHE et al., 2024).

A combinação dessas métricas permite avaliação multidimensional: acurácia geral, equilíbrio entre precisão e *recall*, robustez a variações de *threshold* (EER) e sensibilidade à qualidade da transcrição (WER). Todas serão calculadas com validação cruzada e conjuntos de teste separados, assegurando maior confiabilidade dos resultados.

2.4 Trabalhos relacionados

Nesta seção, são apresentados e discutidos os principais estudos sobre DDSD, selecionados a partir da metodologia descrita na Seção 2.1.

Os trabalhos foram selecionados segundo dois critérios centrais: (i) abordagem direta do problema de DDS ou de tarefa funcionalmente equivalente, isto é, a classificação automática de enunciados como dirigidos ou não a um sistema computacional, e (ii) uso de componente textual ou acústico relevante para a classificação de intenção. Trabalhos que tratam apenas de ASR, VAD, *keyword spotting* clássico ou classificação de intenção em domínios distintos foram excluídos, pois não compartilham o problema central investigado neste TCC (WAZLAWICK, 2020).

Com base nesses critérios, três trabalhos foram selecionados como relacionados principais. O primeiro, de Mallidi et al. (2018), estabelece as bases conceituais e experimentais da DDS. O segundo, de Wagner et al. (2024), foi selecionado por representar uma das abordagens multimodais mais recentes encontradas na literatura revisada. O terceiro, de Dighe et al. (2024), é o trabalho metodologicamente mais próximo desta proposta, por demonstrar que modelos de linguagem aplicados sobre saídas textuais de ASR geram sinal discriminativo suficiente para a detecção de intenção. A análise crítica desses três estudos, conduzida nas subseções seguintes, permite identificar as lacunas que este trabalho busca preencher.

2.4.1 Mallidi et al. (2018)

O trabalho de Mallidi et al. (2018), intitulado *Device-directed Utterance Detection*, é considerado o estudo pioneiro na área de DDS. Publicado nos anais do *Interspeech* em 2018, foi o primeiro a formalizar o problema como tarefa independente de classificação binária, estabelecendo a terminologia, o protocolo experimental e as métricas adotados por estudos posteriores (MALLIDI et al., 2018; WAGNER et al., 2024).

O problema parte de uma constatação prática: em ambientes domésticos com assistentes sempre ligados, parcela significativa das falas captadas não é dirigida ao dispositivo. Ativar o *pipeline* completo (ASR, NLU e geração de resposta) para cada trecho de fala detectado pelo VAD resultaria em alto consumo computacional, degradação da privacidade e comprometimento da experiência do usuário (MALLIDI et al., 2018). A proposta foi inserir um módulo intermediário entre VAD e ASR, capaz de filtrar automaticamente as falas não dirigidas ao dispositivo.

A abordagem é inteiramente baseada em características acústicas extraídas do sinal de áudio, sem depender de transcrições textuais. Os autores utilizaram coeficientes cepstrais de frequência de Mel (MFCCs), *pitch*, energia e características prosódicas como duração de pausas e velocidade de fala, alimentando um modelo de classificação baseado em Redes Neurais *Feed-Forward* treinado de forma supervisionada (MALLIDI et al., 2018).

Os experimentos foram conduzidos em um corpus interno, coletado em cenários reais de uso doméstico em inglês. Os autores reportaram uma EER de aproximadamente 12% em condições controladas. Um achado relevante foi que características prosódicas, entonação

e duração de pausas, exercem papel discriminativo importante para separar comandos intencionais de comentários incidentais (MALLIDI et al., 2018).

Além da contribuição técnica, Mallidi et al. (2018) argumentaram que a dependência de *wake-words* impõe sobrecarga cognitiva artificial ao usuário, fundamentando a necessidade de sistemas capazes de detectar intenção implícita. Esse argumento tornou-se referência recorrente em trabalhos posteriores (NIE et al., 2021; WAGNER et al., 2024).

Apesar do pioneirismo, o trabalho apresenta limitações à luz do estado da arte atual. A abordagem puramente acústica não explora informações textuais ou semânticas, restringindo sua capacidade discriminativa em cenários onde a distinção entre comando e comentário depende do conteúdo linguístico. Os enunciados “acende a luz” e “nossa, está escuro aqui”, por exemplo, podem apresentar padrões prosódicos semelhantes, mas são semanticamente distintos. Adicionalmente, os experimentos foram realizados exclusivamente em inglês e com corpus proprietário (WAGNER et al., 2024; DIGHE et al., 2024).

Para este trabalho, a contribuição de Mallidi et al. (2018) é fundamental do ponto de vista conceitual, a formalização do problema como classificação binária, a definição das classes (DD *versus* NDD) e o uso do EER como métrica principal são elementos diretamente adotados nesta pesquisa. A abordagem técnica, contudo, segue direção oposta, enquanto Mallidi et al. (2018) operam no domínio acústico, este trabalho opera exclusivamente no domínio textual.

2.4.2 Wagner et al. (2024)

O trabalho de Wagner et al. (2024), intitulado *A Multimodal Approach to Device-Directed Speech Detection with Large Language Models*, publicado no IEEE *International Conference on Acoustics, Speech and Signal Processing* (ICASSP) em 2024, constitui um exemplo representativo das abordagens multimodais recentes para DDSD. O estudo propõe uma arquitetura que integra características acústicas do sinal de áudio, hipóteses intermediárias geradas pelo decodificador ASR e representações semânticas produzidas por LLMs.

A motivação parte de uma crítica às abordagens unimodais: sistemas baseados em áudio capturam informações prosódicas, mas carecem de compreensão semântica; sistemas baseados em texto capturam a semântica, mas ignoram pistas acústicas como entonação e ritmo. A fusão de modalidades permite explorar o sinal discriminativo presente em cada domínio de forma complementar (WAGNER et al., 2024).

O sistema adota fusão tardia (*late fusion*), cada modalidade é processada por um *encoder* independente, e as representações são combinadas para a classificação final. O componente textual utiliza representações geradas por um LLM a partir da transcrição 1-best do ASR. Um terceiro componente explora as hipóteses intermediárias do *beam search* do decodificador, a *n-best list* com respectivos escores de confiança, informação que

carrega a incerteza do modelo ASR e mostrou-se altamente informativa (WAGNER et al., 2024).

Os resultados são expressivos, o modelo multimodal alcançou redução de até 61% na EER em comparação com as melhores abordagens unimodais, demonstrando o valor da integração de modalidades. Os experimentos foram conduzidos em corpus interno de grande escala em inglês. Os autores demonstraram ainda que o componente textual, isoladamente, já contribui de forma significativa, evidência direta de que informações semânticas de transcrições ASR constituem sinal discriminativo relevante (WAGNER et al., 2024).

Embora os resultados sejam notáveis, a arquitetura multimodal exige alto poder computacional e sincronização precisa entre componentes. O uso de LLMs de grande escala impõe restrições de latência e custo operacional, dificultando a implantação em dispositivos com recursos limitados (XU et al., 2024). A abordagem foi desenvolvida e avaliada exclusivamente em inglês, com corpus proprietário (WAGNER et al., 2024).

Para este trabalho, o estudo cumpre dois papéis. Primeiro, fornece a evidência empírica mais robusta disponível de que representações textuais de hipóteses ASR contêm sinal discriminativo suficiente para a DDS, evidência que fundamenta diretamente a hipótese de pesquisa deste TCC. Segundo, estabelece o referencial de EER com o qual abordagens futuras poderão ser comparadas em caráter aproximado, respeitando diferenças de idioma, corpus e modalidade. A abordagem puramente textual proposta neste TCC pode ser entendida como a investigação isolada do componente que Wagner et al. (2024) identificaram como altamente discriminativo, aplicada ao português brasileiro com um modelo de linguagem adaptado ao idioma.

2.4.3 Dighe et al. (2024)

O trabalho de Dighe et al. (2024), intitulado *Leveraging Large Language Models for Exploiting ASR Uncertainty* também publicado no IEEE ICASSP em 2024, é o estudo metodologicamente mais próximo desta proposta. O artigo investiga o uso de LLMs para explorar a incerteza inerente às saídas de ASR em tarefas de *Spoken Language Understanding* (SLU), com ênfase na detecção de intenção.

A premissa central é que *pipelines* tradicionais de SLU tratam a saída do ASR como determinística, utilizando apenas a transcrição mais provável (1-best) como entrada para os módulos semânticos. Essa abordagem descarta informações valiosas geradas pelo *beam search*, particularmente as hipóteses alternativas que carregam a incerteza do reconhecedor de forma explícita. Os autores argumentam que LLMs são adequados para explorar essa incerteza, por possuírem a capacidade de raciocinar sobre múltiplas hipóteses textuais e selecionar a interpretação semanticamente mais plausível (DIGHE et al., 2024).

A metodologia consiste em fornecer ao LLM não apenas a transcrição 1-best, mas um conjunto de hipóteses ASR (*n-best list*) ordenadas por probabilidade. O LLM processa essas hipóteses e produz representação semântica que leva em conta a incerteza do ASR

ao classificar a intenção. Os experimentos demonstram ganhos consistentes em métricas de entendimento de intenção quando comparados a *pipelines* que utilizam apenas a transcrição 1-best (DIGHE et al., 2024).

Uma contribuição técnica relevante é demonstrar que modelos de linguagem pré-treinados atuam como segundo estágio de refinamento semântico após o ASR, compensando parcialmente erros de transcrição ao considerar a plausibilidade das hipóteses alternativas. Os autores sugerem, como direção futura, a análise sistemática da correlação entre o WER do ASR e a degradação do classificador de intenção, investigação que este TCC incorpora explicitamente como objetivo específico.

O estudo valida a viabilidade de arquiteturas em cascata (ASR $\rightarrow$ LLM) para compreensão de intenção em fala. Embora os experimentos tenham sido conduzidos em inglês, a metodologia é transferível para outros idiomas mediante modelos pré-treinados no idioma-alvo, que é precisamente a contribuição central deste TCC, ao aplicar uma arquitetura análoga com o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) para o português brasileiro.

Cabe observar que Dighe et al. (2024) utilizam LLMs de grande escala, o que implica custo computacional elevado e dependência de infraestrutura de nuvem. Este trabalho se diferencia ao propor o BERTimbau, modelo de menor escala, especificamente pré-treinado para o português brasileiro e viável para execução local, como classificador, tornando a abordagem mais acessível a cenários com recursos restritos (SOUZA; NOGUEIRA; LOTUFO, 2020; XU et al., 2024).

O trabalho de Dighe et al. (2024) cumpre papel duplo e fundamental para esta pesquisa. Primeiro, valida empiricamente que abordagens baseadas em texto extraído de ASR geram sinal discriminativo relevante para a detecção de intenção implícita, fortalecendo a escolha metodológica de operar no nível textual. Segundo, motiva e fundamenta o terceiro objetivo específico deste TCC, a análise da correlação entre WER e degradação do classificador no contexto do português brasileiro.

2.4.4 Síntese comparativa

A análise dos três trabalhos relacionados permite delinear o estado da arte em DDSD e identificar as lacunas que este TCC busca preencher. As Tabelas 2 e 3 sintetizam, respectivamente, as características técnicas dos trabalhos e o diferencial introduzido por esta proposta.

A Tabela 2 revela um padrão comum aos três estudos, foram desenvolvidos exclusivamente para o inglês, com corpora proprietários não disponibilizados publicamente, e nenhum adota *baselines* clássicos como referência. A ausência de *baselines* tradicionais é uma limitação metodológica, pois impede a quantificação do ganho real dos modelos neurais em relação a métodos mais simples e interpretáveis (MANNING; RAGHAVAN; SCHÜTZ, 2008; WELD et al., 2022).

Tabela 2 – Comparação técnica entre os trabalhos relacionados

Critério	Mallidi (2018)	Wagner (2024)	Dighe (2024)
Modalidade	Áudio	Áudio + Texto + ASR	Texto + ASR
Modelo principal	DNN <i>Feed-Forward</i>	LLM + fusão tardia	LLM (<i>n-best</i>)
Idioma	Inglês	Inglês	Inglês
Corpus	Interno	Interno	Interno
Métricas reportadas	EER	EER	F1, Acurácia
Baseline clássico	Não	Não	Não
Limitação central	Sem análise textual	Alto custo computacional	Apenas inglês

Fonte: Elaborado pelo autor (2026).

Tabela 3 – Diferencial deste TCC em relação aos trabalhos relacionados

Trabalho	Idioma	Modalidade	Corpus público	Baseline	Análise WER
Mallidi (2018)	Inglês	Áudio	Não	Não	Não
Wagner (2024)	Inglês	Multimodal	Não	Não	Não
Dighe (2024)	Inglês	Texto + ASR	Não	Não	Parcial
Este TCC	PT-BR	Texto puro	Sim	Sim	Sim

Fonte: Elaborado pelo autor (2026).

A Tabela 3 posiciona este TCC como contribuição original em quatro dimensões.

O primeiro diferencial é o idioma. Nenhum dos trabalhos aborda o português brasileiro, que permanece sub-representado na literatura de DDS em português brasileiro apesar de ser um dos idiomas mais falados do mundo (JUNIOR et al., 2023). O português brasileiro apresenta características morfosintáticas específicas, como pronomes clíticos, contrações e variação dialetal, que podem influenciar diretamente o desempenho de classificadores de intenção. A ausência de estudos de DDS em português constitui barreira prática para o desenvolvimento de assistentes de voz mais naturais para a população brasileira.

O segundo diferencial planejado é a construção e disponibilização pública de um corpus textual para DDS em português brasileiro. Os três trabalhos relacionados utilizam corpora internos e proprietários, o que impede a reprodutibilidade (WAZLAWICK, 2020). O corpus a ser produzido, com volume estimado em aproximadamente 105.000 amostras textuais, combinará transcrições de corpora públicos de fala espontânea (JUNIOR et al., 2023; LIMA et al., 2025; OLIVEIRA et al., 2026) com enunciados sintéticos gerados por LLMs (MØLLER; AIELLO; AUGENSTEIN, 2024), sendo documentado com protocolo de validação explícito e divisão estratificada.

O terceiro diferencial é a inclusão de *baselines* clássicos, TF-IDF combinado com SVM e Regressão Logística (MANNING; RAGHAVAN; SCHÜTZE, 2008), como referência de comparação. Essa escolha, ausente nos três trabalhos relacionados, permite quantificar objetivamente o ganho obtido pelo BERTimbau, tornando os resultados mais interpretáveis e a análise mais rigorosa (WELD et al., 2022).

O quarto diferencial é a análise sistemática do impacto dos erros de transcrição (WER) sobre o classificador de intenção. Embora Dighe et al. (2024) tratem parcialmente dessa questão, nenhum dos trabalhos propõe avaliação direta e quantitativa da correlação entre WER e degradação do classificador no contexto do português brasileiro, idioma que apresenta desafios específicos para ASR, como alta variabilidade fonética regional e reduções vocálicas da fala informal (JUNIOR et al., 2023; BEVILACQUA et al., 2024).

Em conjunto, esses diferenciais evidenciam que o presente trabalho não é uma replicação dos estudos anteriores em outro idioma, mas uma contribuição com dimensões próprias e complementares ao estado da arte. O objetivo não é superar os resultados de abordagens multimodais como a de Wagner et al. (2024), o que seria improvável dado o escopo e os recursos disponíveis, mas estabelecer um *baseline* textual sólido, reproduzível e documentado para o português brasileiro, que sirva de ponto de partida para investigações futuras na área (WAZLAWICK, 2020; DIGHE et al., 2024).

3 Desenvolvimento

Este capítulo detalha a proposta de desenvolvimento deste trabalho, a arquitetura do sistema, as decisões metodológicas, o planejamento experimental e o cronograma de execução previstos para o TCC2. O foco reside na especificação precisa do que será implementado e avaliado, com cada escolha técnica fundamentada na literatura revisada no Capítulo 2.

3.1 Visão geral da solução proposta

A solução proposta consiste em um sistema de Detecção de Fala Direcionada ao Dispositivo (do inglês *Device-Directed Speech Detection*, referida pela sigla DDSD) para o português brasileiro, operando exclusivamente sobre o nível textual. O sistema recebe um segmento de fala capturado em ambiente controlado, processa esse sinal por meio de um módulo *Automatic Speech Recognition* (traduzido como Reconhecimento Automático de Fala, referenciado pela sigla ASR) e classifica o enunciado resultante como dirigido ao dispositivo ou como conversa incidental, utilizando um classificador baseado em modelos de linguagem pré-treinados (DIGHE et al., 2024; WAGNER et al., 2024).

A arquitetura é deliberadamente modular, os módulos de ASR e de classificação são componentes independentes, com interfaces bem definidas entre si. Essa separação traz duas vantagens concretas. Primeiro, permite a substituição de qualquer componente sem alteração do restante do sistema, o que viabiliza a comparação controlada entre diferentes modelos (WAZLAWICK, 2020). Segundo, favorece a reprodutibilidade e a extensibilidade, pesquisadores futuros poderão reutilizar o módulo de classificação com outros sistemas de ASR, ou vice-versa, sem necessidade de reestruturação.

3.1.1 Arquitetura do pipeline

O *pipeline* completo do sistema é composto por quatro etapas sequenciais, ilustradas na Figura 4:

1. **Captura de áudio:** o sinal de fala é capturado em ambiente controlado e segmentado em enunciados individuais por um módulo de Detecção de Atividade de Voz (VAD, do inglês *Voice Activity Detection*), que delimita os trechos contendo fala (LI et al., 2021);
2. **Transcrição ASR:** o enunciado segmentado é processado pelo Whisper (RADFORD et al., 2023), que gera as N hipóteses textuais mais prováveis (*n-best list*) via *beam search*, ordenadas por probabilidade;

3. **Classificação de intenção:** as hipóteses textuais são processadas pelo classificador binário, que produz uma pontuação de probabilidade para cada classe (dirigida ao dispositivo *versus* conversa incidental);
4. **Decisão:** com base na pontuação do classificador, o sistema emite uma decisão binária que aciona ou não o *pipeline* completo do assistente virtual.

Figura 4 – Arquitetura do pipeline proposto para DDSD textual

Áudio	→	VAD	→	ASR (Whisper)	→	Classificador	→	Decisão
Sinal bruto		Segmento		<i>n-best</i> textual		BERTimbau		DD / NDD

Fonte: Elaborado pelo autor (2026).

Um aspecto central distingue este sistema das abordagens de [Wagner et al. \(2024\)](#) e [Dighe et al. \(2024\)](#): o classificador opera em modalidade textual pura. Isso significa que ele não tem acesso ao sinal de áudio bruto, às representações acústicas internas do Whisper, nem a probabilidades ou escores de confiança do decodificador. As hipóteses geradas pelo *beam search* são tratadas estritamente como sequências de texto. Essa fronteira conceitual é mantida por design ao longo de todo o trabalho.

3.1.2 Definição de ambiente controlado

Para os fins deste trabalho, um ambiente controlado é definido como um cenário de coleta e avaliação com as seguintes características:

- **Ruído ambiental reduzido:** gravações em ambientes com baixo nível de ruído de fundo, sem sobreposição de múltiplos falantes simultâneos e sem música ou televisão ligada durante a captura;
- **Proximidade ao microfone:** enunciados produzidos a distância padronizada do dispositivo de captura, garantindo qualidade acústica consistente entre as amostras;
- **Variedade linguística preservada:** os enunciados cobrem as três classes definidas no cenário motivador (Seção 1.1), comandos diretos ao dispositivo, comentários incidentais e casos ambíguos, sem restrição de sotaque ou variação regional;
- **Ausência de wake-word:** nenhum enunciado do corpus utiliza palavras de ativação explícitas, garantindo que o classificador opere exclusivamente sobre o conteúdo linguístico.

Essa delimitação é uma escolha estratégica de escopo, conforme discutido na Seção 1.6. Cenários com ruído elevado, múltiplos falantes ou condições acústicas adversas representam extensões naturais para trabalhos futuros ([JUNIOR et al., 2023](#)).

3.2 Módulo ASR: transcrição e geração do *n-best*

3.2.1 Escolha e configuração do Whisper

O módulo ASR será implementado com o Whisper, desenvolvido pela OpenAI ([RADFORD et al., 2023](#)). Três razões sustentam essa escolha: (i) desempenho competitivo em português brasileiro sem adaptação específica ao idioma, graças à arquitetura treinada em 680 mil horas de dados multilíngues sob supervisão fraca; (ii) disponibilidade de múltiplos tamanhos de modelo, permitindo comparações entre precisão e custo computacional; e (iii) suporte nativo a *beam search* com geração de múltiplas hipóteses, essencial para a estratégia de *n-best* adotada neste trabalho.

Serão avaliadas três variantes, selecionadas para cobrir diferentes pontos do *trade-off* entre precisão e eficiência, conforme a Tabela 4.

Tabela 4 – Variantes do Whisper avaliadas no módulo ASR

Modelo	Parâmetros	Camadas decoder	Uso previsto
Whisper Medium	307M	24	Referência intermediária
Whisper Large V3	1,5B	32	Maior precisão
Whisper Large V3 Turbo	~809M	4	Maior velocidade

Fonte: Elaborado pelo autor com base em [Radford et al. \(2023\)](#), [Jeffries et al. \(2024\)](#), [Bevilacqua et al. \(2024\)](#).

O Whisper Large V3 Turbo merece destaque, ao reduzir o número de camadas do decodificador de 32 para 4, mantém desempenho próximo ao modelo completo com ganho de velocidade de aproximadamente 6 vezes ([JEFFRIES et al., 2024](#); [BEVILACQUA et al., 2024](#)), tornando-o particularmente adequado para cenários com restrições de latência. A comparação entre as três variantes permitirá analisar a relação entre o WER de cada modelo e o desempenho final do classificador, conforme previsto no terceiro objetivo específico (Seção 1.5).

3.2.2 Estratégia de uso do *n-best*

Em vez de utilizar apenas a transcrição mais provável (1-best), este trabalho adotará a estratégia de *n-best*, na qual as N hipóteses textuais mais prováveis geradas pelo *beam search* do Whisper são fornecidas ao classificador. [Dighe et al. \(2024\)](#) demonstraram que hipóteses alternativas contêm informações complementares à transcrição principal e contribuem para melhorar o entendimento semântico, especialmente quando a 1-best apresenta erros.

As N hipóteses são tratadas exclusivamente como texto, o classificador recebe apenas as transcrições, sem acesso a probabilidades acústicas ou escores de confiança do decodificador.

A representação como entrada para o classificador será implementada por concatenação das N transcrições, separadas pelo token especial [SEP] do BERTimbau (DEVLIN et al., 2019; SOUZA; NOGUEIRA; LOTUFO, 2020).

O valor de N será definido empiricamente durante os experimentos do TCC2, com valores iniciais de $N \in \{1, 3, 5\}$. Essa faixa foi escolhida com base em duas considerações práticas, o valor $N = 1$ serve como referência (equivale ao uso convencional da transcrição 1-best), enquanto $N = 3$ e $N = 5$ exploram o ganho incremental de hipóteses adicionais sem ultrapassar o limite de 128 tokens do BERTimbau, enunciados típicos de assistentes de voz raramente excedem 15 palavras, de modo que 5 hipóteses concatenadas permanecem dentro da capacidade do modelo na maioria dos casos.

3.2.3 Impacto esperado dos erros de transcrição (WER)

A qualidade das transcrições é fator crítico para o desempenho do classificador. Erros de transcrição podem corromper palavras semanticamente relevantes e degradar a capacidade discriminativa do modelo (DIGHE et al., 2024). A título de exemplo, o enunciado “acende a luz da sala” transcrito erroneamente como “acendes a luz da sela” pode confundir o classificador, especialmente em casos ambíguos.

Para quantificar esse impacto, o experimento *upper-bound* detalhado na Seção 3.5.2 avaliará o classificador sobre transcrições manuais (sem erros de ASR) e sobre transcrições automáticas (com erros reais do Whisper), permitindo isolar a degradação atribuível ao módulo ASR. Espera-se que a estratégia de *n-best* contribua para reduzir parcialmente essa degradação ao oferecer hipóteses alternativas que contenham a palavra correta quando a 1-best apresentar erro (DIGHE et al., 2024).

3.3 Módulo de classificação de intenção

3.3.1 Modelo principal: BERTimbau com *fine-tuning*

O classificador principal será o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020). A escolha justifica-se por três fatores: (i) superioridade consistente sobre modelos multilíngues em tarefas de classificação textual em português, demonstrada em múltiplos *benchmarks* (SOUZA; NOGUEIRA; LOTUFO, 2020); (ii) capacidade de *fine-tuning* eficiente com quantidades moderadas de dados rotulados, característica crítica dado o tamanho do corpus de DDS em português; e (iii) ampla adoção na literatura de NLP em português, o que facilita a reprodutibilidade e a comparação com estudos futuros.

O processo de *fine-tuning* seguirá a metodologia padrão de Devlin et al. (2019), uma camada de classificação linear com ativação *softmax* será adicionada sobre a representação do token [CLS], e o modelo completo será treinado para minimizar a entropia cruzada binária. Os hiperparâmetros iniciais estão descritos na Tabela 5.

Tabela 5 – Hiperparâmetros iniciais para o *fine-tuning* do BERTimbau

Hiperparâmetro	Valor inicial	Justificativa
Taxa de aprendizado	2×10^{-5}	Padrão BERT (DEVLIN et al., 2019)
Tamanho do batch	16 ou 32	Limitação de memória GPU
Épocas de treinamento	3–5	Padrão <i>fine-tuning</i> (DEVLIN et al., 2019)
Comprimento máx. de sequência	128 tokens	Adequado a enunciados curtos
<i>Warmup steps</i>	10% do total	Estabilidade no início
<i>Dropout</i>	0,1	Regularização padrão BERT

Fonte: Elaborado pelo autor com base em Devlin et al. (2019), Souza, Nogueira e Lotufo (2020).

Serão avaliadas as duas variantes disponíveis: BERTimbau Base (12 camadas, 110M de parâmetros) e BERTimbau Large (24 camadas, 335M de parâmetros) (SOUZA; NOGUEIRA; LOTUFO, 2020). A versão Base será o padrão principal; a versão Large será avaliada como alternativa de maior capacidade representacional, condicionada aos recursos computacionais disponíveis no TCC2.

3.3.2 Modelos alternativos: DeBERTinha e Albertina

Além do BERTimbau, dois modelos alternativos serão avaliados caso os recursos computacionais e o cronograma permitam, a DeBERTinha (ABONIZIO et al., 2023) e a Albertina PT-BR (RODRIGUES et al., 2023).

A DeBERTinha é uma versão compacta do DeBERTaV3, adaptada para o português brasileiro por Abonizio et al. (2023), com aproximadamente 70 milhões de parâmetros. Apesar de seu tamanho reduzido, demonstrou desempenho competitivo ou superior ao BERTimbau Large em diversas tarefas de NLP para o português, com vantagem em eficiência computacional. Sua avaliação é motivada pela possibilidade de que um modelo mais eficiente alcance desempenho comparável ao BERTimbau em DDSD, o que teria implicações práticas para cenários com recursos limitados.

A Albertina PT-BR (RODRIGUES et al., 2023), construída sobre a arquitetura DeBERTaV2, foi pré-treinada do zero em português, com ênfase na qualidade dos dados de pré-treinamento. Está disponível em variantes de diferentes escalas, desde versões compactas de aproximadamente 100 milhões até versões maiores de cerca de 900 milhões de parâmetros, o que permite selecionar o modelo mais adequado aos recursos disponíveis. Sua avaliação permitirá comparar abordagens de adaptação contínua (*continual pre-training*, como na DeBERTinha) com pré-treinamento do zero em português.

3.3.3 Baselines clássicos: TF-IDF + SVM e Regressão Logística

Para quantificar objetivamente o ganho dos modelos baseados em Transformers, serão implementados dois *baselines* clássicos, TF-IDF combinada com SVM e TF-IDF combinada com Regressão Logística (MANNING; RAGHAVAN; SCHÜTZE, 2008).

As configurações previstas são: (i) TF-IDF com n -gramas de 1 a 3 palavras, para capturar padrões lexicais e sintagmáticos relevantes; (ii) SVM com *kernel* linear e regularização C ajustada por validação cruzada; e (iii) Regressão Logística com regularização L2 e otimizador LBFGS. Ambos receberão como entrada a transcrição 1-best gerada pelo Whisper, representada como vetor TF-IDF esparsos.

A inclusão de *baselines* clássicos constitui uma contribuição metodológica deste trabalho, nenhum dos três estudos relacionados analisados no Capítulo 2 inclui esse tipo de referência (MALLIDI et al., 2018; WAGNER et al., 2024; DIGHE et al., 2024). Ela permite verificar se a complexidade adicional dos Transformers é de fato justificada pelo ganho de desempenho em uma tarefa com corpus de tamanho moderado, tornando os resultados mais interpretáveis (WELD et al., 2022; MANNING; RAGHAVAN; SCHÜTZE, 2008).

3.4 Construção do corpus

A construção de um corpus textual em português brasileiro para DDS é um dos objetivos específicos centrais deste trabalho e, ao mesmo tempo, uma de suas contribuições mais relevantes. A ausência de corpora públicos para essa tarefa em português, identificada na Seção 2.4.4, impõe a necessidade de um recurso próprio, com protocolo de qualidade documentado (WAZLAWICK, 2020).

Uma característica central distingue este corpus dos corpora de DDS típicos da literatura (MALLIDI et al., 2018; WAGNER et al., 2024), ele é **exclusivamente textual**, sem gravações de áudio nem anotações acústicas. Isso decorre da modalidade de entrada do classificador proposto, que opera sobre transcrições textuais. Além de coerente com a abordagem técnica, essa decisão remove as restrições de escala que corpora de fala impõem, a coleta e anotação de texto é significativamente mais rápida e barata do que a gravação e transcrição de áudio (MØLLER; AIELLO; AUGENSTEIN, 2024). Estima-se um corpus de grande escala, com volume superior a 100.000 amostras textuais, o que representa uma ordem de grandeza acima dos corpora de DDS reportados na literatura.

Para garantir a viabilidade dos experimentos mesmo em caso de dificuldades na construção do corpus completo, define-se um volume mínimo viável de 40.000 amostras (aproximadamente 20.000 por classe principal). Abaixo desse limiar, a capacidade de *fine-tuning* do BERTimbau e a representatividade estatística dos resultados seriam comprometidas, exigindo reavaliação do escopo experimental.

3.4.1 Esquema de rotulação

Cada enunciado do corpus receberá um rótulo dentre três categorias:

- **DD** (*Device-Directed*): enunciado claramente dirigido ao assistente virtual, comando, pergunta ou solicitação. Exemplos: “liga o ventilador”, “qual a previsão do tempo para amanhã?”, “toca uma música relaxante”;
- **NDD** (*Non-Device-Directed*): enunciado claramente não dirigido ao dispositivo, sendo parte de conversa entre humanos ou comentário incidental. Exemplos: “nossa, está quente hoje”, “você foi ao mercado ontem?”, “preciso terminar esse relatório”;
- **AMB** (*Ambiguous*): enunciado cuja interpretação como DD ou NDD depende de contexto não disponível no texto. Exemplos: “apaga a luz, por favor”, “pode colocar mais baixo?”, “me lembra disso amanhã”.

Para a classificação binária, os enunciados **AMB** serão tratados como **NDD**, seguindo a lógica conservadora de que, na ausência de contexto suficiente para confirmar a intenção, o sistema não deve acionar o assistente. Essa convenção alinha-se com a definição do problema como classificação binária (MALLIDI et al., 2018) e com o princípio de minimização de ativações indevidas. Os enunciados **AMB** serão mantidos como subconjunto identificado por uma *flag*, permitindo análises de desempenho segmentadas.

É necessário reconhecer que a fusão de **AMB** com **NDD** introduz um viés conservador mensurável, casos genuinamente ambíguos tendem a ser mais fáceis de classificar como **NDD**, o que pode inflacionar artificialmente as métricas no subconjunto **AMB**. Para controlar esse efeito, os resultados serão reportados em duas perspectivas, desempenho sobre o corpus completo e desempenho sobre amostras inequívocas (apenas **DD** e **NDD** puros). Essa análise segmentada tornará as conclusões metodologicamente mais robustas.

3.4.2 Fontes de dados e estratégias de construção

O corpus será construído a partir de duas fontes complementares, dados públicos existentes para a classe **NDD** e dados gerados sinteticamente com auxílio de LLMs para as classes **DD** e **AMB**.

3.4.2.1 Classe **NDD**: datasets públicos de fala espontânea

A classe **NDD** será composta por transcrições de corpora públicos de fala espontânea, selecionados por sua diversidade dialetal, de registro e de contexto. Três corpora serão utilizados como fontes primárias:

O **CORAA ASR** (JUNIOR et al., 2023) é um dos maiores corpora de fala espontânea validados manualmente para o português brasileiro, com transcrições de entrevistas, apresentações e conversas informais em diferentes variedades regionais. Suas transcrições

são ricas em vocabulário cotidiano e padrões conversacionais naturais, tornando-o adequado para representar enunciados incidentais.

O **NURC-SP** (LIMA et al., 2025) contém gravações de fala espontânea paulistana em contextos formais e informais. Sua inclusão contribui para a representatividade do português falado em São Paulo, variedade amplamente presente nos contextos de uso de assistentes de voz.

O **TAGARELA** (OLIVEIRA et al., 2026) é um corpus de fala extraído de *podcasts* em português brasileiro, caracterizado por fala semi-espontânea em formato conversacional. Sua inclusão adiciona diversidade temática e de estilo ao subconjunto NDD.

As transcrições desses corpora não requerem nova anotação para a classe NDD, pois por definição representam fala espontânea em contextos sem assistentes de voz. Uma amostragem aleatória estratificada por corpus e por tipo de contexto será aplicada para garantir diversidade.

3.4.2.2 Classes DD e AMB: geração sintética assistida por LLM

A classe DD não possui representação natural em corpora de fala espontânea, pois enunciados dirigidos a assistentes raramente ocorrem em gravações de conversação cotidiana. Para suprir essa lacuna em escala, será adotada uma abordagem de geração sintética assistida por LLMs, estratégia com respaldo crescente na literatura de NLP para criação de dados em domínios com poucos recursos (MØLLER; AIELLO; AUGENSTEIN, 2024).

A geração será estruturada em três estratégias complementares:

Estratégia 1: Expansão por paráfrase de templates. Serão elaborados manualmente entre 200 e 300 templates de enunciados imperativos e interrogativos típicos de assistentes de voz, cobrindo domínios como controle de dispositivos domésticos, consulta de informações, entretenimento, produtividade e comunicação. Cada template será fornecido a um LLM com a instrução de gerar múltiplas paráfrases naturais em português brasileiro, variando formalidade, grau de implicação e estrutura sintática (MØLLER; AIELLO; AUGENSTEIN, 2024).

Estratégia 2: Geração por *role-playing* contextual. O LLM será instruído a adotar o papel de um usuário em diferentes contextos domésticos (cozinha, sala, quarto, escritório, carro) e a gerar enunciados que esse usuário diria ao assistente sem *wake-words*. O tom e o estado emocional também serão variados (casual, apressado, educado, irritado, sussurrando) para capturar a diversidade de registros em uso real. Essa estratégia produz enunciados mais contextualizados e naturais que a expansão por templates.

Estratégia 3: Geração de diálogos sintéticos completos. O LLM gerará diálogos completos simulando uma pessoa em ambiente doméstico alternando entre conversas com outros humanos e enunciados ao assistente. Cada turno será rotulado como DD, NDD ou AMB pelo próprio LLM, sendo o rótulo posteriormente validado por revisão humana. Essa

estratégia é especialmente útil para a classe **AMB**, pois a ambiguidade surge naturalmente em diálogos mistos. O Quadro 6 apresenta um exemplo de saída esperada.

Tabela 6 – Exemplo de diálogo sintético gerado por LLM com rótulos de classe

Enunciado	Rótulo
“Nossa, está muito quente aqui hoje.”	NDD
“Tem como liga o ventilador, por favor.”	AMB
“Coloca o ventilador no máximo.”	DD
“Você foi ao mercado ontem?”	NDD
“Qual a previsão do tempo para amanhã?”	DD
“Me lembra de ligar para o médico às três.”	DD
“Preciso terminar esse relatório hoje.”	NDD

Fonte: Elaborado pelo autor (2026).

Os LLMs utilizados incluirão modelos de alta capacidade disponíveis via API (GPT-4o, Claude, Gemini) e modelos com foco em português brasileiro, como o Sabiá (PIRES et al., 2023), priorizando a naturalidade e a correção gramatical dos enunciados gerados.

Um risco inerente à geração sintética é o viés de artefato linguístico, amostras geradas por LLMs tendem a apresentar linguagem mais formal, sintaticamente regular e semanticamente explícita do que a fala espontânea real, que é marcada por disfluências, reduções fonéticas e construções coloquiais (MØLLER; AIELLO; AUGENSTEIN, 2024). Para mitigar esse viés, serão adotadas três medidas: (i) instrução explícita dos LLMs para emular registros coloquiais, incluindo marcadores de disfluência típicos do português falado (“né”, “tipo”, “então”, hesitações); (ii) variação sistemática de parâmetros de temperatura e de estilo nos *prompts*; (iii) comparação da distribuição de características lexicais (comprimento médio de sentença, riqueza vocabular, frequência de marcadores informais) entre as amostras sintéticas e as transcrições dos corpora públicos. Caso disparidades significativas sejam detectadas, os *prompts* serão refinados e as amostras problemáticas re-geradas.

A Tabela 7 resume as fontes, estratégias e volumes estimados do corpus.

Os volumes apresentados são estimativas iniciais sujeitas a ajuste durante a execução do TCC2, em função da disponibilidade dos corpora públicos e da capacidade de geração dos LLMs utilizados. O critério de balanceamento entre classes DD e NDD será monitorado durante a construção: caso a razão entre classes supere 3:1, serão adotadas técnicas de balanceamento durante o treinamento, como ponderação de classes (*class weighting*) ou *oversampling* da classe minoritária.

3.4.3 Protocolo de validação e controle de qualidade

Dado que a maioria das amostras NDD é extraída de corpora validados publicamente e que as amostras DD e AMB são geradas sinteticamente com rótulos atribuídos pelo próprio

Tabela 7 – Fontes, estratégias e volumes estimados do corpus de DDSD em PT-BR

Fonte / Estratégia	Classe	Método	Volume estimado
CORAA ASR	NDD	Extração de transcrições	~30.000
NURC-SP	NDD	Extração de transcrições	~20.000
TAGARELA	NDD	Extração de transcrições	~20.000
<i>Template-based paraphrasing</i>	DD	LLM (geração sintética)	~15.000
<i>Role-playing</i> contextual	DD	LLM (geração sintética)	~10.000
Diálogos sintéticos	DD / AMB	LLM (geração sintética)	~10.000
Total estimado	—	—	~105.000 amostras

Fonte: Elaborado pelo autor (2026).

LLM, o protocolo de qualidade deste corpus difere do protocolo de anotação manual clássico. Ele é estruturado em duas etapas complementares:

Etapla 1 — Validação por amostragem humana. Uma amostra aleatória estratificada de 5% de cada subconjunto (NDD extraído, DD sintético e AMB sintético) será revisada manualmente por dois avaliadores independentes, falantes nativos do português brasileiro. A escolha de 5% por subconjunto corresponde, dado o volume estimado do corpus, a aproximadamente 3.500 amostras por avaliador — tamanho considerado suficiente para detectar, com margem de erro de 5% e intervalo de confiança de 95%, desvios de qualidade superiores a 5 pontos percentuais na taxa de acerto de rótulos (MANNING; RAGHAVAN; SCHÜTZE, 2008). Para cada amostra, os avaliadores confirmarão ou corrigirão o rótulo atribuído, sem acesso ao rótulo original. A concordância entre avaliadores será medida pelo coeficiente Kappa de Cohen; amostras com discordância serão resolvidas por um terceiro avaliador. Um valor de Kappa acima de 0,70 no subconjunto amostrado será considerado indicativo de qualidade aceitável para o corpus completo; caso o Kappa obtido seja inferior a 0,60, o protocolo de geração sintética será revisado antes de prosseguir com o corpus completo.

Etapla 2 — Filtragem automática de qualidade. Amostras com comprimento inferior a 3 tokens ou superior a 50 tokens serão descartadas, por fugirem do padrão típico de enunciados de assistentes de voz. Duplicatas exatas e duplicatas aproximadas (similaridade cossenoidal TF-IDF superior a 0,95) também serão removidas para evitar contaminação entre treino e teste (MANNING; RAGHAVAN; SCHÜTZE, 2008).

3.4.4 Divisão treino / validação / teste

O corpus será dividido nas proporções 70% treino, 15% validação e 15% teste (MANNING; RAGHAVAN; SCHÜTZE, 2008), com divisão estratificada por classe e por fonte de dados. A estratificação por fonte é essencial para garantir que cada subconjunto contenha amostras de todas as origens (corpora públicos e geração sintética), evitando que o conjunto

de teste seja composto exclusivamente por um único tipo de dado.

O conjunto de teste será mantido estritamente reservado durante todo o processo de desenvolvimento e ajuste de hiperparâmetros, sendo utilizado exclusivamente na avaliação final (WAZLAWICK, 2020). Adicionalmente, os enunciados AMB serão identificados por uma flag no corpus, permitindo análises de desempenho segmentadas por subconjunto: desempenho geral, desempenho em amostras inequívocas (DD e NDD puros) e desempenho em casos ambíguos.

Por fim, uma versão reduzida do conjunto de teste — composta por amostras com transcrições manuais produzidas durante a fase de validação humana — será utilizada no experimento *upper-bound* descrito na Seção 3.5.2, permitindo estimar o desempenho do classificador sobre texto sem ruído de transcrição ASR.

3.5 Planejamento experimental

O planejamento experimental define o conjunto de experimentos que serão conduzidos no TCC2 para testar a hipótese de pesquisa formulada na Seção 1.5. Os experimentos são organizados em três grupos, detalhados nas subseções a seguir.

3.5.1 Configuração dos experimentos e hiperparâmetros

Experimento 1 — Baselines clássicos. Os modelos TF-IDF + SVM e TF-IDF + Regressão Logística serão treinados e avaliados sobre o conjunto de treinamento, com hiperparâmetros ajustados por validação cruzada de 5 *folds* sobre o conjunto de treino. A entrada será a transcrição 1-best gerada pelo Whisper Large V3 Turbo.

Experimento 2 — BERTimbau com *fine-tuning*. O BERTimbau Base e o BERTimbau Large serão submetidos ao processo de *fine-tuning* descrito na Seção 3.3.1, com diferentes configurações de entrada: (a) transcrição 1-best apenas; e (b) *n-best* com $N \in \{3, 5\}$ hipóteses concatenadas. Os hiperparâmetros iniciais são os descritos na Tabela 5, com ajuste fino por validação no conjunto de validação.

Experimento 3 — Modelos alternativos (condicionais). Caso os recursos computacionais permitam, os modelos DeBERTinha (ABONIZIO et al., 2023) e Albertina (RODRIGUES et al., 2023) serão avaliados com as mesmas configurações do Experimento 2, permitindo comparação direta entre as diferentes famílias de modelos de linguagem para o português brasileiro.

Todos os experimentos serão avaliados sobre o conjunto de teste com as métricas descritas na Seção 2.3.7: F1-score, acurácia, precisão, *recall*, Taxa de Erro Igual (conhecida por EER, do inglês *Equal Error Rate*) e ROC-AUC. Os resultados serão reportados com média e desvio padrão sobre 5 execuções com diferentes sementes aleatórias, garantindo a robustez estatística das conclusões (WAZLAWICK, 2020).

3.5.2 Experimento *upper-bound*: transcrição manual *versus* automática

O terceiro objetivo específico deste trabalho prevê a análise sistemática do impacto dos erros de transcrição ASR no desempenho do classificador de intenção (DIGHE et al., 2024). Para isso, será conduzido um experimento específico denominado *upper-bound*:

1. O classificador BERTimbau (melhor configuração dos Experimentos 1 e 2) será avaliado sobre o conjunto de teste com transcrições **manuais** (sem erros de ASR), produzindo o desempenho *upper-bound* — o teto teórico da abordagem textual com entrada perfeita;
2. O mesmo classificador será avaliado sobre o conjunto de teste com transcrições **automáticas** geradas pelas três variantes do Whisper (Medium, Large V3 e Large V3 Turbo), produzindo os desempenhos reais do sistema completo;
3. A diferença entre o desempenho *upper-bound* e os desempenhos com transcrições automáticas será analisada em função do WER de cada variante do Whisper, verificando se existe correlação entre a taxa de erro de transcrição e a degradação do classificador.

Esse experimento é particularmente relevante para o contexto do português brasileiro, idioma que apresenta desafios específicos para sistemas de ASR, como alta variabilidade fonética regional, reduções vocálicas e contrações características da fala informal (JUNIOR et al., 2023; BEVILACQUA et al., 2024).

3.5.3 Análise de interpretabilidade

Para além das métricas quantitativas, será conduzida uma análise qualitativa de interpretabilidade dos resultados do classificador BERTimbau. Essa análise tem dois objetivos: (i) identificar os padrões linguísticos mais discriminativos para a tarefa de DDSD em português brasileiro; e (ii) verificar se os erros do classificador concentram-se nos casos ambíguos esperados, validando a coerência dos resultados com a teoria.

A análise de interpretabilidade será realizada por meio da técnica SHAP (*SHapley Additive exPlanations*) aplicada aos modelos *baseline* (TF-IDF + SVM/LR), que por sua natureza linear permitem identificar diretamente as *features* (termos do vocabulário) com maior peso discriminativo. Para o BERTimbau, será utilizada a técnica de visualização de pesos de atenção (*attention visualization*), que permite identificar quais tokens o modelo considera mais relevantes para a decisão de classificação (WELD et al., 2022).

3.6 Critérios de validação e aceitação da hipótese

A hipótese de pesquisa formulada na Seção 1.5 será considerada **confirmada** se, e somente se, os seguintes critérios forem simultaneamente satisfeitos sobre o conjunto de teste:

1. **Superioridade sobre os baselines clássicos:** o BERTimbau com *fine-tuning* deve alcançar F1-score estatisticamente superior (teste t de Student com $p < 0,05$) ao melhor *baseline* clássico (TF-IDF + SVM ou Regressão Logística).
2. **Viabilidade técnica da abordagem textual:** o sistema proposto deve alcançar EER inferior a 30% sobre o conjunto de teste, limiar definido como indicativo de capacidade discriminativa não trivial da abordagem textual para DDS em português brasileiro. Esse limiar foi estabelecido com base na premissa de que um classificador sem capacidade discriminativa real convergiria para EER próximo a 50% (equivalente à chance), e que qualquer valor substancialmente abaixo desse patamar constitui evidência de viabilidade técnica.
3. **Ganho mensurável do *n-best* sobre o 1-best:** a configuração com *n-best* ($N > 1$) deve apresentar F1-score igual ou superior à configuração com apenas a transcrição 1-best, validando a estratégia de uso de múltiplas hipóteses do ASR.

Caso a hipótese não seja confirmada, os resultados serão igualmente reportados e analisados, pois resultados negativos também contribuem para o avanço do conhecimento na área, especialmente no contexto de um *baseline* inicial para DDS em português brasileiro (WAZLAWICK, 2020).

3.7 Tecnologias e ferramentas

A implementação do sistema proposto utilizará o ecossistema Python de aprendizado de máquina e processamento de linguagem natural, consolidado como padrão na área (WELD et al., 2022). A Tabela 8 lista as principais bibliotecas e ferramentas previstas.

Os experimentos serão executados em ambiente com suporte a GPU, dado o custo computacional do *fine-tuning* de modelos baseados em Transformers. Caso os recursos computacionais locais sejam insuficientes, será utilizada a plataforma Google Colab Pro ou equivalente com acesso a GPUs de pelo menos 16GB de VRAM, requisito mínimo para o *fine-tuning* do BERTimbau Large (SOUZA; NOGUEIRA; LOTUFO, 2020).

Tabela 8 – Tecnologias e ferramentas previstas para o desenvolvimento

Ferramenta	Versão prevista	Finalidade
Python	3.11+	Linguagem principal
PyTorch	2.x	Framework de deep learning
HuggingFace Transformers	4.x	Fine-tuning BERTimbau
HuggingFace Datasets	2.x	Gerenciamento do corpus
OpenAI Whisper	Large V3	Módulo ASR
scikit-learn	1.x	Baselines TF-IDF + SVM/LR
NumPy / Pandas	—	Manipulação de dados
Matplotlib / Seaborn	—	Visualização de resultados
SHAP	—	Análise de interpretabilidade
Git / GitHub	—	Controle de versão

Fonte: Elaborado pelo autor (2026).

3.8 Resultados esperados

Com base na literatura revisada no Capítulo 2 e nas escolhas metodológicas descritas neste capítulo, são esperados os seguintes resultados ao final do TCC2:

(i) **Corpus textual de DDS em português brasileiro.** Espera-se a produção de um corpus com aproximadamente 105.000 amostras textuais anotadas, distribuídas entre as classes DD, NDD e AMB, construído a partir de corpora públicos de fala espontânea e de geração sintética assistida por LLMs (MÖLLER; AIELLO; AUGENSTEIN, 2024). Esse corpus será a primeira contribuição pública de grande escala para DDS em português brasileiro, de acordo com o levantamento realizado na metodologia de pesquisa bibliográfica (Seção 2.1).

(ii) **Superioridade do BERTimbau sobre os baselines clássicos.** Com base em Weld et al. (2022), que demonstram que modelos Transformer superam consistentemente abordagens tradicionais em tarefas de classificação de intenção, espera-se que o BERTimbau com *fine-tuning* alcance F1-score superior ao TF-IDF + SVM e à Regressão Logística. A magnitude dessa superioridade dependerá do tamanho final do corpus: em corpora menores, a diferença tende a ser menos expressiva (WELD et al., 2022).

(iii) **Ganho parcial da estratégia *n-best*.** Com base nos achados de Dighe et al. (2024), espera-se que a estratégia de *n-best* contribua para reduzir parcialmente o impacto dos erros de transcrição, especialmente em enunciados com WER elevado. No entanto, o ganho pode ser marginal em casos onde a transcrição 1-best já é de alta qualidade.

(iv) **Degradação mensurável do desempenho com erros de ASR.** O experimento *upper-bound* deverá evidenciar uma degradação estatisticamente significativa entre o


desempenho com transcrições manuais e com transcrições automáticas, com magnitude proporcional ao WER de cada variante do Whisper. Essa análise fornecerá evidências empíricas sobre o papel do módulo ASR como gargalo do sistema proposto.

(v) **Baseline textual inicial para DDSD em PT-BR.** O conjunto de resultados produzidos — corpus, modelos treinados, código e métricas — constituirá o primeiro *baseline* documentado e reprodutível para a tarefa de DDSD em português brasileiro, servindo como ponto de referência para estudos futuros na área (WAZLAWICK, 2020; DIGHE et al., 2024).

3.9 Cronograma de trabalho

O cronograma de execução do TCC2 está organizado em seis fases sequenciais, distribuídas ao longo de um semestre letivo de aproximadamente 16 semanas, conforme ilustrado no diagrama de Gantt da Figura 5.

Figura 5 – Cronograma de execução previsto para o TCC2



Fonte: Elaborado pelo autor (2026).

A Tabela 9 descreve os marcos e entregáveis esperados ao final de cada fase.

Tabela 9 – Marcos e entregáveis por fase do TCC2

Fase	Semanas	Entregável principal
F1 – Corpus	1–5	Corpus anotado e validado
F2 – Implementação	4–9	Pipeline ASR + baselines + modelo BERTimbau
F3 – Experimentos	8–13	Resultados completos dos experimentos
F4 – Análise	12–14	Análise quantitativa e qualitativa
F5 – Escrita	13–15	Texto completo do TCC2 redigido
F6 – Entrega	15–16	TCC2 revisado, submetido e apresentado

Fonte: Elaborado pelo autor (2026).

As Fases F1 e F2 possuem sobreposição intencional a partir da Semana 4, permitindo que o desenvolvimento do módulo ASR inicie paralelamente ao processo final de anotação do corpus. Da mesma forma, as Fases F4 e F5 apresentam sobreposição a partir da Semana 13, viabilizando o início da redação enquanto as análises finais ainda estão em andamento. Essa sobreposição foi planejada para otimizar o tempo disponível dentro das 16 semanas do semestre.

Referências

- ABONIZIO, H. et al. DeBERTinha: A multistep approach to adapt DeBERTaV3 XSmall for Brazilian Portuguese natural language processing tasks. *arXiv preprint arXiv:2309.16844*, 2023. 10, 12, 21, 24, 38, 44
- BEVILACQUA, A. et al. Whispy: Adapting STT whisper models to real-time environments. *arXiv preprint arXiv:2405.03484*, 2024. 9, 13, 26, 33, 36, 45
- CHEN, Y. et al. FakeWake: Understanding and mitigating fake wake-up words of voice assistants. In: *Proceedings of the 2021 ACM SIGSAC Conference on Computer and Communications Security*. [S.l.]: ACM, 2021. p. 1861–1883. 7, 14, 19
- CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, v. 20, n. 3, p. 273–297, 1995. 25
- DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Association for Computational Linguistics, p. 4171–4186, 2019. 16, 20, 21, 23, 37, 38
- DIGHE, P. et al. Leveraging large language models for exploiting asr uncertainty. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2024. 10, 12, 13, 20, 27, 28, 29, 30, 31, 33, 34, 35, 36, 37, 39, 45, 47, 48
- GARG, V. et al. Streaming transformer for hardware efficient voice trigger detection and false trigger mitigation. *Proceedings of Interspeech 2021*, 2021. 7, 17, 18, 19
- GROSMAN, J.; NOGUEIRA, R. Wav2vec 2.0 for Brazilian Portuguese. In: *Anais do Encontro Nacional de Inteligência Artificial e Computacional (ENIAC)*. [S.l.]: SBC, 2021. 9
- HE, P. et al. DeBERTa: Decoding-enhanced BERT with disentangled attention. In: *Proceedings of the 9th International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2021. 24
- JEFFRIES, N. et al. Moonshine: Speech recognition for live transcription and voice commands. *arXiv preprint arXiv:2410.15608*, 2024. 9, 26, 36
- JUNIOR, A. C. et al. Coraa asr: A large corpus of spontaneous and prepared speech manually validated for speech recognition in brazilian portuguese. *Language Resources and Evaluation*, Springer, v. 57, p. 1139–1171, 2023. 11, 13, 14, 32, 33, 35, 40, 45
- JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.]: Pearson, 2024. Rascunho online disponível em <https://web.stanford.edu/~jurafsky/slp3/>. 7, 17, 18, 20
- KRISHNA, G. et al. Modality dropout for multimodal device directed speech detection using verbal and non-verbal features. *arXiv preprint arXiv:2310.15261*, 2023. 11, 13, 20, 27

- KUNDU, A. et al. Heimdal: Highly efficient method for detection and localization of wake-words. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2023. 19
- LI, N. et al. Robust voice activity detection using a masked auditory encoder based convolutional neural network. In: *IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*. [S.l.: s.n.], 2021. 17, 18, 34
- LIMA, R. et al. A large dataset of spontaneous speech with the accent spoken in são paulo for automatic speech recognition evaluation. In: *Intelligent Systems*. [S.l.]: Springer, 2025. (Lecture Notes in Computer Science). 11, 13, 32, 41
- MALLIDI, S. H. et al. Device-directed utterance detection. In: *Proceedings of Interspeech 2018*. [S.l.: s.n.], 2018. p. 3629–3633. 8, 9, 11, 16, 19, 28, 29, 39, 40
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press, 2008. 20, 25, 27, 31, 33, 39, 43
- MØLLER, A. G.; AIELLO, L. M.; AUGENSTEIN, I. Is a prompt and a few samples all you need? using GPT-4 for data augmentation in low-resource classification tasks. In: *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. [S.l.]: ELRA and ICCL, 2024. p. 12764–12779. 32, 39, 41, 42, 47
- Next Move Strategy Consulting. *Voice Assistant Market Size and Share / Statistics 2025-2030*. 2025. Acesso em: 09 abr. 2026. Disponível em: <<https://www.nextmsc.com/report/voice-assistant-market>>. 7, 17
- NIE, L. et al. Multimodal activation: Awakening dialog robots without wake words. In: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. [S.l.]: ACM, 2021. p. 491–500. 7, 11, 19, 20, 29
- NOROUZIAN, A. et al. Exploring attention mechanism for acoustic-based classification of speech utterances into system-directed and non-system-directed. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2019. p. 7310–7314. 11, 13, 16, 20
- OLIVEIRA, F. S. de et al. Tagarela: A portuguese speech dataset from podcasts. *arXiv preprint arXiv:2603.15326*, 2026. 11, 13, 32, 41
- PIRES, R. et al. Sabiá: Portuguese large language models. In: *Brazilian Conference on Intelligent Systems (BRACIS)*. [S.l.]: Springer, 2023. p. 226–240. 10, 42
- RADFORD, A. et al. Robust speech recognition via large-scale weak supervision. *Proceedings of the 40th International Conference on Machine Learning*, PMLR, p. 28492–28518, 2023. 9, 18, 26, 34, 36
- RODRIGUES, J. et al. Advancing neural encoding of Portuguese with transformer Albertina PT-*. *arXiv preprint arXiv:2305.06721*, 2023. 10, 21, 25, 38, 44
- RUDOVIC, O. et al. Device-directed speech detection for follow-up conversations using large language models. In: *NeurIPS 2024 Workshop on Adaptive Foundation Models*. [S.l.: s.n.], 2024. 10

- SHIN, D. *Low Latency and Energy-efficient Hotword Detection Based on Mouth Movement*. [S.l.], 2023. Disponível em: <https://www.tdcommons.org/dpubs_series/6034/>. 19
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: *Proceedings of the Brazilian Conference on Intelligent Systems (BRACIS)*. [S.l.]: Springer, 2020. p. 403–417. 9, 11, 12, 13, 16, 21, 23, 24, 31, 37, 38, 46
- VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems*, v. 30, p. 5998–6008, 2017. 9, 16, 18, 20, 21, 22
- WAGNER, D. et al. A multimodal approach to device-directed speech detection with large language models. In: *IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*. [S.l.: s.n.], 2024. 8, 9, 10, 11, 12, 19, 20, 27, 28, 29, 30, 33, 34, 35, 39
- WAZLAWICK, R. S. *Metodologia de Pesquisa para Ciência da Computação*. 3. ed. Rio de Janeiro: Elsevier, 2020. 28, 32, 33, 34, 39, 44, 46, 48
- WELD, H. et al. A survey of joint intent detection and slot filling models in natural language understanding. *ACM Computing Surveys*, v. 55, n. 8, p. 156, 2022. Levantamento amplo sobre métodos de detecção de intenção. Demonstra que modelos baseados em Transformers pré-treinados como o BERT atingem estado da arte em classificação de intenção textual, superando abordagens tradicionais de ML. 7, 12, 20, 21, 26, 27, 31, 33, 39, 45, 46, 47
- XU, M. et al. Conformer-based speech recognition on extreme edge-computing devices. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Industry Track)*. [S.l.]: Association for Computational Linguistics, 2024. p. 131–139. 11, 30, 31